Apprentissage supervisé avec R

L. Rouvière

4 janvier 2023

Table des matières

Présentation **4**

I Notion de risque en apprentissage **6**

1 Calcul de risques avec R **7**
1.1 L'algorithme des k plus proches voisins . . . 9
1.2 La courbe ROC . . . 11
1.3 Exercices complémentaires . . . 21

2 Estimation du risque par ré-échantillonnage **24**
2.1 Validation croisée . . . 24
2.2 Le package tidymodels . . . 28

3 Compléments **34**
3.1 Variance de l'erreur de validation croisée . . . 34
3.2 Répéter les méthodes de ré-échantillonnage . . . 37
3.3 Calcul parallèle . . . 39

II Arbres **41**

4 Méthodes CART **42**
4.1 Coupures CART en fonction de la nature des variables . . . 42
4.1.1 Arbres de régression . . . 43
4.1.2 Arbres de classification . . . 46
4.1.3 Entrée qualitative . . . 49
4.2 Élagage . . . 50
4.2.1 Élagage pour un problème de régression . . . 50
4.2.2 Élagage en classification binaire et matrice de coût . . . 70
4.2.3 Calcul de la sous-suite d'arbres optimaux . . . 75

III Agrégation **80**

5 Forêts aléatoires **81**

6 Gradient boosting **93**
6.1 Un exemple simple en régression 94
6.2 Adaboost et logitboost pour la classification binaire. 98
6.3 Comparaison de méthodes 104
6.4 Xgboost 110

Références **119**

Présentation

Ce tutoriel présente les principaux algorithmes d'**apprentissage supervisé avec R**. On pourra trouver :

- les supports de cours associés à ce tutoriel ainsi que les données utilisées à l'adresse suivante https://lrouviere.github.io/page_perso/apprentissage_sup.html ;
- le tutoriel sans les correction à l'url https://lrouviere.github.io/TUTO_APP_SUP
- le tutoriel avec les corrigés (à certains moment) à l'url https://lrouviere.github.io/TUTO_APP_SUP/correction.

Les thèmes suivants sont abordés :

- **Estimation du risque**, présentation du package **caret** ;
- **SVM**, cas séparable, non séparable et astuce du noyau ;
- **Arbres**, notamment l'algorithme CART ;
- **Agrégation d'arbres**, forêts aléatoires et gradient boosting ;
- **Réseaux de neurones et introduction au deep learning**, perceptron multicouches avec `keras`.

Il existe de nombreuses références sur le machine learning, la plus connue étant certainement Hastie, Tibshirani, et Friedman (2009), disponible en ligne à l'url https://web.stanford.edu/~hastie/ElemStatLearn/. On pourra également consulter Boehmke et Greenwell (2019) qui propose une présentation très claire des algorithmes machine learning avec **R**. Cet ouvrage est également disponible en ligne à l'url https://bradleyboehmke.github.io/HOML/.

Ce tutoriel présente quelques exercices d'application sur les méthodes par arbres. On pourra trouver

- les supports de cours associés à ce tutoriel ainsi que les données utilisées à l'adresse suivante https://lrouviere.github.io/page_perso/grande_dim.html ;
- le tutoriel sans les corrections à l'url https://lrouviere.github.io/TUTO_ARBRES/
- le tutoriel avec les corrigés (à certains moment) à l'url https://lrouviere.github.io/TUTO_ARBRES/correction.

Il est recommandé d'utiliser **mozilla firefox** pour lire le tutoriel.

Des connaissances de base en R et en statistique (modèles de régression) sont nécessaires. Le tutoriel se structure en 4 parties :

- **Arbres** : construction d'arbres et élagages avec `rpart`
- **Forêts aléatoires** : l'algorithme et le choix des paramètres avec `ranger` et `randomForest`
- **Gradient boosting**: l'algorithme et le choix des paramètres avec `gbm` et `xgboost`

partie I

Notion de risque en apprentissage

1 Calcul de risques avec R

L'apprentissage supervisé consiste à expliquer ou prédire une sortie $y \in \mathcal{Y}$ par des entrées $x \in \mathcal{X}$ (le plus souvent $\mathcal{X} = \mathbb{R}^p$). Cela revient à trouver un **algorithme** ou **machine** représenté par une fonction

$$f : \mathcal{X} \to \mathcal{Y}$$

qui à une nouvelle observation x associe la prévision $f(x)$. Bien entendu le problème consiste à chercher le **meilleur algorithme** pour le cas d'intérêt. Cette notion nécessite de meilleur algorithme la définition de **critères** que l'on va chercher à optimiser. Les critères sont le plus souvent définis à partir du fonction de perte

$$\begin{aligned} \ell : \mathcal{Y} \times \mathcal{Y} &\mapsto \mathbb{R}^+ \\ (y, y') &\to \ell(y, y') \end{aligned}$$

où $\ell(y, y')$ représentera l'erreur (ou la perte) pour la prévision y' par rapport à l'observation y. Si on représente le phénomène d'intérêt par un couple aléatoire (X, Y) à valeurs dans $\mathcal{X} \times \mathcal{Y}$, on mesurera la performance d'un algorithme f par son risque

$$\mathcal{R}(f) = \mathbf{E}[\ell(Y, f(X))].$$

Trouver le meilleur algorithme revient alors à trouver f qui minimise $\mathcal{R}(f)$. Bien entendu, ce cadre possède une utilité limitée en pratique puisqu'on ne connaît jamais la loi de (X, Y), on ne pourra donc jamais calculer le **vrai risque** d'un algorithme f. Tout le problème va donc être de trouver l'algorithme qui a le plus petit risque à partir de n observations $(x_1, y_1), \ldots, (x_n, y_n)$.

Nous verrons dans les chapitres suivants plusieurs façons de construire des algorithmes mais, dans tous les cas, un algorithme est représenté par une fonction

$$f_n : \mathcal{X} \times (\mathcal{X} \times \mathcal{Y})^n \to \mathcal{Y}$$

qui, pour une nouvelle donnée x, renverra la prévision $f_n(x)$ calculée à partir de l'échantillon qui vit dans $(\mathcal{X} \times \mathcal{Y})^n$. Dès lors la question qui se pose est de calculer (ou plutôt d'estimer) le risque (inconnu) $\mathcal{R}(f_n)$ d'un algorithme f_n. Les techniques classiques reposent sur des algorithmes de type validation croisée. Nous les mettons en œuvre dans cette partie pour un algorithme simple : les k plus proches voisins. On commencera par programmer ces techniques "à la main" puis on utilisera le package **tidymodels** qui permet de calculer des risques pour quasiment tous les algorithmes que l'on retrouver en apprentissage supervisé.

Dans cette partie nous considérerons les données suivantes :

```r
gen_class_bin2D <- function(n=100,graine=1234,bayes=0.1){
  set.seed(graine)
  grille <- 0.1
  X1 <- runif(n)
  X2 <- runif(n)
  Y <- rep(0,n)
  cond0 <- (X1>0.2 & X2>=0.8) | (X1>0.6 & X2<0.4) | (X1<0.25 & X2<0.5)
  cond1 <- !cond0
  Y[cond0] <- rbinom(sum(cond0),1,bayes)
  Y[cond1] <- rbinom(sum(cond1),1,1-bayes)
  donnees <- tibble(X1,X2,Y=as.factor(Y))
  px1 <- seq(0,1,by=grille)
  px2 <- seq(0,1,by=grille)
  px <- expand.grid(X1=px1,X2=px2)
  py <- rep(0,nrow(px))
  cond0 <- (px[,1]>0.2 & px[,2]>=0.8) | (px[,1]>0.6 & px[,2]<0.4) | (px[,1]<0.25 & px[,2]<0.5)
  cond1 <- !cond0
  py[cond0] <- 0
  py[cond1] <- 1
  df <- px |> as_tibble() |> mutate(Y=as.factor(py))
  p <- ggplot(df)+aes(x=X1,y=X2,fill=Y)+geom_raster(hjust=1,vjust=1)#+theme(legend.position='none')
  return(list(donnees=donnees,graphe=p))
}
donnees <- gen_class_bin2D(n=500,graine=12345,bayes=0.20)$donnees
head(donnees)
## # A tibble: 6 x 3
##      X1    X2 Y
##   <dbl> <dbl> <fct>
## 1 0.721 0.209 0
## 2 0.876 0.766 1
## 3 0.761 0.842 1
## 4 0.886 0.934 0
## 5 0.456 0.676 0
## 6 0.166 0.859 1
ggplot(donnees)+aes(x=X1,y=X2,color=Y)+geom_point()
```

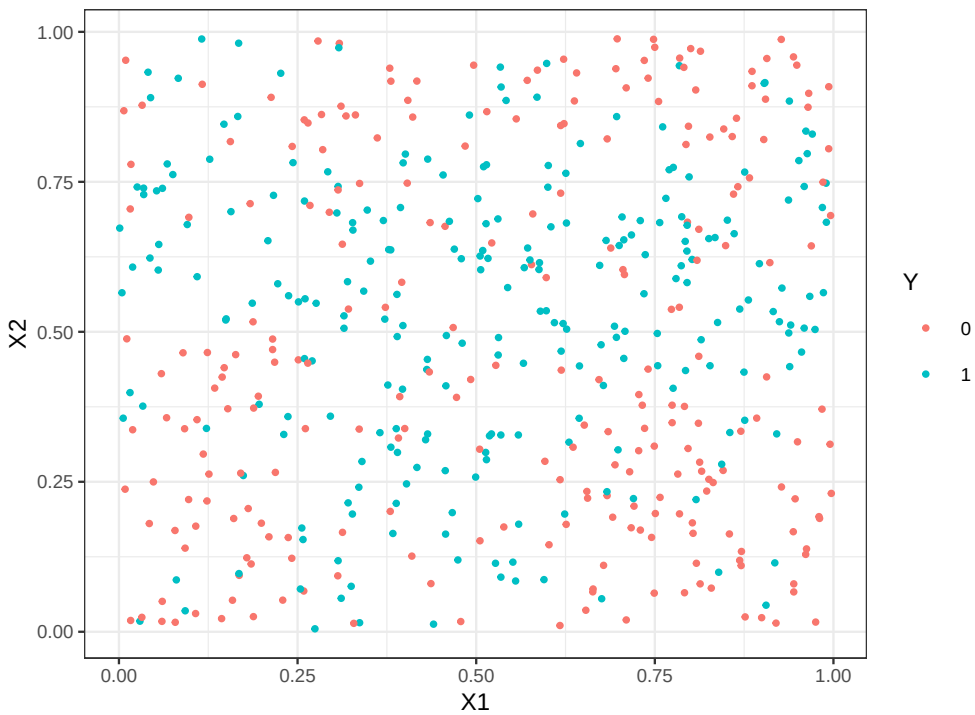

Le problème est d'expliquer/prédire une variable binaire Y par deux variables quantitatives X_1 et X_2.

1.1 L'algorithme des k plus proches voisins

C'est un algorithme simple qui va établir des prévisions en point x à partir des observations qui sont proches de x. Plus précisément, étant donné $k \leq n$ il est défini par

$$g_{n,k}(x) = \begin{cases} 1 & \text{si } \sum_{i \in \text{kppv}(x)} \mathbf{1}_{y_i=1} \geq \sum_{i \in \text{kppv}(x)} \mathbf{1}_{y_i=0} \\ 0 & \text{sinon.} \end{cases}$$

pour la prévision des groupes et par

$$S_{n,k}(x) = \frac{1}{|\text{kppv}(x)|} \sum_{i \in \text{kppv}(x)} \mathbf{1}_{y_i=1}$$

pour la prévision de la probabilité $\mathbf{P}(Y = 1|X = x)$ avec

$$\text{kppv}(x) = \{i \leq n : \|x - x_i\| \leq \|x - x_{(k)}\|\}$$

et $\|x - x_{(k)}\|$ la k^e plus petite valeur parmi $\{\|x - x_1\|, \ldots, \|x - x_n\|\}$.

Exercice 1.1 (kppv avec kknn)**.**

1. Séparer les données en un échantillon d'apprentissage de taille 300 et un échantillon test de taille 200.

```
set.seed(1234)
index.app <- sample(500,300)
dapp <- donnees[index.app,]
dtest <- donnees[-index.app,]
```

2. A l'aide de la fonction **kknn** du package **kknn** entraîner la règle des 3 plus proches voisins sur les données d'apprentissage et calculer les groupes prédits par cette règle des données test.

```
library(kknn)
prev3ppv <- kknn(Y~.,train=dapp,test=dtest,k=3,
                 kernel="rectangular")$fitted.values
head(prev3ppv)
## [1] 0 0 1 1 1 0
## Levels: 0 1
```

3. En déduire une estimation de l'erreur de classification de la règle des 3 plus proches voisins.

   Il suffit de calculer la proportion de mauvaises prévisions sur les données test :

```
mean(prev3ppv!=dtest$Y)
## [1] 0.42
```

4. Retrouver le résultat précédent à l'ai de la fonction `accuracy` du package `yardstick`.

```
library(yardstick)
tbl <- tibble(prev=prev3ppv,obs=dtest$Y)
accuracy(tbl,truth=obs,estimate=prev)
## # A tibble: 1 x 3
##   .metric  .estimator .estimate
##   <chr>    <chr>          <dbl>
## 1 accuracy binary          0.58
1-(accuracy(tbl,truth=obs,estimate=prev) |> select(.estimate))
##   .estimate
## 1      0.42
```

5. Toujours à l'aide des fonctiosn de `yardstick`, calculer la spécificité, le sensibilité et le balanced accuracy. On pourra consulter la page https://yardstick.tidymodels.org/articles/metric-types.html#metrics

```
tbl |> spec(truth=obs,estimate=prev)
## # A tibble: 1 x 3
##   .metric .estimator .estimate
##   <chr>   <chr>          <dbl>
## 1 spec    binary         0.604
tbl |> sens(truth=obs,estimate=prev)
## # A tibble: 1 x 3
##   .metric .estimator .estimate
##   <chr>   <chr>          <dbl>
## 1 sens    binary         0.553
tbl |> bal_accuracy(truth=obs,estimate=prev)
## # A tibble: 1 x 3
##   .metric      .estimator .estimate
##   <chr>        <chr>          <dbl>
## 1 bal_accuracy binary         0.578
```

6. Retrouver les résultats précédents en utilisant la fonction `metric_set`.

```
multi_metric <- metric_set(accuracy,spec,sens,bal_accuracy)
tbl |> multi_metric(truth=obs,estimate=prev)
## # A tibble: 4 x 3
##   .metric      .estimator .estimate
##   <chr>        <chr>          <dbl>
## 1 accuracy     binary         0.58
## 2 spec         binary         0.604
## 3 sens         binary         0.553
## 4 bal_accuracy binary         0.578
```

1.2 La courbe ROC

C'est un critère fréquemment utilisé pour mesurer la performance d'un **score**. Etant donné (X, Y) un couple aléatoire à valeurs dans $\mathcal{X} \times \{-1, 1\}$, on rappelle qu'un score est une fonction $S : \mathcal{X} \to \mathbb{R}$. Dans la plupart des cas, un score s'obtient en estimant la probabilité $\mathbf{P}(Y = 1|X = x)$. Pour un seuil $s \in \mathbb{R}$ fixé, un score possède deux types d'erreur

$$\alpha(s) = \mathbf{P}(S(X) \geq s|Y = -1) \quad \text{et} \quad \beta(s) = \mathbf{P}(S(X) < s|Y = 1).$$

La courbe ROC est la **courbe paramétrée** définie par :

$$\begin{cases} x(s) = \alpha(s) = \mathbf{P}(S(X) > s|Y = -1) \\ y(s) = 1 - \beta(s) = \mathbf{P}(S(X) \geq s|Y = 1) \end{cases}$$

Elle permet donc de visualiser sur une seul graphe 2D ces deux erreurs pour toutes les valeurs de seuil s.

Exercice 1.2 (Étude de la courbe ROC)**.** On considère dans cet exercice une fonction de score S que l'on suppose absolument continue.

1. Montrer que la courbe ROC vit dans le carré $[0,1]^2$.

   On note $x(-\infty) = \lim_{n\to-\infty} x(s)$. On a

   $$x(-\infty) = \lim_{n\to-\infty} \mathbf{P}(S(X) > s|Y = -1) = 1.$$

   De même on montre facilement $y(-\infty) = 1$, $x(\infty) = 0$ et $y(\infty) = 0$. On déduit donc que la courbe ROC part du point $(1,1)$ pour arriver au point $(0,0)$ sans quitter le carré $[0,1]^2$.

2. On suppose dans cette question que S est **parfait**, ce qui revient à dire qu'il sépare parfaitement les 2 groupes. Mathématiquement on traduit cela par l'existence d'un seuil $s^\star \in \mathbb{R}$ tel que

   $$\mathbf{P}(Y = 1|S(X) \geq s^\star) = 1 \quad \text{et} \quad \mathbf{P}(Y = -1|S(X) < s^\star) = 1.$$

   Analyser la courbe ROC du score parfait.

   Il est facile de voir que $\alpha(s^\star) = \beta(s^\star) = 0$. Par conséquent la courbe ROC du score parfait passe par le point $(0,1)$. On déduit que la courbe ROC du score parfait est l'union des segments

   $$[(0,0),(1,0)] \quad \text{et} \quad [(1,0),(1,1)].$$

3. On suppose dans cette question que S est **aléatoire** dans le sens où $S(X)$ est indépendante de Y (cela revient à dire que les notes $S(X)$ n'ont aucun lien avec le groupe). Analyser la courbe ROC d'un tel score.

   En utilisant l'indépendance et l'absolu continuité de $S(X)$ on a

   $$x(s) = \mathbf{P}(S(X) > s|Y = -1) = \mathbf{P}(S(X) > s) = \mathbf{P}(S(X) \geq s) = \mathbf{P}(S(X) \geq s|Y = 1) = y(s),$$

   On déduit que la courbe ROC est la première bissectrice.

Exercice 1.3 (Courbe ROC avec yardstick)**.** On reprend les données de l'Exercice 1.1 et on considère toujours la règle des 3 plus proches voisins entrainée sur les données d'apprentissage.

1. Toujours pour la règle des 3 plus proches voisins, calculer les probabilités $\mathbf{P}(Y = 1|X = x)$ prédites pour les données tests.

```
prob3ppv <- kknn(Y~.,train=dapp,test=dtest,k=3,
             kernel="rectangular")$prob[,2]
```

2. En déduire une estimation de la courbe ROC de la règle des 3 plus proches voisins. On pourra utiliser la fonction **roc_curve** du package **yardstick**.

```
tbl <- tibble(obs=dtest$Y,prob=prob3ppv)
tbl |> roc_curve(truth=obs,prob,event_level="second") |>
  autoplot()
```

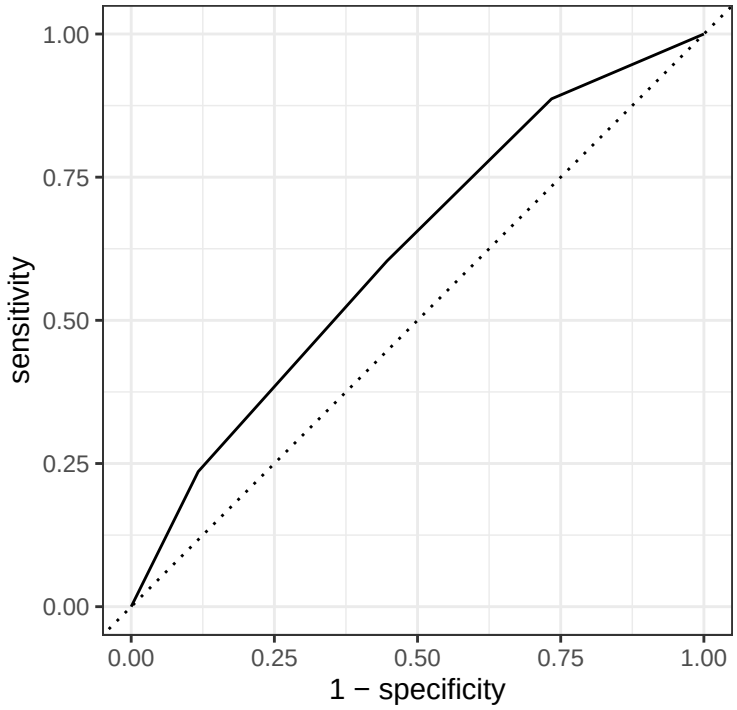

Exercice 1.4 (Autres outils R pour la courbe ROC)**.** On dispose de 4 fonctions de score $S_j(x)$ dont on souhaite visualiser les courbes ROC à partir des valeurs de score calculés sur un échantillon. On trouvera dans le tableau `df` les scores $S_j(X_i), i = 1, \ldots, n$ ainsi que les observations des groupes Y_i

```r
set.seed(12345)
n <- 200
Y <- rbinom(n,1,0.5)
S1 <- runif(n)
S2 <- S1
S2[Y==1] <- runif(sum(Y==1),0.6,1)
S2[Y==0] <- runif(sum(Y==0),0,0.6)
S3 <- S2
S3[Y==1][1:10] <- runif(10,0,0.6)
S3[Y==0][1:10] <- runif(10,0.6,1)
(tbl <- tibble(S1,S2,S3,Y=Y))
## # A tibble: 200 x 4
##        S1    S2      S3     Y
##     <dbl> <dbl>   <dbl> <int>
##  1 0.589  0.630 0.420       1
##  2 0.893  0.790 0.00624     1
##  3 0.124  0.706 0.302       1
##  4 0.513  0.692 0.439       1
##  5 0.664  0.203 0.806       0
##  6 0.766  0.404 0.666       0
##  7 0.0926 0.194 0.954       0
##  8 0.0676 0.838 0.198       1
##  9 0.556  0.664 0.492       1
## 10 0.651  0.942 0.531       1
## # ... with 190 more rows
```

1. Visualiser, pour chaque score, les valeurs de score en fonction de Y. Commenter

```r
tbl1 <- tbl |> pivot_longer(-Y,names_to="Score",values_to="valeurs")
ggplot(tbl1)+aes(x=valeurs,y=Score,color=as.factor(Y))+geom_point()+labs(color="Y")
```

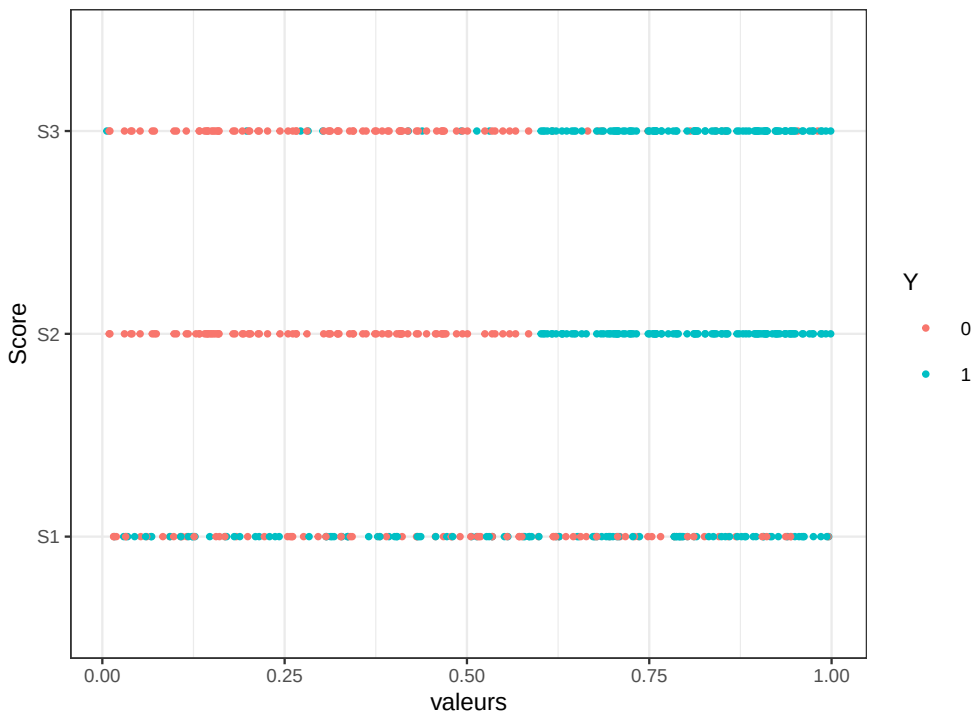

*On remarque que **S2** sépare parfaitement les deux groupes. La séparation de **S3** est satisfaisante mais pas parfaite. **S1** semble quant à lui ordonner les observations indépendamment du groupe (proche du score aléatoire).*

2. Visualiser sur un même graphe les trois courbes ROC. On pourra utiliser d'abord utiliser la fonction **roc** du package **pROC** puis la fonction **geom_roc** du **plotROC** et enfin la fonction **roc_curve** du package **yardstick**.

   *Avec **pROC** on peut combiner les fonction **roc** et **plot**.*

```
library(pROC)
roc.obj <- roc(Y~.,data=tbl)
plot(roc.obj[[1]])
plot(roc.obj[[2]],add=TRUE,col="red")
plot(roc.obj[[3]],add=TRUE,col="blue")
legend("bottomright",legend=c("S1","S2","S3"),col=c("black","red","blue"),lwd=3,cex=0.5)
```

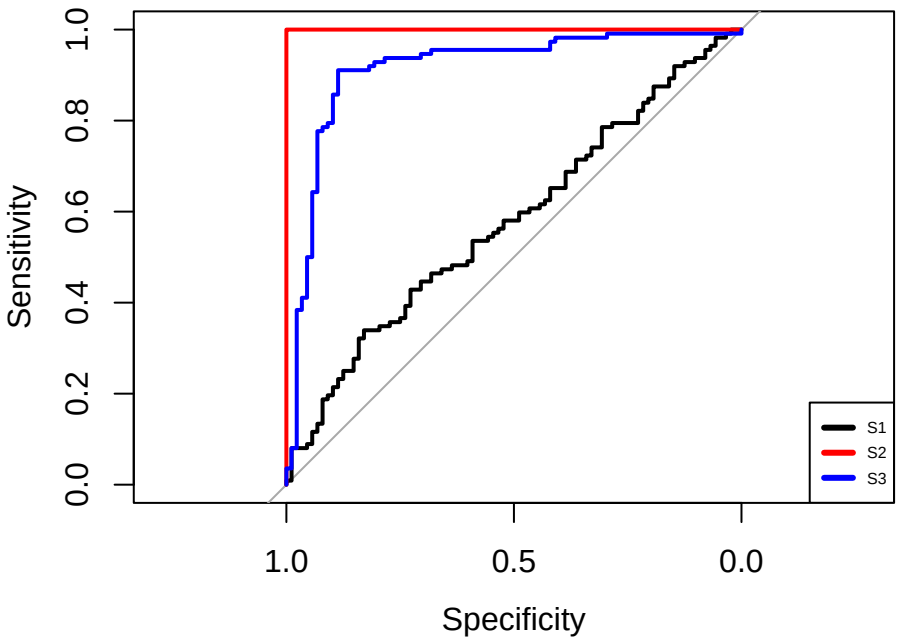

pROC *possède également une fonction* ***ggroc*** *qui permet d'obtenir les courbes ROC en* ***ggplot****.*

```
pROC::ggroc(roc.obj)+labs(color="Score")
```

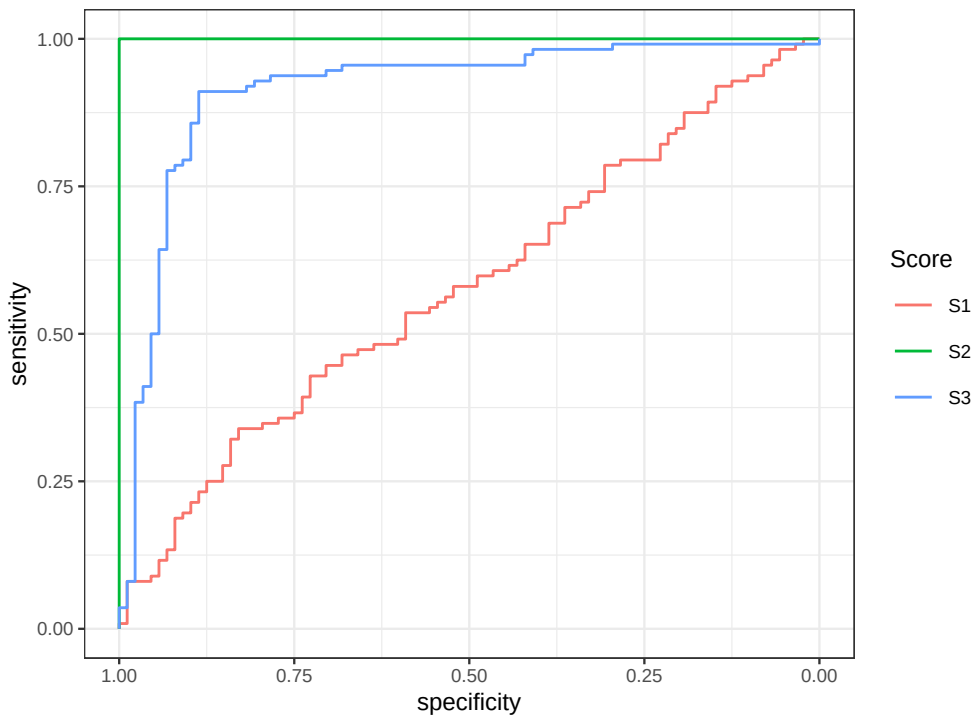

Pour ***plotROC*** *on utilise le verbe* ***geom_roc*** *:*

```
library(plotROC)
ggplot(tbl1)+aes(d=Y,m=valeurs,color=Score)+geom_roc(n.cuts=0)
```

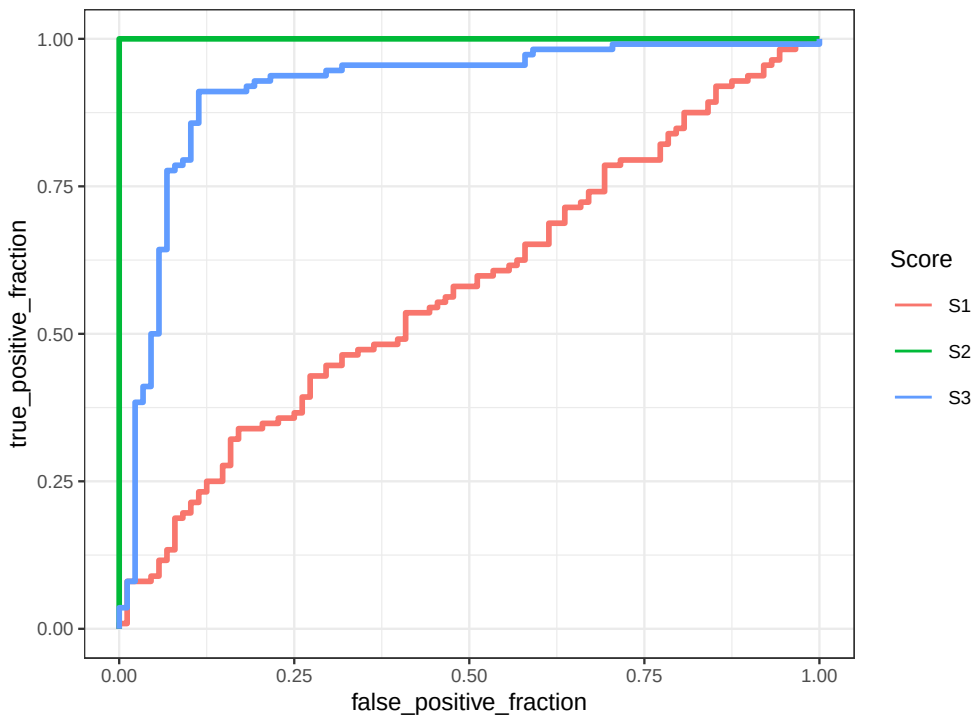

Enfin avec ***roc_curve*** *:*

```
tbl |> pivot_longer(-Y,names_to = "Score",values_to = "valeur") |>
  group_by(Score) |>
  roc_curve(truth=as.factor(Y),valeur,event_level="second") |>
  autoplot()
```

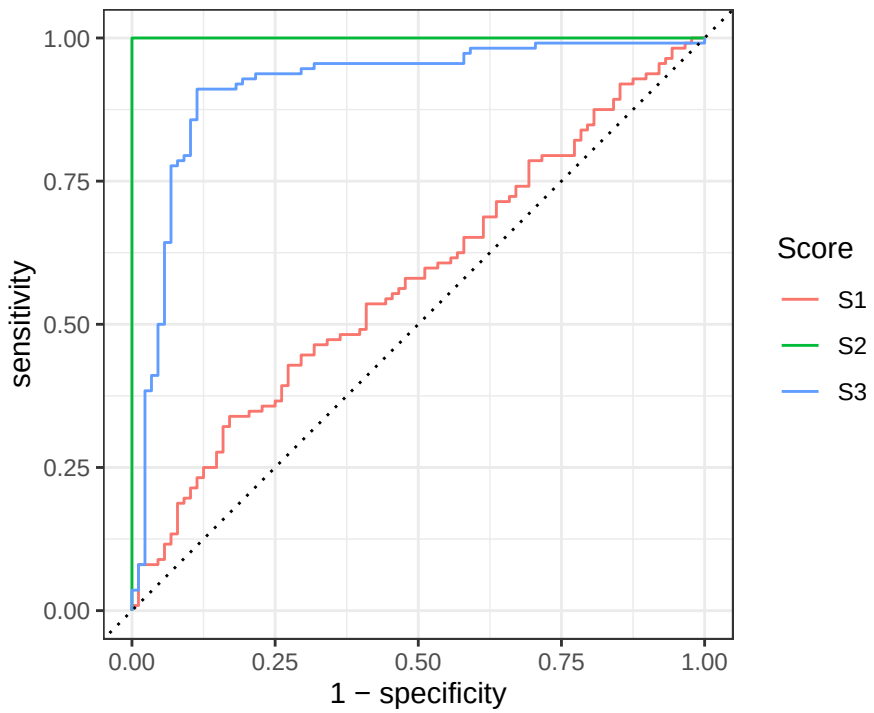

3. Calculer les `AUC` à l'aide de la fonction `aucde` `pROC` puis `roc_auc` de `yardstick`.

```
lapply(roc.obj,auc)
## $S1
## Area under the curve: 0.5785
##
## $S2
## Area under the curve: 1
##
## $S3
## Area under the curve: 0.9148
```

On peut aussi les obtenir avec la syntaxe ***dplyr***

```
tbl |> mutate(Y=as.factor(Y)) |> summarize_at(1:3,~auc(Y,.)) |> round(3)
## # A tibble: 1 x 3
##      S1    S2    S3
##   <dbl> <dbl> <dbl>
## 1 0.579     1 0.915
tbl1 |> mutate(Y=as.factor(Y)) |>  group_by(Score) |>
  summarize(AUC=round(as.numeric(auc(Y,valeurs)),3))
## # A tibble: 3 x 2
##   Score   AUC
```

```
##   <chr> <dbl>
## 1 S1    0.579
## 2 S2    1
## 3 S3    0.915
```

On peut obtenir les mêmes valeurs avec ***roc_auc*** *:*

```
tbl |> pivot_longer(-Y,names_to = "Score",values_to = "valeur") |>
  group_by(Score) |>
  roc_auc(truth=as.factor(Y),valeur,event_level="second")
## # A tibble: 3 x 4
##   Score .metric .estimator .estimate
##   <chr> <chr>   <chr>          <dbl>
## 1 S1    roc_auc binary         0.579
## 2 S2    roc_auc binary         1
## 3 S3    roc_auc binary         0.915
```

4. On rappelle que l'AUC vérifier la propriété suivante : si (X_1, Y_1) et (X_2, Y_2) sont indépendantes et de même loi que (X, Y) et que $S(X)$ est continue, on a

$$AUC(S) = \mathbf{P}(S(X_1) \geq S(X_2)|(Y_1, Y_2) = (1, -1)).$$

Utiliser cette propriété pour retrouver l'AUC de S3.

On peut estimer l'AUC en calculant, parmi les paires qui vérifient $(Y_1, Y_2) = (1, -1)$*, la proportion de paires qui vérifient* $S(X_1) < S(X_2)$*. Si on note*

$$\mathcal{I} = \{(i, j), y_i = 1, y_j = 0\},$$

alors l'estimateur s'écrit

$$\widehat{AUC}(S) = \frac{1}{|\mathcal{I}|} \sum_{(i,j)\in\mathcal{I}} \mathbf{1}_{S(X_i)>S(S_j)}.$$

```
D0 <- which(tbl$Y==0)
D1 <- which(tbl$Y==1)
S30 <- S3[D0]
S31 <- S3[D1]
S3.01 <- expand.grid(S30=S30,S31=S31)
mean(S3.01$S31>S3.01$S30)
## [1] 0.9147727
```

1.3 Exercices complémentaires

Exercice 1.5 (Optimalité de la fonction de régression)**.** Soit (X, Y) un couple aléatoire à valeurs dans $\mathbb{R}^d \times \mathbb{R}$.

1. Rappeler la définition du risque quadratique en régression.

   Il est défini par
   $$\mathcal{R}(m) = \mathbf{E}\big[(Y - m(X))^2\big].$$

2. Montrer que la fonction de régression $m^\star(x) = \mathbf{E}[Y|X = x]$ minimise ce risque.

   Pour toute fonction $m : \mathbb{R}^d \to \mathbb{R}$, on a
   $$\begin{aligned}\mathcal{R}(m) =& \mathbf{E}[(Y - m(X))^2]\\ =& \mathbf{E}[(Y - m^\star(X) + m^\star(X) - m(X))^2]\\ =& \mathbf{E}[(Y - m^\star(X))^2] + \mathbf{E}[(m^\star(X) - m(X))^2]\end{aligned}$$
   car
   $$\begin{aligned}&\mathbf{E}[(m^\star(X) - m(X))(Y - m^\star(X))]\\ &\qquad =\mathbf{E}\left[\mathbf{E}[(m^\star(X) - m(X))(Y - m^\star(X))|X]\right]\\ &\qquad =\mathbf{E}\left[\mathbf{E}[(m^\star(X) - m(X))]\mathbf{E}[Y - m^\star(X)|X]\right]\\ &\qquad =\mathbf{E}\left[\mathbf{E}[(m^\star(X) - m(X))](m^\star(X) - m^\star(X))\right]\\ &\qquad =0.\end{aligned}$$
   On conclut de l'équation 1.1 que le risque est minimal en $m^\star$.

Exercice 1.6 (Optimalité de la règle de Bayes)**.** Soit (X, Y) un couple aléatoire à valeurs dans $\mathbb{R}^d \times \{0, 1\}$.

1. Rappeler la définition d'une fonction de prévision.

   C'est une fonction $g : \mathbb{R}^p \to \{0, 1\}$.

2. Rappeler la définition de la règle de Bayes $g^\star$ et de l'erreur de Bayes $L^\star$.

   La règle de Bayes est définie par
   $$g^\star(x) = \begin{cases} 1 & \text{si } \mathbf{P}(Y = 1|X = x) \geq 0.5 \\ 0 & \text{sinon.}\end{cases}$$
   L'erreur de Bayes est définie par $L^\star = \mathbf{P}(g^\star(X) \neq Y)$.

3. Soit g une fonction de décision. Montrer que pour tout $x \in \mathbb{R}^d$ on a

$$\mathbf{P}(g(X) \neq Y | X = x) = 1 - (\mathbf{1}_{g(x)=1}\eta(x) + \mathbf{1}_{g(x)=0}(1 - \eta(x)))$$

où $\eta(x) = \mathbf{P}(Y = 1|X = x)$.

On a

$$\begin{aligned}\mathbf{P}(g(X) \neq Y|X = x) &= 1 - \Big(\mathbf{P}(g(X) = Y, g(X) = 1|X = x) \\ &\qquad + \mathbf{P}(g(X) = Y, g(X) = 0|X = x)\Big) \\ &= 1 - \Big(\mathbf{1}_{g(x)=1}\mathbf{P}(Y = 1|X = x) \\ &\qquad + \mathbf{1}_{g(x)=0}\mathbf{P}(Y = 0|X = x)\Big) \\ &= 1 - (\mathbf{1}_{g(x)=1}\eta(x) + \mathbf{1}_{g(x)=0}(1 - \eta(x))).\end{aligned}$$

4. En déduire que pour tout $x \in \mathbb{R}^d$ et pour toute fonction de prévision g

$$\mathbf{P}(g(X) \neq Y|X = x) - \mathbf{P}(g^\star(X) \neq Y|X = x) \geq 0.$$

Conclure.

On déduit

$$\begin{aligned}&\mathbf{P}(g(X) \neq Y|X = x) - \mathbf{P}(g^\star(X) \neq Y|X = x) \\ &\quad = \eta(x)\left(\mathbf{1}_{g^\star(x)=1} - \mathbf{1}_{g(x)=1}\right) + (1 - \eta(x))\left(\mathbf{1}_{g^\star(x)=0} - \mathbf{1}_{g(x)=0}\right) \\ &\quad = (2\eta(x) - 1)\left(\mathbf{1}_{g^\star(x)=1} - \mathbf{1}_{g(x)=1}\right) \\ &\quad \geq 0\end{aligned}$$

par définition de $g^\star$. On conclut en intégrant par la loi de X que

$$\mathbf{P}(g(X) \neq Y) \geq \mathbf{P}(g^\star(X) \neq Y).$$

5. On considère (X, Y) un couple aléatoire à valeurs dans $\mathbb{R} \times \{0, 1\}$ tel que

$$X \sim \mathcal{U}[-2, 2] \quad \text{et} \quad (Y|X = x) \sim \begin{cases} \mathcal{B}(1/5) & \text{si } x \leq 0 \\ \mathcal{B}(9/10) & \text{si } x > 0 \end{cases}$$

où $\mathcal{U}[a, b]$ désigne la loi uniforme sur $[a, b]$ et $\mathcal{B}(p)$ la loi de Bernoulli de paramètre p. Calculer la règle de Bayes et l'erreur de Bayes.

Si $x \leq 0$, on a $\mathbf{P}(Y = 1|X = x) = \frac{1}{5}$ et si $x > 0$, $\mathbf{P}(Y = 1|X = x) = \frac{9}{10}$. Ainsi

$$g^\star(x) = \begin{cases} 0 & \text{si } x \leq 0 \\ 1 & \text{si } x > 0. \end{cases}$$

L'erreur de Bayes vaut

$$L^\star = \mathbf{P}(g^\star(X) \neq Y | X \leq 0)\mathbf{P}(X \leq 0) \\ + \mathbf{P}(g^\star(X) \neq Y | X > 0)\mathbf{P}(X > 0).$$

Or

$$\mathbf{P}(g^\star(X) \neq Y | X \leq 0) = \mathbf{P}(Y \neq 0 | X \leq 0) = \frac{1}{5}$$

et

$$\mathbf{P}(g^\star(X) \neq Y | X > 0) = \mathbf{P}(Y \neq 1 | X > 0) = \frac{1}{10}.$$

On obtient

$$L^\star = \frac{1}{5}\frac{1}{2} + \frac{1}{10}\frac{1}{2} = \frac{3}{20}.$$

2 Estimation du risque par ré-échantillonnage

Rappelons que, pour une fonction de perte ℓ donnée, le risque de f_n est défini par

$$\mathcal{R}(f_n) = \mathbf{E}[\ell(Y, f_n(X, \mathcal{D}_n))] = \mathbf{E}_{\mathcal{D}_n}[\mathbf{E}_{(X,Y)}[\ell(Y, f_n(X, \mathcal{D}_n))]].$$

Il représente la perte moyenne de f_n par rapport aux lois de (X, Y) et de $\mathcal{D}_n$. Ces lois étant inconnues, l'utilisateur n'a jamais accès à $\mathcal{R}(f_n)$ et doit donc l'estimer. Nous présentons dans ce chapitre les méthodes classiques qui reposent sur des techniques de ré-échantillonnage.

2.1 Validation croisée

Exercice 2.1 (Calculs de blocs avec rsample)**.** Le package **rsample** permet d'obtenir des partitions des données pour calculer des estimations de risques. On s'intéresse dans cet exercice aux fonctions

- **mc_cv** pour partager les données en 2 (*validation hold out*)
- **vfold_cv** pour partager les données en blocs (*validation croisée*)

On reprend les données générées avec la fonction du chapitre précédent :

```
donnees <- gen_class_bin2D(n=500,graine=12345,bayes=0.20)$donnees
```

1. À l'aide de **mc_cv** séparer les données en 2 échantillons apprentissage/test avec 2/3 des données dans l'échantillon d'apprentissage.

```
library(rsample)
set.seed(12345)
re_ech_ho <- mc_cv(donnees,prop=2/3,times = 1)
re_ech_ho
## # Monte Carlo cross-validation (0.67/0.33) with 1 resamples
## # A tibble: 1 x 2
##   splits            id
##   <list>            <chr>
```

```
## 1 <split [333/167]> Resample1
```

2. Afficher l'index des individus de l'échantillon d'apprentissage. Faire de même pour l'échantillon test.

```
ind_app <- re_ech_ho$splits[[1]]$in_id
head(ind_app)
## [1] 142  51 208 218 220 152
length(ind_app)
## [1] 333
```

```
ind_test <- c(1:500)[-re_ech_ho$splits[[1]]$in_id]
head(ind_test)
## [1]  1  4 11 20 22 26
length(ind_test)
## [1] 167
```

3. À l'aide de **vfold_cv** séparer les données en 10 blocs.

```
set.seed(12345)
(re_ech_cv <- vfold_cv(donnees,v=10))
## #  10-fold cross-validation
## # A tibble: 10 x 2
##    splits           id
##    <list>           <chr>
##  1 <split [450/50]> Fold01
##  2 <split [450/50]> Fold02
##  3 <split [450/50]> Fold03
##  4 <split [450/50]> Fold04
##  5 <split [450/50]> Fold05
##  6 <split [450/50]> Fold06
##  7 <split [450/50]> Fold07
##  8 <split [450/50]> Fold08
##  9 <split [450/50]> Fold09
## 10 <split [450/50]> Fold10
```

4. Afficher l'index des individus qui se trouvent dans le bloc 4.

```
bloc4 <- re_ech_cv$splits[[4]]$in_id
head(bloc4)
## [1] 1 2 3 4 5 6
length(bloc4)
## [1] 450
```

On considère la perte indicatrice : $\ell(y, y') = \mathbf{1}_{y \neq y'}$, le risque d'un algorithme f est donc

$$\mathcal{R}(f) = \mathbf{E}[\mathbf{1}_{Y \neq f(X)}] = \mathbf{P}(Y \neq f(X)),$$

il est appelé **probabilité d'erreur** ou **erreur de classification**. On s'intéresse à l'estimation de ce risque par des méthodes de ré-échantillonnage pour l'algorithme des k plus proches voisins.

Exercice 2.2 (Progammation de validation hold out et validation croisée)**.**

1. Créer une fonction qui admet en entrée

   - un jeu de données
   - une valeur de `k`
   - une séparation des données en apprentissage/test issue de `mc_cv`

   et renvoie en sortie l'erreur de classification de la règle des k plus proches voisins calculées sur l'échantillon test. On pourra la tester pour `k=3`.

```
library(kknn)
hold.out.kppv <-  function(donnees,re_ech,k=3){
  index.app <- re_ech$splits[[1]]$in_id
  dapp <- donnees[index.app,]
  dtest <- donnees[-index.app,]
  prev <- kknn(Y~.,train=dapp,test=dtest,k=k,
               kernel="rectangular")$fitted.values
  return(mean(prev!=dtest$Y))
}
hold.out.kppv(donnees,re_ech_ho,k=3)
## [1] 0.4491018
```

2. Refaire la question précédente avec une validation croisée K blocs.

```
cv.kppv <- function(donnees,re_ech,k=3){
  K <- length(re_ech$splits)
  err.bloc <- rep(0,K)
  for (j in 1:K){
    ind.app <- re_ech$splits[[j]]$in_id
    dapp <- donnees[ind.app,]
    dtest <- donnees[-ind.app,]
    prev.j <- kknn(Y~.,train=dapp,test=dtest,k=k,
                   kernel="rectangular")$fitted.values
    err.bloc[j] <- mean(prev.j!=donnees$Y[-ind.app])
  }
```

```
  return(mean(err.bloc))
}
cv.kppv(donnees,re_ech_cv,k=3)
## [1] 0.328
```

3. On considère la grille de valeurs de `k`

```
grille.k <- c(1:100)
```

Sélectionner dans cette grille une valeur de k en minimisant l'erreur de classification calculée par validation hold out, puis par validation croisée 10 blocs. On pourra également visualiser les courbes de risque (erreur de classification en fonction du nombre de voisins).

```
mat.err <- matrix(0,nrow=length(grille.k),ncol=2) |> as_tibble()
names(mat.err) <- c("hold.out","cv.10blocs")
compt <- 1
for (k in grille.k){
  mat.err[compt,1] <- hold.out.kppv(donnees,re_ech_ho,k=k)
  mat.err[compt,2] <- cv.kppv(donnees,re_ech_cv,k=k)
  compt <- compt+1
}
```

```
mat.err1 <- mat.err |> mutate(k=grille.k) |>
  pivot_longer(-k,names_to="Methode",values_to="Erreur")
ggplot(mat.err1)+aes(x=k,y=Erreur,color=Methode)+geom_line()
```

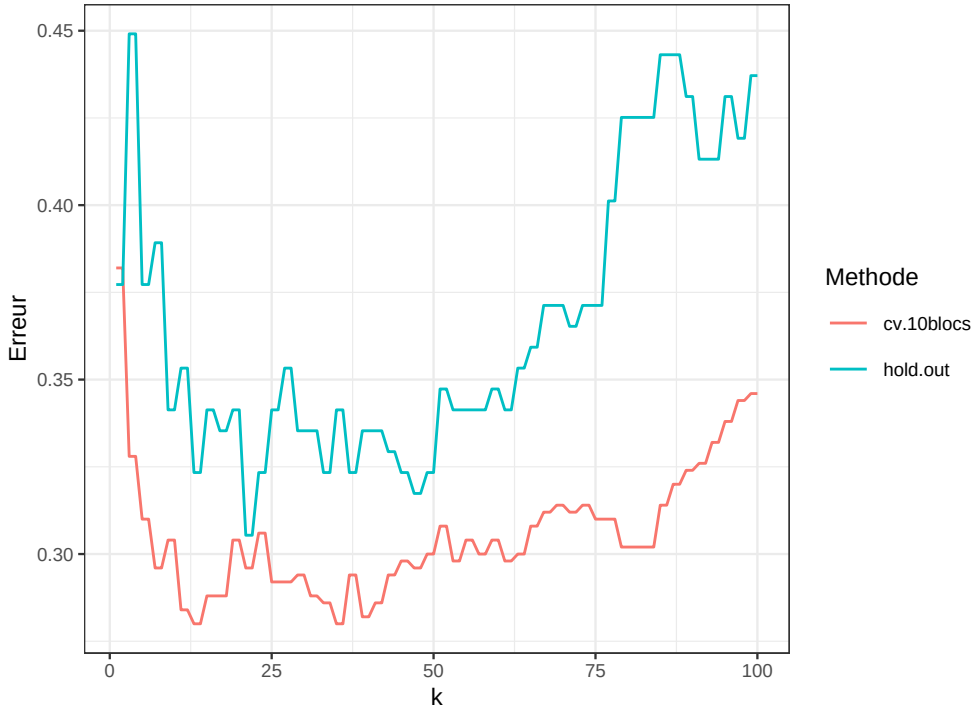


```
mat.err1 |> group_by(Methode) |> slice(which.min(Erreur))
## # A tibble: 2 x 3
## # Groups:   Methode [2]
##       k Methode    Erreur
##   <int> <chr>       <dbl>
## 1    13 cv.10blocs  0.28
## 2    21 hold.out    0.305
```

2.2 Le package tidymodels

Il s'agit d'un meta-package qui regroupe plusieurs packages (`parsnip`, `recipes`, `rsample`...) qui utilisent une approche *tidy* pour **sélectionner un algorithme de prévision**. Il propose de créer un projet de travail, appelé **workflow**, permettant de construire un algorithme de prévision. Cette construction requiert tout un ensemble d'étapes comme la gestion des données manquantes, la création ou suppression de variables explicatives, la recherche de colinéarité parmi les variables explicatives, la sélection des paramètres de l'algorithme... Toutes ces étapes s'enchaînent en mettant à jour le workflow. Nous ne présentons pas toutes les fonctionnalités de `tidymodels`, on pourra les retrouver dans le tutoriel présentant le package à l'url https://www.tidymodels.org. Nous nous concentrons uniquement sur le choix de paramètres d'algorithmes de prévision à travers l'exemple des plus proches voisins.

La première étape est consacrée à la définition de l'algorithme. Pour des plus proches voisins en classification on utilise

```
library(tidymodels)
tune_spec <-
  nearest_neighbor(neighbors=tune(),weight_func="rectangular") |>
  set_mode("classification") |>
  set_engine("kknn")
```

Dans la fonction `nearest_neighbor` nous précisions que nous souhaitons utiliser le noyau `rectangular` comme nous l'avons fait jusqu'à présent. L'option `neighbors=tune()` spécifie que le nombre de plus proches voisins est un paramètre à calibrer. Plusieurs packages `R` permettent d'entraîner des k plus proches voisins, on utilise `set_engine("kknn")` pour indiquer que l'on souhaite utiliser la fonction `kknn`. On pourra trouver l'ensemble des algorithmes disponibles dans `tidymodels` ainsi que les noms de leurs paramètres ici : https://www.tidymodels.org/find/parsnip/.

On initialise le projet de travail dans la seconde étape en créant le *workflow* :

```
ppv_wf <- workflow() |>
  add_model(tune_spec) |>
  add_formula(Y ~ .)
```

On renseigne dans `add_model` les différentes informations sur l'algorithme des plus proches voisins et on indique dans `add_formula` la variable à expliquer et les variables explicatives. Nous avons vu dans la section précédente que la recherche du meilleur nombre de voisins s'effectue en estimant un risque de prévision sur une grille de valeurs candidates. On considère toujours des valeurs de k variant entre 1 et 100 :

```
grille_k <- tibble(neighbors=1:100)
```

Le choix de k s'effectue avec la fonction `tune_grid` du package `tune` qui possède notamment les arguments suivants :

```
tune_grid(...,resamples=...,grid=...,metrics=...)
```

On indique dans :

- `resamples` le ré-échantillonnage. Par exemple les échantillons d'apprentissage et test pour la validation hold out (avec la fonction `mc_cv`), les blocs pour la validation croisée (`vfolds_cv`), les tirages bootstraps (`bootstraps`) ;
- `grid` la grille de paramètres candidats ;
- `metrics` le risque de prévision (erreur quadratique, erreur de classification, AUC...).

Exercice 2.3 (Validation hold out et validation croisée avec tidymodels)**.**

1. Retrouver les erreurs par validation hold out en utilisant `tune_grid` et `collect_metrics`.

```
ppv.ho <- ppv_wf |>
  tune_grid(
    resamples = re_ech_ho,
    grid = grille_k,
    metrics=metric_set(accuracy))
ppv.ho |> collect_metrics()
## # A tibble: 100 x 7
##    neighbors .metric  .estimator  mean     n std_err .config
##        <int> <chr>    <chr>      <dbl> <int>   <dbl> <chr>
##  1         1 accuracy binary     0.623     1      NA Prepro~
##  2         2 accuracy binary     0.623     1      NA Prepro~
##  3         3 accuracy binary     0.551     1      NA Prepro~
##  4         4 accuracy binary     0.551     1      NA Prepro~
##  5         5 accuracy binary     0.623     1      NA Prepro~
##  6         6 accuracy binary     0.623     1      NA Prepro~
##  7         7 accuracy binary     0.611     1      NA Prepro~
##  8         8 accuracy binary     0.611     1      NA Prepro~
##  9         9 accuracy binary     0.659     1      NA Prepro~
## 10        10 accuracy binary     0.659     1      NA Prepro~
## # ... with 90 more rows
```

2. Visualiser les meilleures valeurs de `k` à l'aide de `show_best`

```
ppv.ho |> show_best() |> dplyr::select(1:6)
## # A tibble: 5 x 6
##   neighbors .metric  .estimator  mean     n std_err
##       <int> <chr>    <chr>      <dbl> <int>   <dbl>
## 1        21 accuracy binary     0.695     1      NA
## 2        22 accuracy binary     0.695     1      NA
## 3        47 accuracy binary     0.683     1      NA
## 4        48 accuracy binary     0.683     1      NA
## 5        13 accuracy binary     0.677     1      NA
```

3. Sélectionner la meilleur valeur de `k` avec `select_best`.

```
(best_k <- ppv.ho |> select_best())
## # A tibble: 1 x 2
##   neighbors .config
##       <int> <chr>
```

```
## 1        21 Preprocessor1_Model021
```

4. Finaliser l'algorithme à l'aide de `finalize_workflow` et `fit`.

```
(final_ppv <-
  ppv_wf |>
  finalize_workflow(best_k) |>
  fit(data = donnees))
## == Workflow [trained] ======================================
## Preprocessor: Formula
## Model: nearest_neighbor()
##
## -- Preprocessor ------------------------------------------
## Y ~ .
##
## -- Model -------------------------------------------------
##
## Call:
## kknn::train.kknn(formula = ..y ~ ., data = data, ks = min_rows(21L,     data, 5), kernel =
##
## Type of response variable: nominal
## Minimal misclassification: 0.294
## Best kernel: rectangular
## Best k: 21
```

5. Faire le même travail pour la validation croisée 10 blocs.

```
ppv.cv <- ppv_wf |>
  tune_grid(
    resamples = re_ech_cv,
    grid = grille_k,
    metrics=metric_set(accuracy))
ppv.cv |> collect_metrics()
## # A tibble: 100 x 7
##    neighbors .metric  .estimator  mean     n std_err .config
##        <int> <chr>    <chr>      <dbl> <int>   <dbl> <chr>
##  1         1 accuracy binary     0.618    10  0.0247 Prepro~
##  2         2 accuracy binary     0.618    10  0.0247 Prepro~
##  3         3 accuracy binary     0.672    10  0.0215 Prepro~
##  4         4 accuracy binary     0.672    10  0.0215 Prepro~
##  5         5 accuracy binary     0.69     10  0.0209 Prepro~
##  6         6 accuracy binary     0.69     10  0.0209 Prepro~
##  7         7 accuracy binary     0.704    10  0.0176 Prepro~
##  8         8 accuracy binary     0.704    10  0.0176 Prepro~
##  9         9 accuracy binary     0.696    10  0.0242 Prepro~
## 10        10 accuracy binary     0.696    10  0.0242 Prepro~
```

```
## # ... with 90 more rows
```

```
(best_k <- ppv.cv |> select_best())
## # A tibble: 1 x 2
##   neighbors .config
##       <int> <chr>
## 1        13 Preprocessor1_Model013
```

Exercice 2.4 (Validation croisée pour l'AUC)**.** Sélectionner la valeur de k qui maximise l'AUC calculé par validation croisée 10 blocs.

```
ppv.auc.cv <- ppv_wf |>
  tune_grid(
    resamples = re_ech_cv,
    grid = grille_k,
    control=control_resamples(save_pred = TRUE),
    metrics=metric_set(roc_auc))
ppv.auc.cv |> collect_metrics()
## # A tibble: 100 x 7
##    neighbors .metric .estimator  mean     n std_err .config
##        <int> <chr>   <chr>      <dbl> <int>   <dbl> <chr>
##  1         1 roc_auc binary     0.619    10  0.0241 Preproc~
##  2         2 roc_auc binary     0.658    10  0.0172 Preproc~
##  3         3 roc_auc binary     0.698    10  0.0226 Preproc~
##  4         4 roc_auc binary     0.709    10  0.0217 Preproc~
##  5         5 roc_auc binary     0.734    10  0.0209 Preproc~
##  6         6 roc_auc binary     0.740    10  0.0200 Preproc~
##  7         7 roc_auc binary     0.744    10  0.0209 Preproc~
##  8         8 roc_auc binary     0.749    10  0.0225 Preproc~
##  9         9 roc_auc binary     0.755    10  0.0217 Preproc~
## 10        10 roc_auc binary     0.752    10  0.0221 Preproc~
## # ... with 90 more rows
```

```
(best_k_auc <- ppv.auc.cv |> select_best())
## # A tibble: 1 x 2
##   neighbors .config
##       <int> <chr>
## 1        12 Preprocessor1_Model012
```

```
(score <- collect_predictions(ppv.auc.cv))
## # A tibble: 50,000 x 7
##    id     .pred_0 .pred_1  .row neighbors Y     .config
```

```
##    <chr>    <dbl>   <dbl> <int>     <int> <fct> <chr>
##  1 Fold01       1       0     2         1 1     Preprocesso~
##  2 Fold01       0       1    33         1 0     Preprocesso~
##  3 Fold01       1       0    44         1 0     Preprocesso~
##  4 Fold01       1       0    52         1 1     Preprocesso~
##  5 Fold01       0       1    68         1 1     Preprocesso~
##  6 Fold01       0       1    79         1 1     Preprocesso~
##  7 Fold01       0       1    81         1 0     Preprocesso~
##  8 Fold01       1       0    98         1 0     Preprocesso~
##  9 Fold01       1       0   102         1 0     Preprocesso~
## 10 Fold01       1       0   127         1 0     Preprocesso~
## # ... with 49,990 more rows
score |> filter(neighbors==best_k_auc$neighbors) |>
 roc_curve(Y, .pred_1,event_level="second") |>
 autoplot()
```

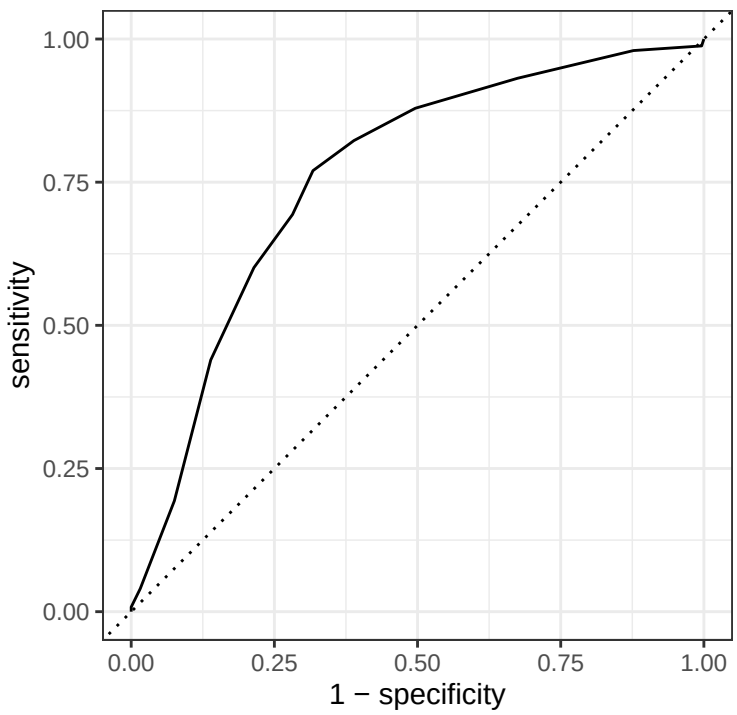

3 Compléments

3.1 Variance de l'erreur de validation croisée

Lorsque les estimateurs du risque sont obtenus en ajustant l'algorithme plusieurs fois (sur différent sous-échantillons), il est possible d'estimer la variance (conditionnelle aux données) de ces estimateurs. Par exemple, dans le cas d'une validation croisée K blocs pour le risque quadratique en régression, cette variance est approchée par

$$\frac{1}{K}\frac{1}{K-1}\sum_{k=1}^{K}(\mathcal{R}_k - \mathcal{R}_{\mathrm{CV}})^2$$

où $\mathcal{R}_k$ représente l'erreur sur le bloc k et $\mathcal{R}_{\mathrm{CV}}$ est l'erreur de validation croisée. L'estimation de cette variance est très importante puisqu'elle permet d'avoir une idée sur les erreurs obtenues. Elle peut donc aider l'utilisateur à calibrer les algorithmes.

Exercice 3.1 (Variance de l'estimateur du risque)**.** On reprend les données générées avec la fonction des chapitres précédents :

```
donnees <- gen_class_bin2D(n=500,graine=12345,bayes=0.20)$donnees
```

et on considère les estimateurs du risque obtenus avec la validation croisée suivants :

```
set.seed(12345)
tune_spec <-
  nearest_neighbor(neighbors=tune(),weight_func="rectangular") |>
  set_mode("classification") |>
  set_engine("kknn")
ppv_wf <- workflow() |>
  add_model(tune_spec) |>
  add_formula(Y ~ .)

grille_k <- tibble(neighbors=1:100)
re_ech_cv <- vfold_cv(donnees,v=10)

ppv.cv <- ppv_wf |>
```

```
  tune_grid(
    resamples = re_ech_cv,
    grid = grille_k,
    metrics=metric_set(accuracy))
```

On visualise la courbe de risque avec

```
tbl <- ppv.cv |> collect_metrics()
ggplot(tbl)+aes(x=neighbors,y=mean)+geom_line()+ylab("Accuracy")
```

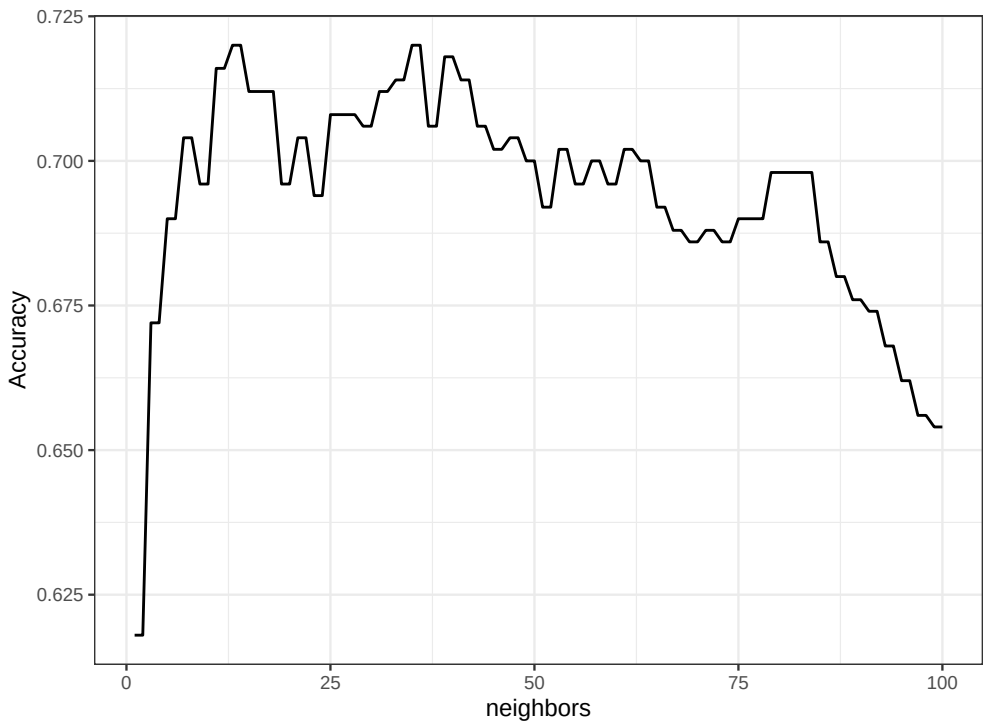


```
ppv.cv |> collect_metrics()
## # A tibble: 100 x 7
##    neighbors .metric  .estimator  mean     n std_err .config
##        <int> <chr>    <chr>      <dbl> <int>   <dbl> <chr>
##  1         1 accuracy binary     0.618    10  0.0247 Prepro~
##  2         2 accuracy binary     0.618    10  0.0247 Prepro~
##  3         3 accuracy binary     0.672    10  0.0215 Prepro~
##  4         4 accuracy binary     0.672    10  0.0215 Prepro~
##  5         5 accuracy binary     0.69     10  0.0209 Prepro~
##  6         6 accuracy binary     0.69     10  0.0209 Prepro~
##  7         7 accuracy binary     0.704    10  0.0176 Prepro~
```

```
## 8          8 accuracy binary     0.704    10  0.0176 Prepro~
## 9          9 accuracy binary     0.696    10  0.0242 Prepro~
## 10        10 accuracy binary     0.696    10  0.0242 Prepro~
## # ... with 90 more rows
```

1. Expliquer à quoi correspond la colonne `std_err` du tibble `tbl`.
2. Expliquer la sortie de

```
(k_one_std_err <- ppv.cv |> select_by_one_std_err(desc(neighbors)))
## # A tibble: 1 x 9
##   neighb~1 .metric .esti~2  mean     n std_err .config .best
##      <int> <chr>   <chr>   <dbl> <int>   <dbl> <chr>   <dbl>
## 1       84 accura~ binary  0.698    10  0.0241 Prepro~  0.72
## # ... with 1 more variable: .bound <dbl>, and abbreviated
## #   variable names 1: neighbors, 2: .estimator
```

3. Visualiser les écart-types estimés sur la courbe de risque ainsi que la valeur de k optimale et celle de la question précédente. On pourra par exemple tracer le graphe suivant :

```
ggplot(tbl)+aes(x=neighbors,y=mean,ymin=mean-std_err,ymax=mean+std_err)+
  geom_pointrange(linewidth=0.2,size=0.2)+
  geom_vline(aes(xintercept=which.max(mean)),linetype="dotted")+
  geom_vline(data=k_one_std_err,aes(xintercept=neighbors),linetype="dotted")+
  geom_hline(data=k_one_std_err,aes(yintercept=.bound),linetype="dashed")+
  ylab("accuracy")
```

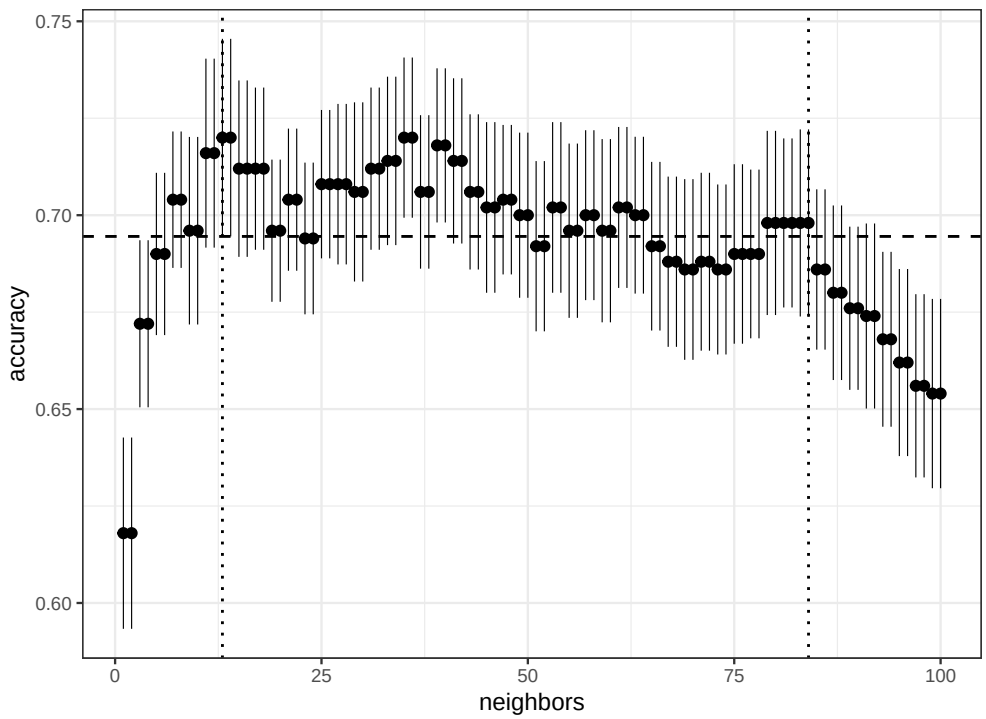

3.2 Répéter les méthodes de ré-échantillonnage

Les méthodes d'estimation du risque présentées dans cette partie (hold out, validation croisée) sont basées sur du **ré-échantillonnage**. Elles peuvent se révéler sensible à la manière de couper l'échantillon. C'est pourquoi il est recommandé de les **répéter plusieurs fois** et de moyenner les erreurs sur les répétitions. Ces répétitions sont très faciles à mettre en œuvre avec l'approche `tidymodels`, il suffit de construire les échantillons adéquat. Par exemple,

- pour répéter 20 fois une validation hold out, on définit les blocs avec

```
ho_rep <- mc_cv(donnees,prop=2/3,times = 20)
```

- pour la validation croisée, on utilise

```
cv_rep <- vfold_cv(donnees, v = 10, repeats = 20)
```

Le reste ne change pas, il faudra utiliser ces objets dans l'option `resamples` de `tune_grid`.

Exercice 3.2 (Validation croisée répétée)**.** Refaire l'Exercice 3.1 avec une validation croisée répétée 20 fois. On comparera notamment la variance des estimateurs obtenus.

```
cv_rep <- vfold_cv(donnees, v = 10, repeats = 20)
ppv.cv.rep <- ppv_wf |>
  tune_grid(
    resamples = cv_rep,
    grid = grille_k,
    metrics=metric_set(accuracy))
```

```
tbl <- ppv.cv.rep |> collect_metrics()
k_one_std_err <- ppv.cv.rep |> select_by_one_std_err(desc(neighbors))
ggplot(tbl)+aes(x=neighbors,y=mean,ymin=mean-std_err,ymax=mean+std_err)+
  geom_pointrange(linewidth=0.2,size=0.2)+
  geom_vline(aes(xintercept=which.max(mean)),linetype="dotted")+
  geom_vline(data=k_one_std_err,aes(xintercept=neighbors),linetype="dotted")+
  geom_hline(data=k_one_std_err,aes(yintercept=.bound),linetype="dashed")+
  ylab("accuracy")
```

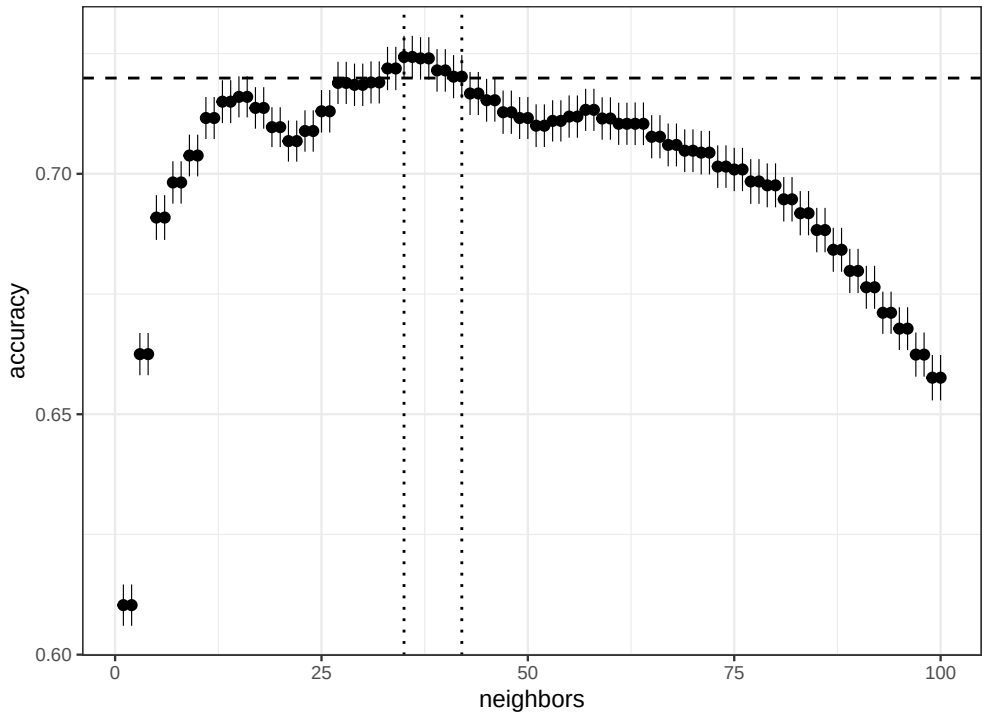

3.3 Calcul parallèle

Les validations croisées (répétées) peuvent se révéler coûteuses en temps de calcul. On utilise souvent des techniques de parallélisation pour améliorer les performances computationnelles. Ces techniques sont relativement facile à mettre en œuvre avec `tunegrid`, on peut par exemple utiliser la librairie **doParallel** pour utiliser plusieurs cœurs de la machine. À titre d'illustration, nous comparons ci-dessous les temps de calcul pour faire une validation croisée répétée 20 fois. On commence sans calcul parallèle

```
grille_k1 <- tibble(neighbors=c(1,11,21,31))
t1 <- system.time(
  ppv_wf |> tune_grid(
  resamples = cv_rep,
  grid = grille_k1))
```

```
t1
##    user  system elapsed
## 146.115   5.331 152.338
```

Pour paralléliser on regarde tout d'abord la nombre de cœurs disponibles sur la machine

```
library(doParallel)
detectCores()
## [1] 4
```

On ouvre les connexions sur chaque cœur

```
cl <- makePSOCKcluster(4)
registerDoParallel(cl)
```

et on lance la validation croisée, elle sera automatiquement parallélisée

```
t2 <- system.time(
  ppv_wf |> tune_grid(
  resamples = cv_rep,
  grid = grille_k1))
```

```
t2
##    user  system elapsed
##   0.490   0.094  32.988
```

Le temps de calcul a bien été diminué. Enfin on n'oublie pas de refermer les connexions

```r
stopCluster(cl)
```

partie II

Arbres

4 Méthodes CART

Les méthodes par arbres sont des algorithmes où la prévision s'effectue à partir de **moyennes locales**. Plus précisément, étant donné un échantillon $(x_1, y_1) \ldots, (x_n, y_n)$, l'approche consiste à :

- construire une partition de l'espace de variables explicatives ($\mathbb{R}^p$) ;
- prédire la sortie d'une nouvelle observation x en faisant :
  - la moyenne des y_i pour les x_i qui sont dans la même classe que x si on est en régression ;
  - un vote à la majorité parmi les y_i tels que les x_i qui sont dans la même classe que x si on est en classification.

Bien entendu toute la difficulté est de trouver la "bonne partition" pour le problème d'intérêt. Il existe un grand nombre d'algorithmes qui permettent de trouver une partition. Le plus connu est l'algorithme **CART** (Breiman et al. 1984) où la partition est construite par **divisions successives** au moyen d'hyperplan orthogonaux aux axes de $\mathbb{R}^p$. L'algorithme est récursif : il va à chaque étape séparer un groupe d'observations (**nœuds**) en deux groupes (**nœuds fils**) en cherchant la meilleure variable et le meilleur seuil de coupure. Ce choix s'effectue à partir d'un critère **d'impureté** : la meilleure coupure est celle pour laquelle l'impureté des 2 nœuds fils sera minimale. Nous étudions cet algorithme dans cette partie.

4.1 Coupures CART en fonction de la nature des variables

Une partition CART s'obtient en séparant les observations en 2 selon une coupure parallèle aux axes puis en itérant ce procédé de séparation binaire sur les deux groupes... Par conséquent la première question à se poser est : pour un ensemble de données $(x_1, y_1), \ldots, (x_n, y_n)$ fixé, comment obtenir la meilleure coupure ?

Comme souvent ce sont les données qui vont répondre à cette question. La sélection de la meilleur coupure s'effectue en introduisant une **fonction d'impureté** $\mathcal{I}$ qui va mesurer le degrés d'hétérogénéité d'un nœud $\mathcal{N}$. Cette fonction prendra de

- grandes valeurs pour les nœuds hétérogènes (les valeurs de Y diffèrent à l'intérieur du nœud) ;

- faibles valeurs pour les nœuds homogènes (les valeurs de Y sont proches à l'intérieur du nœud).

On utilise souvent comme fonction d'impureté :

- la **variance** en régression

$$\mathcal{I}(\mathcal{N}) = \frac{1}{|\mathcal{N}|} \sum_{i:x_i \in \mathcal{N}} (y_i - \overline{y}_{\mathcal{N}})^2,$$

  où $\overline{y}_{\mathcal{N}}$ désigne la moyenne des y_i dans $\mathcal{N}$.

- l'impureté de **Gini** en classification binaire

$$\mathcal{I}(\mathcal{N}) = 2p(\mathcal{N})(1 - p(\mathcal{N}))$$

  où $p(\mathcal{N})$ représente la proportion de 1 dans $\mathcal{N}$.

Les coupures considérées par l'algorithme CART sont des hyperplans orthogonaux aux axes de $\mathbb{R}^p$, choisir une coupure revient donc à choisir une variable j parmi les p variables explicatives et un seuil s dans $\mathbb{R}$. On peut donc représenter une coupure par un couple (j, s). Une fois l'impureté définie, on choisira la coupure (j, s) qui **maximise le gain d'impureté** entre le noeud père et ses deux noeuds fils :

$$\Delta(\mathcal{I}) = \mathbf{P}(\mathcal{N})\mathcal{I}(\mathcal{N}) - (\mathbf{P}(\mathcal{N}_1(j,s))\mathcal{I}(\mathcal{N}_1(j,s)) + \mathbf{P}(\mathcal{N}_2(j,s))\mathcal{I}(\mathcal{N}_2(j,s))$$

où

- $\mathcal{N}_1(j, s)$ et $\mathcal{N}_2(j, s)$ sont les 2 nœuds fils de $\mathcal{N}$ engendrés par la coupure (j, s) ;
- $\mathbf{P}(\mathcal{N})$ représente la proportion d'observations dans le nœud $\mathcal{N}$.

4.1.1 Arbres de régression

On considère le jeu de données suivant où le problème est d'expliquer la variable quantitative Y par la variable quantitative X.

```
n <- 50
set.seed(1234)
X <- runif(n)
set.seed(5678)
Y <- 1*X*(X<=0.6)+(-1*X+3.2)*(X>0.6)+rnorm(n,sd=0.1)
data1 <- data.frame(X,Y)
ggplot(data1)+aes(x=X,y=Y)+geom_point()
```

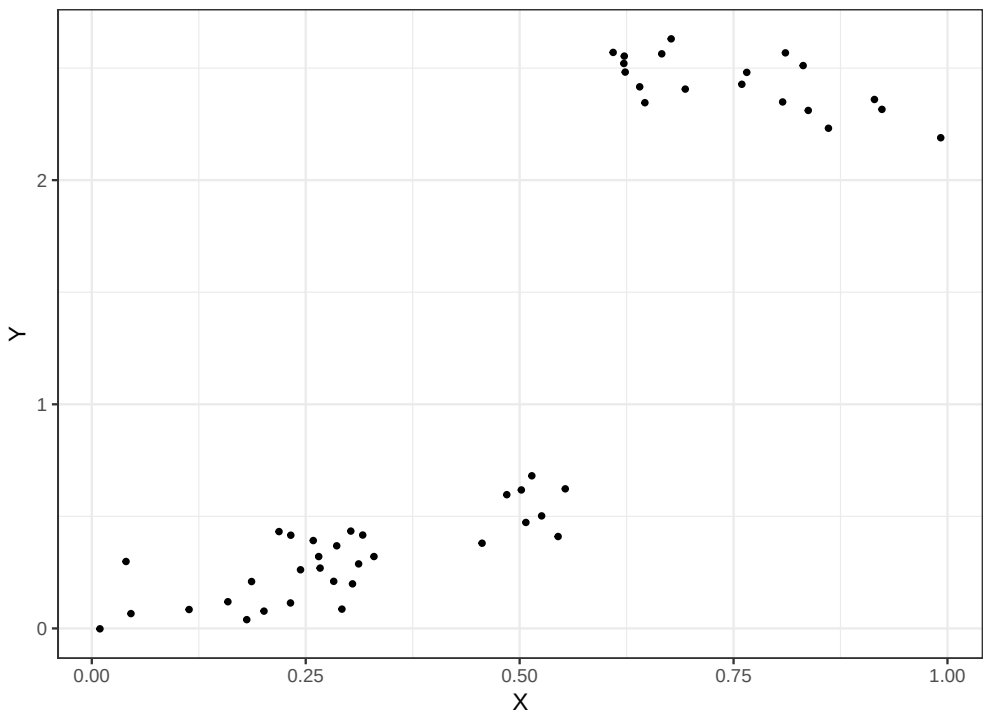

1. A l'aide de la fonction **rpart** du package **rpart**, construire un arbre permettant d'expliquer Y par X.

```
library(rpart)
```

```
tree <- rpart(Y~X,data=data1)
```

2. Visualiser l'arbre à l'aide des fonctions **prp** et **rpart.plot** du package **rpart.plot**.

```
library(rpart.plot)
```

```
prp(tree)
```

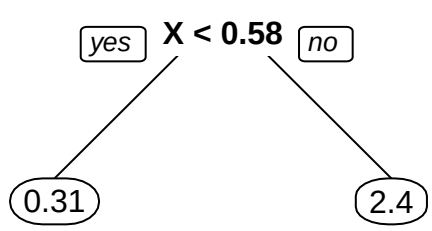

```r
rpart.plot(tree)
```

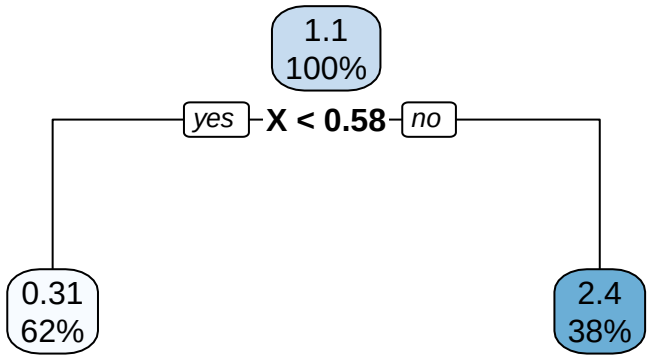

3. Écrire l'estimateur associé à l'arbre.
4. Ajouter sur le graphe de la question 1 la partition définie par l'arbre ainsi que les valeurs prédites.

```r
df1 <- data.frame(x=c(0,0.58),xend=c(0.58,1),
                  y=c(0.31,2.41),yend=c(0.31,2.41))
ggplot(data1)+aes(x=X,y=Y)+geom_point()+
  geom_vline(xintercept = 0.58,size=1,color="blue")+
  geom_segment(data=df1,aes(x=x,y=y,xend=xend,yend=yend),
               size=1,color="red")
```

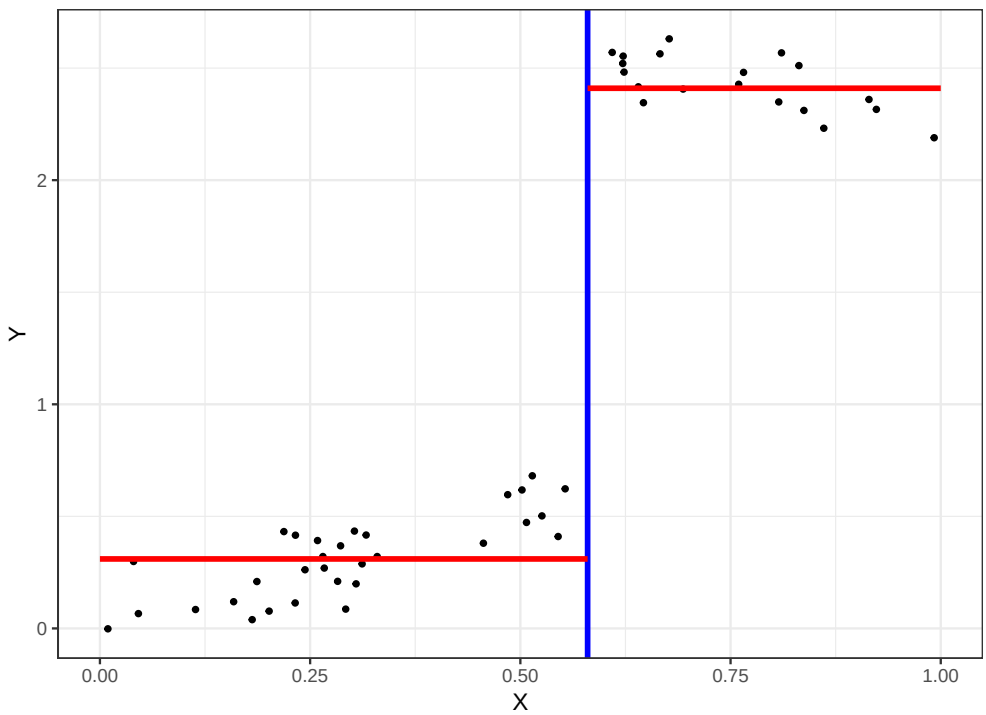

4.1.2 Arbres de classification

On considère les données suivantes où le problème est d'expliquer la variable binaire Y par deux variables quantitatives X_1 et X_2.

```
n <- 50
set.seed(12345)
X1 <- runif(n)
set.seed(5678)
X2 <- runif(n)
Y <- rep(0,n)
set.seed(54321)
Y[X1<=0.45] <- rbinom(sum(X1<=0.45),1,0.85)
set.seed(52432)
Y[X1>0.45] <- rbinom(sum(X1>0.45),1,0.15)
data2 <- data.frame(X1,X2,Y)
ggplot(data2)+aes(x=X1,y=X2,color=Y)+geom_point(size=2)+
  scale_x_continuous(name="")+
  scale_y_continuous(name="")
```

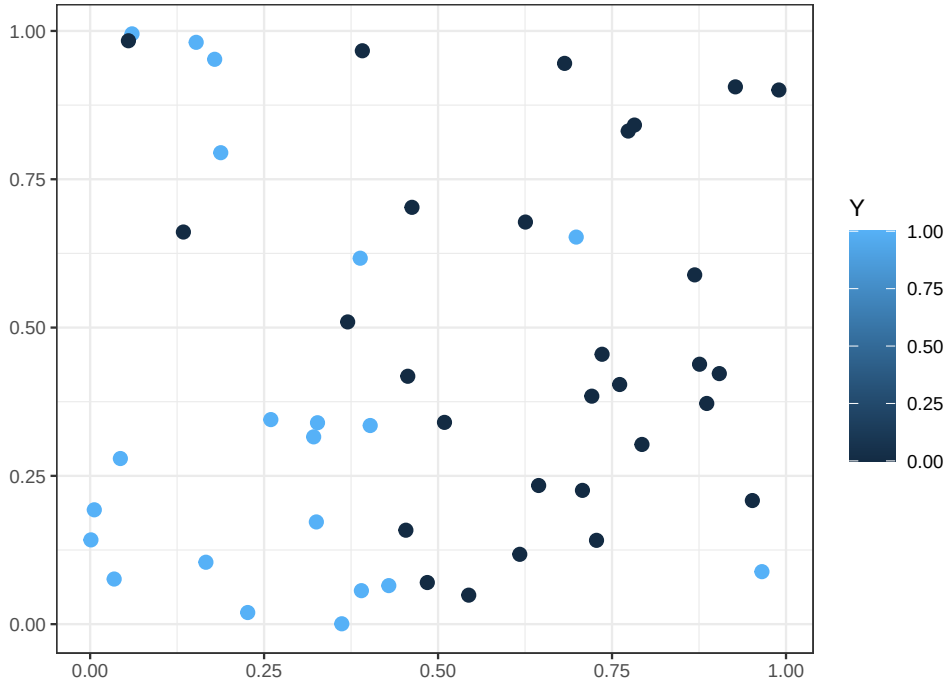

1. Construire un arbre permettant d'expliquer Y par X_1 et X_2. Représenter l'arbre et identifier l'éventuel problème.

```
tree <- rpart(Y~.,data=data2)
rpart.plot(tree)
```

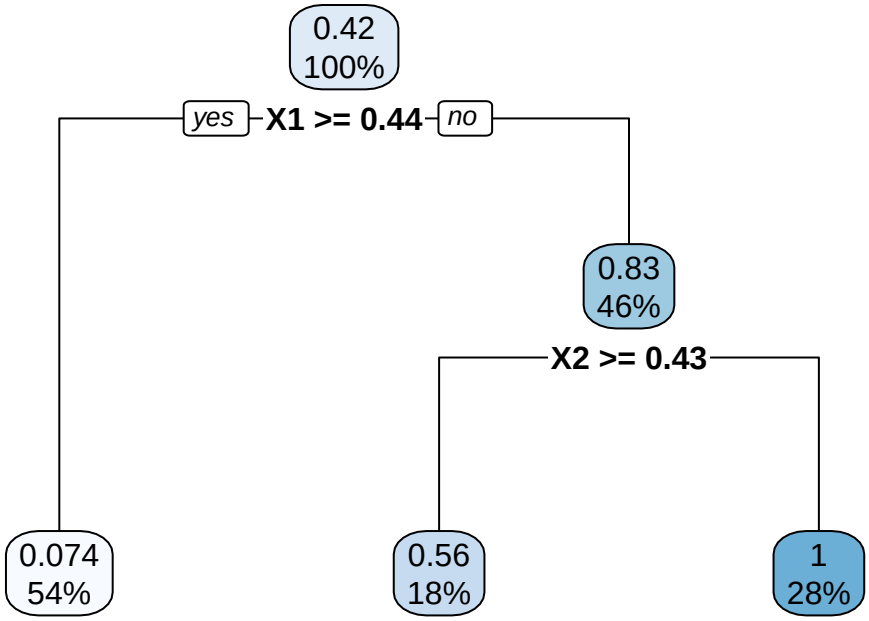


```
data2$Y <- as.factor(data2$Y)
tree <- rpart(Y~.,data=data2)
rpart.plot(tree)
```

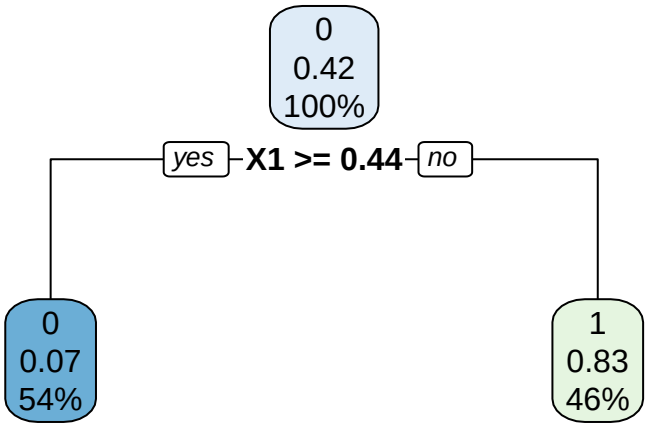

2. Écrire la règle de classification ainsi que la fonction de score définies par l'arbre.
3. Ajouter sur le graphe de la question 1 la partition définie par l'arbre.

```
ggplot(data2)+aes(x=X1,y=X2,color=Y,shape=Y)+geom_point(size=2)+
  geom_vline(xintercept = 0.44,size=1,color="blue")
```

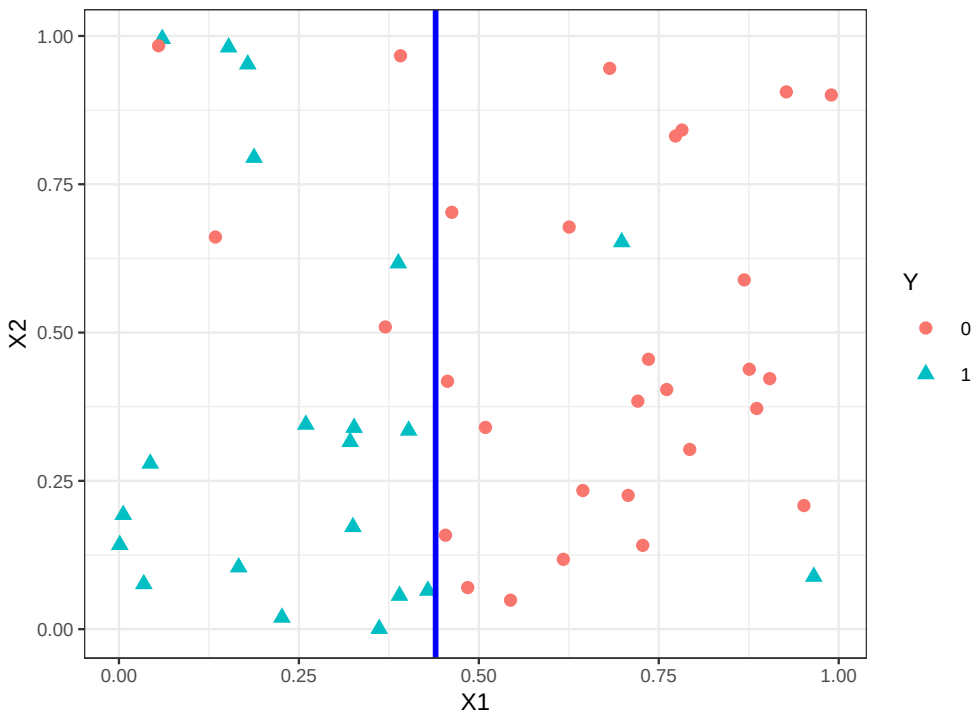

4.1.3 Entrée qualitative

On considère les données

```
n <- 100
X <- factor(rep(c("A","B","C","D"),n))
set.seed(1234)
Y[X=="A"] <- rbinom(sum(X=="A"),1,0.9)
Y[X=="B"] <- rbinom(sum(X=="B"),1,0.25)
Y[X=="C"] <- rbinom(sum(X=="C"),1,0.8)
Y[X=="D"] <- rbinom(sum(X=="D"),1,0.2)
Y <- as.factor(Y)
data3 <- data.frame(X,Y)
```

1. Construire un arbre permettant d'expliquer Y par X.

```
tree3 <- rpart(Y~.,data=data3)
rpart.plot(tree3)
```

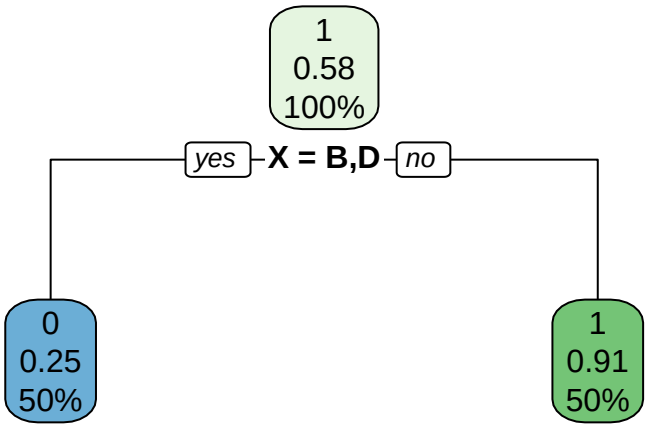

2. Expliquer la manière dont l'arbre est construit dans ce cadre là.

4.2 Élagage

Le procédé de coupe présenté précédemment permet de définir un très grand nombre d'arbres à partir d'un jeu de données (arbre sans coupure, avec une coupure, deux coupures...). Se pose alors la question de trouver le **meilleur arbre** parmi tous les arbres possibles. Une première idée serait de choisir parmi tous les arbres possibles celui qui optimise un critère de performance. Cette approche, bien que cohérente, n'est généralement pas possible à mettre en œuvre en pratique car le nombre d'arbres à considérer est souvent trop important.

La méthode CART propose une procédure permettant de choisir automatiquement un arbre en 3 étapes :

- On construit un **arbre maximal** (très profond) $\mathcal{T}_{max}$;
- On sélectionne une **suite d'arbres emboités** :

$$\mathcal{T}_{max} = \mathcal{T}_0 \supset \mathcal{T}_1 \supset \cdots \supset \mathcal{T}_K.$$

  La sélection s'effectue en optimisant un critère **Cout/complexité** qui permet de réguler le compromis entre **ajustement** et **complexité** de l'arbre.
- On **sélectionne un arbre** dans cette sous-suite en optimisant un critère de performance.

Cette approche revient à choisir un sous-arbre de l'arbre $\mathcal{T}_{\max}$, c'est-à-dire à enlever des branches à $T_{\max}$, c'est pourquoi on parle **d'élagage**.

4.2.1 Élagage pour un problème de régression

On considère les données **Carseats** du package **ISLR**.

```r
library(ISLR)
data(Carseats)
summary(Carseats)
##      Sales          CompPrice       Income
##  Min.   : 0.000   Min.   : 77   Min.   : 21.00
##  1st Qu.: 5.390   1st Qu.:115   1st Qu.: 42.75
##  Median : 7.490   Median :125   Median : 69.00
##  Mean   : 7.496   Mean   :125   Mean   : 68.66
##  3rd Qu.: 9.320   3rd Qu.:135   3rd Qu.: 91.00
##  Max.   :16.270   Max.   :175   Max.   :120.00
##   Advertising       Population        Price
##  Min.   : 0.000   Min.   : 10.0   Min.   : 24.0
##  1st Qu.: 0.000   1st Qu.:139.0   1st Qu.:100.0
##  Median : 5.000   Median :272.0   Median :117.0
##  Mean   : 6.635   Mean   :264.8   Mean   :115.8
##  3rd Qu.:12.000   3rd Qu.:398.5   3rd Qu.:131.0
##  Max.   :29.000   Max.   :509.0   Max.   :191.0
##   ShelveLoc        Age          Education    Urban
##  Bad   : 96   Min.   :25.00   Min.   :10.0   No :118
##  Good  : 85   1st Qu.:39.75   1st Qu.:12.0   Yes:282
##  Medium:219   Median :54.50   Median :14.0
##               Mean   :53.32   Mean   :13.9
##               3rd Qu.:66.00   3rd Qu.:16.0
##               Max.   :80.00   Max.   :18.0
##    US
##  No :142
##  Yes:258
##
##
##
##
```

On cherche ici à expliquer la variable quantitative **Sales** par les autres variables.

1. Construire un arbre permettant de répondre au problème.

```r
tree <- rpart(Sales~.,data=Carseats)
rpart.plot(tree)
```

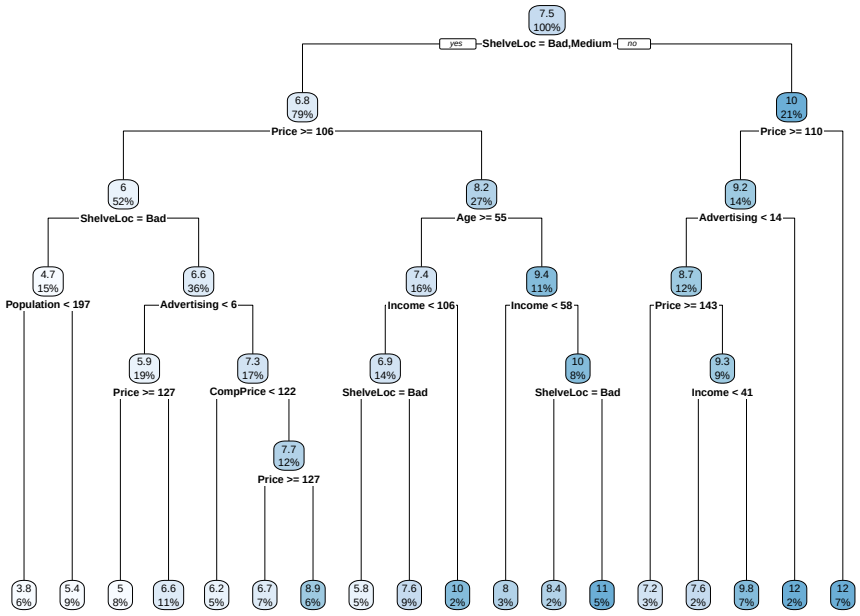

2. Expliquer les sorties de la fonction **printcp** appliquée à l'arbre de la question précédente et calculer le dernier terme de la colonne **rel error**.

```
printcp(tree)
##
## Regression tree:
## rpart(formula = Sales ~ ., data = Carseats)
##
## Variables actually used in tree construction:
## [1] Advertising Age         CompPrice   Income
## [5] Population  Price       ShelveLoc
##
## Root node error: 3182.3/400 = 7.9557
##
## n= 400
##
##          CP nsplit rel error  xerror     xstd
## 1  0.250510      0   1.00000 1.00492 0.069530
## 2  0.105073      1   0.74949 0.75877 0.051613
## 3  0.051121      2   0.64442 0.68283 0.046333
## 4  0.045671      3   0.59330 0.64240 0.043550
## 5  0.033592      4   0.54763 0.60051 0.041716
## 6  0.024063      5   0.51403 0.58903 0.039691
## 7  0.023948      6   0.48997 0.59472 0.039561
## 8  0.022163      7   0.46602 0.58972 0.039539
## 9  0.016043      8   0.44386 0.58329 0.039731
## 10 0.014027      9   0.42782 0.57392 0.038516
```

```
## 11 0.013145     11   0.39976 0.57780 0.038529
## 12 0.012711     12   0.38662 0.58719 0.038339
## 13 0.012147     13   0.37391 0.58970 0.038419
## 14 0.011888     14   0.36176 0.58850 0.038291
## 15 0.010778     15   0.34987 0.58673 0.038383
## 16 0.010506     16   0.33909 0.57818 0.038886
## 17 0.010000     17   0.32859 0.57320 0.038277
plotcp(tree)
```

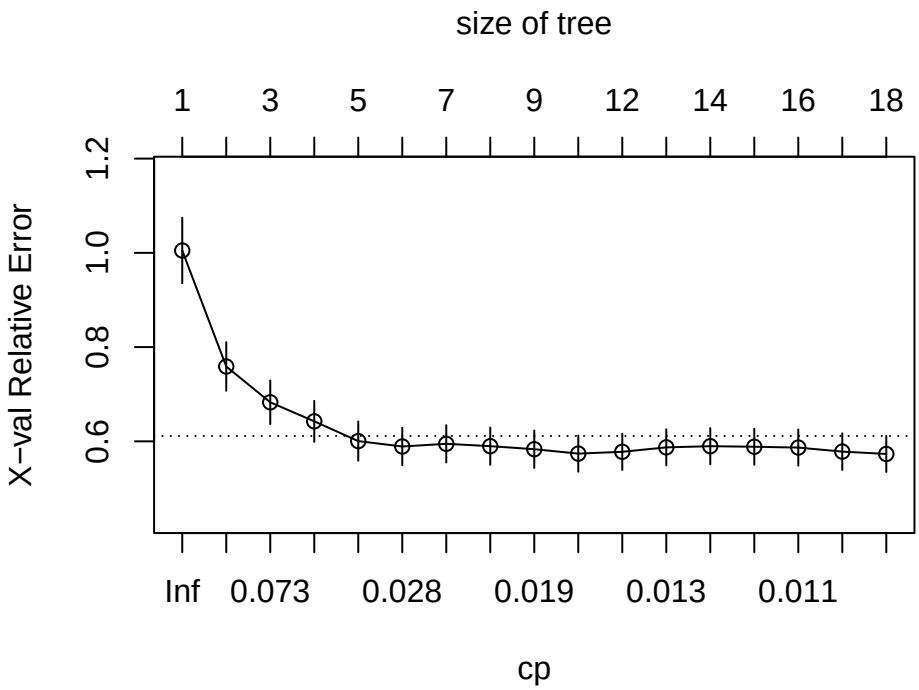


```
Carseats |> mutate(fitted=predict(tree)) |>
  summarise(MSE=mean((fitted-Sales)^2)/mean((Sales-mean(Sales))^2))
##         MSE
## 1 0.3285866
```

3. Construire une suite d'arbres plus grandes en jouant sur les paramètres `cp` et `minsplit` de la fonction **rpart**.

```
set.seed(123)
tree1 <- rpart(Sales~.,data=Carseats,cp=0.00001,minsplit=2)
printcp(tree1)
```

```
##
```

```
## Regression tree:
## rpart(formula = Sales ~ ., data = Carseats, cp = 1e-05, minsplit = 2)
##
## Variables actually used in tree construction:
##  [1] Advertising Age         CompPrice   Education
##  [5] Income      Population  Price       ShelveLoc
##  [9] Urban       US
##
## Root node error: 3182.3/400 = 7.9557
##
## n= 400
##
##             CP nsplit  rel error  xerror     xstd
## 1   2.5051e-01      0 1.00000000 1.00632 0.069635
## 2   1.0507e-01      1 0.74948961 0.75985 0.051802
## 3   5.1121e-02      2 0.64441706 0.67592 0.044633
## 4   4.5671e-02      3 0.59329646 0.67720 0.043488
## 5   3.3592e-02      4 0.54762521 0.64640 0.043209
## 6   2.4063e-02      5 0.51403284 0.64674 0.041192
## 7   2.3948e-02      6 0.48997005 0.63825 0.041103
## 8   2.2163e-02      7 0.46602225 0.63234 0.040983
## 9   1.6043e-02      8 0.44385897 0.61886 0.039262
## 10  1.4027e-02      9 0.42781645 0.61392 0.039072
## 11  1.3145e-02     11 0.39976237 0.61848 0.039060
## 12  1.2711e-02     12 0.38661699 0.62070 0.039293
## 13  1.2147e-02     13 0.37390609 0.62158 0.039768
## 14  1.1888e-02     14 0.36175900 0.62655 0.039848
## 15  1.0778e-02     15 0.34987122 0.61565 0.039116
## 16  1.0506e-02     16 0.33909277 0.62089 0.039292
## 17  1.0301e-02     17 0.32858663 0.62477 0.039223
## 18  9.8052e-03     18 0.31828518 0.62074 0.039205
## 19  9.5324e-03     20 0.29867475 0.62340 0.039696
## 20  9.3098e-03     21 0.28914234 0.61989 0.039722
## 21  8.6039e-03     22 0.27983257 0.62566 0.040168
## 22  8.5728e-03     23 0.27122871 0.61686 0.039659
## 23  7.7737e-03     25 0.25408305 0.62076 0.040607
## 24  7.4353e-03     26 0.24630936 0.61125 0.040480
## 25  6.2838e-03     28 0.23143882 0.59597 0.039395
## 26  6.1242e-03     29 0.22515504 0.60994 0.040169
## 27  5.6953e-03     30 0.21903085 0.59896 0.039173
## 28  5.5687e-03     31 0.21333555 0.60151 0.039820
## 29  5.4134e-03     32 0.20776686 0.60041 0.039844
## 30  5.1373e-03     33 0.20235343 0.58408 0.039291
```

```
## 31  4.9581e-03     34 0.19721608 0.58631 0.039265
## 32  4.8270e-03     35 0.19225798 0.58969 0.039393
## 33  4.5558e-03     36 0.18743102 0.59070 0.039253
## 34  4.5456e-03     37 0.18287525 0.58833 0.038997
## 35  4.3739e-03     38 0.17832965 0.58757 0.038982
## 36  4.3307e-03     39 0.17395578 0.58716 0.038985
## 37  4.2485e-03     40 0.16962503 0.58706 0.039096
## 38  4.0980e-03     41 0.16537650 0.58472 0.039006
## 39  4.0525e-03     42 0.16127847 0.58935 0.039188
## 40  4.0054e-03     43 0.15722596 0.58756 0.038706
## 41  3.6917e-03     44 0.15322052 0.60472 0.039435
## 42  3.6352e-03     45 0.14952883 0.60179 0.039308
## 43  3.5301e-03     46 0.14589367 0.60395 0.039286
## 44  3.5196e-03     47 0.14236356 0.60402 0.039279
## 45  2.8653e-03     48 0.13884396 0.59319 0.038874
## 46  2.8565e-03     49 0.13597868 0.58540 0.039159
## 47  2.8565e-03     50 0.13312217 0.58540 0.039159
## 48  2.7253e-03     51 0.13026571 0.58760 0.039209
## 49  2.6841e-03     52 0.12754044 0.58585 0.038937
## 50  2.6829e-03     54 0.12217220 0.58743 0.038915
## 51  2.6660e-03     55 0.11948928 0.58794 0.038911
## 52  2.4588e-03     56 0.11682326 0.58713 0.038864
## 53  2.3693e-03     57 0.11436443 0.57598 0.038151
## 54  2.3018e-03     58 0.11199508 0.57746 0.038203
## 55  2.2746e-03     60 0.10739152 0.58523 0.039585
## 56  2.2540e-03     61 0.10511688 0.58489 0.039595
## 57  2.1781e-03     62 0.10286290 0.58466 0.039588
## 58  2.1645e-03     63 0.10068483 0.58575 0.039509
## 59  2.0950e-03     64 0.09852033 0.58152 0.039361
## 60  2.0945e-03     65 0.09642538 0.58236 0.039446
## 61  2.0740e-03     66 0.09433084 0.58431 0.039597
## 62  1.8864e-03     67 0.09225680 0.57892 0.039320
## 63  1.8413e-03     68 0.09037038 0.58456 0.039520
## 64  1.7921e-03     69 0.08852905 0.58578 0.040068
## 65  1.7167e-03     70 0.08673697 0.58533 0.039995
## 66  1.6766e-03     71 0.08502031 0.58336 0.039558
## 67  1.6704e-03     72 0.08334367 0.58559 0.039491
## 68  1.6064e-03     73 0.08167332 0.58367 0.039470
## 69  1.6055e-03     74 0.08006697 0.58229 0.039276
## 70  1.5103e-03     75 0.07846149 0.58881 0.039911
## 71  1.4967e-03     76 0.07695120 0.58862 0.039908
## 72  1.4907e-03     77 0.07545453 0.59042 0.040029
## 73  1.4007e-03     78 0.07396387 0.60029 0.040368
```

```
## 74  1.4002e-03     79 0.07256317 0.60033 0.040358
## 75  1.3613e-03     80 0.07116301 0.60705 0.040742
## 76  1.3589e-03     81 0.06980172 0.61439 0.041431
## 77  1.3462e-03     82 0.06844282 0.61457 0.041431
## 78  1.3351e-03     83 0.06709659 0.61405 0.041405
## 79  1.3304e-03     84 0.06576144 0.61487 0.041409
## 80  1.3146e-03     85 0.06443102 0.61487 0.041409
## 81  1.2795e-03     86 0.06311644 0.61217 0.041323
## 82  1.2412e-03     87 0.06183696 0.61153 0.041238
## 83  1.2373e-03     88 0.06059575 0.61610 0.041280
## 84  1.2135e-03     89 0.05935843 0.61519 0.041307
## 85  1.2002e-03     91 0.05693148 0.61097 0.041152
## 86  1.1269e-03     92 0.05573126 0.61178 0.041184
## 87  1.0919e-03     93 0.05460435 0.60862 0.041145
## 88  1.0898e-03     94 0.05351243 0.60925 0.041145
## 89  1.0864e-03     95 0.05242260 0.60925 0.041145
## 90  1.0646e-03     96 0.05133621 0.60693 0.041083
## 91  1.0116e-03     97 0.05027156 0.60260 0.040185
## 92  9.5940e-04     98 0.04925996 0.60122 0.040328
## 93  8.9105e-04     99 0.04830056 0.60234 0.040289
## 94  8.8465e-04    100 0.04740951 0.60105 0.040619
## 95  8.7611e-04    101 0.04652486 0.60055 0.040661
## 96  8.5644e-04    102 0.04564875 0.60111 0.040661
## 97  8.4568e-04    103 0.04479231 0.60150 0.040657
## 98  8.3004e-04    104 0.04394663 0.60427 0.040867
## 99  8.0748e-04    105 0.04311659 0.60590 0.040864
## 100 7.9944e-04    106 0.04230912 0.60627 0.040864
## 101 7.5680e-04    107 0.04150968 0.61302 0.041688
## 102 7.4082e-04    108 0.04075288 0.61164 0.041485
## 103 7.4043e-04    109 0.04001206 0.61183 0.041479
## 104 7.3510e-04    110 0.03927163 0.61163 0.041483
## 105 7.0107e-04    111 0.03853653 0.61182 0.041563
## 106 6.9184e-04    112 0.03783546 0.60947 0.041716
## 107 6.7585e-04    113 0.03714362 0.60947 0.041716
## 108 6.7373e-04    114 0.03646776 0.60689 0.041731
## 109 6.7173e-04    115 0.03579403 0.60689 0.041731
## 110 6.6783e-04    116 0.03512230 0.60591 0.041707
## 111 6.6518e-04    117 0.03445448 0.60613 0.041700
## 112 6.6451e-04    118 0.03378929 0.60613 0.041700
## 113 6.0900e-04    119 0.03312478 0.60732 0.041781
## 114 6.0343e-04    120 0.03251578 0.61077 0.042036
## 115 5.9465e-04    121 0.03191235 0.61269 0.042102
## 116 5.8550e-04    123 0.03072304 0.61208 0.042081
```

```
## 117 5.8340e-04    124 0.03013754 0.61187 0.042084
## 118 5.6972e-04    125 0.02955414 0.61258 0.042084
## 119 5.6433e-04    126 0.02898442 0.61258 0.042084
## 120 5.6323e-04    127 0.02842009 0.61228 0.042075
## 121 5.4821e-04    128 0.02785686 0.60943 0.042014
## 122 5.4339e-04    131 0.02621222 0.60980 0.042021
## 123 5.1968e-04    132 0.02566882 0.60983 0.042171
## 124 5.0869e-04    133 0.02514915 0.60906 0.042168
## 125 5.0157e-04    134 0.02464045 0.60828 0.042297
## 126 4.7302e-04    135 0.02413889 0.61003 0.042276
## 127 4.6969e-04    136 0.02366587 0.60911 0.042228
## 128 4.6775e-04    137 0.02319618 0.61118 0.042218
## 129 4.6669e-04    138 0.02272842 0.61118 0.042218
## 130 4.5761e-04    139 0.02226174 0.60991 0.042232
## 131 4.5283e-04    140 0.02180413 0.60956 0.042235
## 132 4.5270e-04    141 0.02135130 0.61176 0.042356
## 133 4.5251e-04    142 0.02089861 0.61176 0.042356
## 134 4.4875e-04    143 0.02044610 0.61176 0.042356
## 135 4.4874e-04    144 0.01999735 0.61164 0.042360
## 136 4.4666e-04    145 0.01954861 0.61164 0.042360
## 137 4.3805e-04    146 0.01910194 0.61410 0.042468
## 138 4.2159e-04    147 0.01866389 0.61468 0.042470
## 139 4.1179e-04    148 0.01824230 0.61626 0.042531
## 140 3.8646e-04    149 0.01783051 0.61657 0.042546
## 141 3.6959e-04    150 0.01744404 0.61985 0.042911
## 142 3.3035e-04    151 0.01707446 0.62146 0.043372
## 143 3.0799e-04    152 0.01674411 0.62258 0.043333
## 144 3.0672e-04    153 0.01643612 0.62274 0.043330
## 145 3.0672e-04    154 0.01612940 0.62274 0.043330
## 146 3.0672e-04    155 0.01582268 0.62274 0.043330
## 147 3.0544e-04    156 0.01551596 0.62274 0.043330
## 148 3.0094e-04    157 0.01521052 0.62395 0.043352
## 149 2.9757e-04    158 0.01490958 0.62467 0.043363
## 150 2.8981e-04    159 0.01461201 0.62274 0.043380
## 151 2.8923e-04    160 0.01432220 0.62270 0.043354
## 152 2.8782e-04    161 0.01403296 0.62400 0.043499
## 153 2.8635e-04    162 0.01374515 0.62400 0.043499
## 154 2.8189e-04    163 0.01345879 0.62219 0.043487
## 155 2.8173e-04    164 0.01317690 0.62253 0.043478
## 156 2.6988e-04    165 0.01289517 0.62531 0.043675
## 157 2.6283e-04    166 0.01262530 0.62452 0.043671
## 158 2.5737e-04    167 0.01236246 0.62258 0.043382
## 159 2.5139e-04    168 0.01210509 0.62028 0.043359
```

```
## 160 2.5003e-04    169 0.01185370 0.61871 0.043243
## 161 2.3771e-04    170 0.01160367 0.61747 0.043178
## 162 2.3512e-04    171 0.01136596 0.61853 0.043182
## 163 2.2600e-04    172 0.01113084 0.61800 0.043165
## 164 2.1796e-04    173 0.01090483 0.61542 0.043149
## 165 2.1590e-04    174 0.01068688 0.61466 0.043133
## 166 2.1121e-04    175 0.01047098 0.61339 0.043099
## 167 2.0973e-04    176 0.01025977 0.61238 0.043036
## 168 2.0949e-04    178 0.00984031 0.61238 0.043036
## 169 2.0779e-04    179 0.00963081 0.61220 0.043040
## 170 2.0120e-04    180 0.00942302 0.61280 0.043025
## 171 2.0025e-04    181 0.00922182 0.61280 0.043025
## 172 1.9247e-04    182 0.00902157 0.61353 0.043060
## 173 1.8668e-04    183 0.00882910 0.61383 0.043085
## 174 1.7976e-04    184 0.00864242 0.61349 0.043056
## 175 1.6630e-04    185 0.00846266 0.61532 0.043131
## 176 1.6596e-04    186 0.00829637 0.61615 0.043142
## 177 1.6594e-04    187 0.00813041 0.61615 0.043142
## 178 1.6347e-04    188 0.00796447 0.61623 0.043140
## 179 1.6290e-04    189 0.00780100 0.61623 0.043140
## 180 1.5712e-04    190 0.00763810 0.61644 0.043133
## 181 1.5619e-04    191 0.00748098 0.61562 0.043119
## 182 1.5210e-04    192 0.00732479 0.61504 0.043100
## 183 1.4745e-04    193 0.00717270 0.61484 0.043106
## 184 1.4354e-04    194 0.00702525 0.61434 0.043095
## 185 1.3883e-04    195 0.00688171 0.61338 0.043090
## 186 1.3883e-04    196 0.00674288 0.61357 0.043102
## 187 1.3613e-04    197 0.00660405 0.61349 0.043104
## 188 1.3589e-04    198 0.00646792 0.61374 0.043123
## 189 1.3299e-04    199 0.00633203 0.61225 0.043031
## 190 1.3241e-04    200 0.00619904 0.61244 0.043040
## 191 1.3011e-04    201 0.00606664 0.61182 0.043038
## 192 1.2674e-04    202 0.00593652 0.61207 0.043052
## 193 1.2674e-04    203 0.00580978 0.61250 0.043040
## 194 1.2167e-04    204 0.00568304 0.61345 0.043093
## 195 1.2167e-04    205 0.00556136 0.61264 0.043092
## 196 1.2105e-04    206 0.00543969 0.61264 0.043092
## 197 1.1352e-04    207 0.00531864 0.61255 0.043081
## 198 1.0898e-04    208 0.00520512 0.61236 0.043083
## 199 1.0860e-04    209 0.00509614 0.61259 0.043076
## 200 1.0592e-04    210 0.00498754 0.61259 0.043076
## 201 1.0265e-04    211 0.00488162 0.61474 0.043307
## 202 9.6794e-05    212 0.00477896 0.61439 0.043163
```

```
## 203 9.5532e-05    213 0.00468217 0.61428 0.043175
## 204 9.4042e-05    214 0.00458664 0.61450 0.043168
## 205 9.1257e-05    215 0.00449260 0.61509 0.043172
## 206 9.0753e-05    216 0.00440134 0.61548 0.043188
## 207 8.9624e-05    217 0.00431059 0.61573 0.043180
## 208 8.8270e-05    218 0.00422096 0.61566 0.043182
## 209 8.7486e-05    219 0.00413269 0.61545 0.043188
## 210 8.3729e-05    220 0.00404521 0.61466 0.043180
## 211 8.1451e-05    221 0.00396148 0.61426 0.043159
## 212 7.9204e-05    222 0.00388003 0.61366 0.043149
## 213 7.7471e-05    224 0.00372162 0.61346 0.043143
## 214 7.6989e-05    225 0.00364415 0.61346 0.043143
## 215 7.4805e-05    227 0.00349017 0.61288 0.043144
## 216 7.2925e-05    228 0.00341536 0.61356 0.043182
## 217 7.2160e-05    229 0.00334244 0.61239 0.043184
## 218 7.1694e-05    230 0.00327028 0.61239 0.043184
## 219 6.9264e-05    231 0.00319859 0.61315 0.043444
## 220 6.8065e-05    232 0.00312932 0.61316 0.043445
## 221 6.8065e-05    233 0.00306126 0.61363 0.043442
## 222 6.7977e-05    234 0.00299319 0.61363 0.043442
## 223 6.6383e-05    235 0.00292522 0.61341 0.043441
## 224 6.6383e-05    236 0.00285883 0.61341 0.043441
## 225 6.6383e-05    237 0.00279245 0.61341 0.043441
## 226 6.6203e-05    238 0.00272607 0.61341 0.043441
## 227 6.5697e-05    239 0.00265986 0.61341 0.043441
## 228 6.5373e-05    240 0.00259417 0.61341 0.043441
## 229 6.4356e-05    241 0.00252879 0.61327 0.043444
## 230 6.3372e-05    242 0.00246444 0.61244 0.043314
## 231 6.2228e-05    243 0.00240107 0.61268 0.043307
## 232 6.2225e-05    244 0.00233884 0.61268 0.043307
## 233 6.0397e-05    245 0.00227661 0.61266 0.043308
## 234 5.8464e-05    246 0.00221622 0.61302 0.043300
## 235 5.8137e-05    248 0.00209929 0.61288 0.043302
## 236 5.4694e-05    249 0.00204115 0.61454 0.043304
## 237 5.2855e-05    251 0.00193176 0.61433 0.043357
## 238 5.1331e-05    252 0.00187891 0.61341 0.043318
## 239 5.1048e-05    253 0.00182758 0.61222 0.043262
## 240 4.9324e-05    255 0.00172548 0.61222 0.043262
## 241 4.9278e-05    256 0.00167616 0.61214 0.043261
## 242 4.9278e-05    257 0.00162688 0.61214 0.043261
## 243 4.9273e-05    258 0.00157760 0.61214 0.043261
## 244 4.5298e-05    259 0.00152833 0.61225 0.043257
## 245 4.3577e-05    260 0.00148303 0.61182 0.043250
```

```
## 246 4.3370e-05    261 0.00143945 0.61153 0.043256
## 247 4.2422e-05    262 0.00139608 0.61153 0.043256
## 248 4.0867e-05    263 0.00135366 0.61087 0.043246
## 249 3.9280e-05    264 0.00131279 0.61059 0.043234
## 250 3.7840e-05    265 0.00127351 0.61039 0.043239
## 251 3.7840e-05    266 0.00123567 0.61013 0.043231
## 252 3.7840e-05    267 0.00119783 0.61013 0.043231
## 253 3.6955e-05    268 0.00115999 0.61040 0.043226
## 254 3.5847e-05    269 0.00112304 0.61040 0.043226
## 255 3.5216e-05    270 0.00108719 0.61040 0.043226
## 256 3.4708e-05    271 0.00105197 0.61069 0.043225
## 257 3.4032e-05    272 0.00101727 0.61083 0.043221
## 258 3.3519e-05    273 0.00098323 0.61077 0.043223
## 259 3.3247e-05    274 0.00094971 0.61077 0.043223
## 260 2.9981e-05    275 0.00091647 0.61135 0.043216
## 261 2.9052e-05    276 0.00088649 0.61163 0.043224
## 262 2.7245e-05    277 0.00085744 0.61167 0.043189
## 263 2.5663e-05    278 0.00083019 0.61090 0.043097
## 264 2.5663e-05    279 0.00080453 0.61090 0.043097
## 265 2.2814e-05    280 0.00077886 0.61105 0.043094
## 266 2.2688e-05    281 0.00075605 0.61153 0.043120
## 267 2.2128e-05    282 0.00073336 0.61091 0.043128
## 268 2.1877e-05    283 0.00071123 0.61118 0.043154
## 269 2.1510e-05    284 0.00068936 0.61118 0.043154
## 270 2.0132e-05    285 0.00066785 0.61155 0.043169
## 271 2.0132e-05    286 0.00064772 0.61209 0.043176
## 272 1.8231e-05    287 0.00062758 0.61222 0.043173
## 273 1.8163e-05    288 0.00060935 0.61289 0.043189
## 274 1.7618e-05    289 0.00059119 0.61289 0.043189
## 275 1.7618e-05    290 0.00057357 0.61289 0.043189
## 276 1.7608e-05    291 0.00055595 0.61289 0.043189
## 277 1.7110e-05    292 0.00053834 0.61261 0.043152
## 278 1.5272e-05    293 0.00052123 0.61323 0.043154
## 279 1.5099e-05    294 0.00050596 0.61262 0.043101
## 280 1.4162e-05    296 0.00047576 0.61252 0.043100
## 281 1.4162e-05    297 0.00046160 0.61237 0.043096
## 282 1.4141e-05    298 0.00044744 0.61237 0.043096
## 283 1.4141e-05    300 0.00041916 0.61237 0.043096
## 284 1.3214e-05    301 0.00040502 0.61212 0.043066
## 285 1.3214e-05    302 0.00039180 0.61186 0.043063
## 286 1.3093e-05    303 0.00037859 0.61186 0.043063
## 287 1.2318e-05    304 0.00036550 0.61172 0.043054
## 288 1.2318e-05    305 0.00035318 0.61141 0.043044
```

```
## 289 1.1454e-05    306 0.00034086 0.61140 0.043044
## 290 1.1082e-05    307 0.00032941 0.61149 0.043050
## 291 1.0621e-05    308 0.00031832 0.61200 0.043160
## 292 1.0000e-05    312 0.00027584 0.61200 0.043160
```

4. Expliquer la sortie de la fonction **plotcp** appliquée à l'arbre de la question précédente.

```
plotcp(tree1)
```

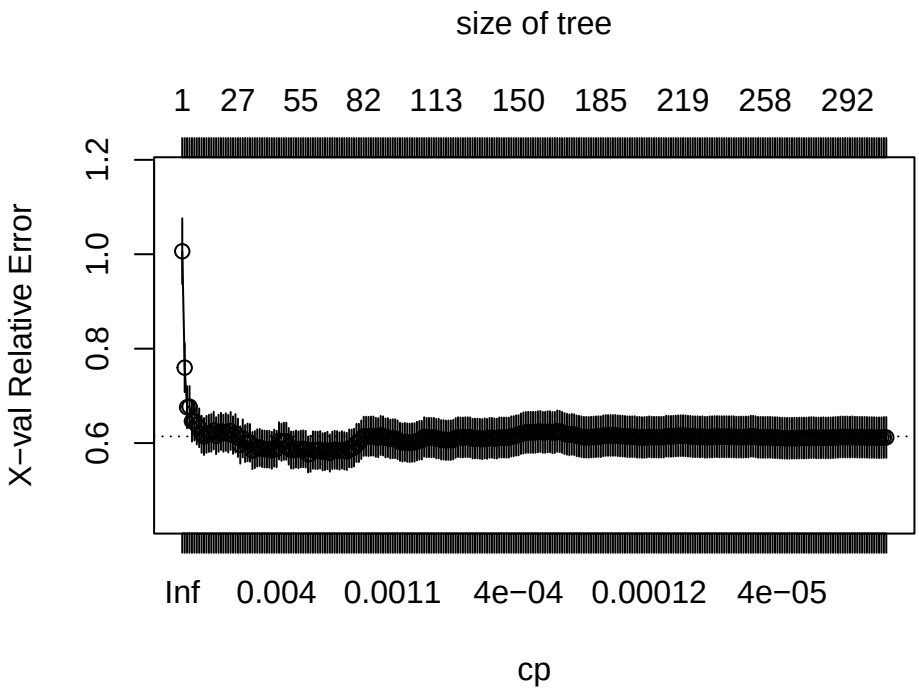

5. Sélectionner le "meilleur" arbre dans la suite construite.

```
cp_opt <- tree1$cptable |> as.data.frame() |>
  filter(xerror==min(xerror)) |> dplyr::select(CP) |>
  as.numeric()
cp_opt
## [1] 0.002369349
```

6. Visualiser l'arbre choisi (utiliser la fonction **prune**).

```
tree_opt <- prune(tree,cp=cp_opt)
rpart.plot(tree_opt)
```

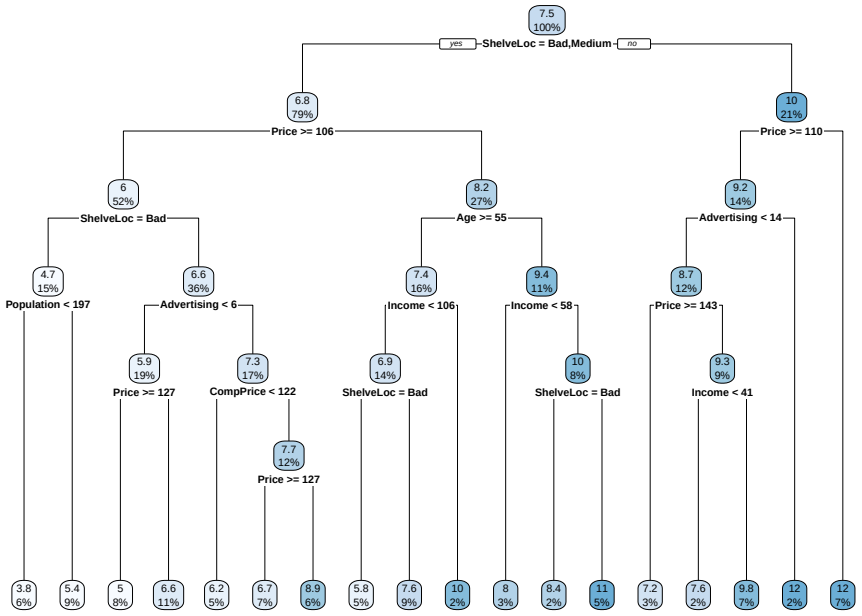


```
library(visNetwork)
visTree(tree_opt)
```

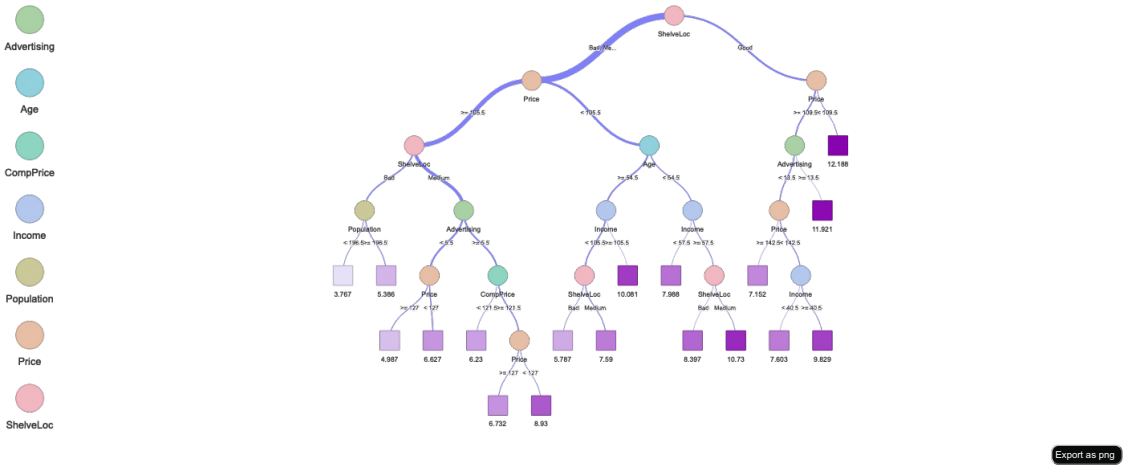


```
visTreeEditor(Carseats)
```

7. On souhaite prédire les valeurs de Y pour de nouveaux individus à partir de l'arbre sélectionné. Pour simplifier on considèrera ces 4 individus :

```
(new_ind <- Carseats |> as_tibble() |>
   slice(3,58,185,218) |> dplyr::select(-Sales))
## # A tibble: 4 x 10
##   CompP~1 Income Adver~2 Popul~3 Price Shelv~4   Age Educa~5
##     <dbl>  <dbl>   <dbl>   <dbl> <dbl> <fct>   <dbl>   <dbl>
## 1     113     35      10     269    80 Medium     59      12
## 2      93     91       0      22   117 Bad        75      11
## 3     132     33       7      35    97 Medium     60      11
## 4     106     44       0     481   111 Medium     70      14
## # ... with 2 more variables: Urban <fct>, US <fct>, and
## #   abbreviated variable names 1: CompPrice,
## #   2: Advertising, 3: Population, 4: ShelveLoc,
## #   5: Education
```

Calculer les valeurs prédites.

```
predict(tree_opt,newdata=new_ind)
##        1        2        3        4
## 7.590278 3.767200 7.590278 6.626512
```

8. Séparer les données en un échantillon d'apprentissage de taille 250 et un échantillon test de taille 150.

```
n.train <- 250
set.seed(1234)
perm <- sample(nrow(Carseats))
train <- Carseats[perm[1:n.train],]
test <- Carseats[-perm[1:n.train],]
```

9. On considère la suite d'arbres définie par

```
set.seed(4321)
tree <- rpart(Sales~.,data=train,cp=0.000001,minsplit=2)
```

Dans cette suite, sélectionner

- un arbre très simple (avec 2 ou 3 coupures)
- un arbre très grand
- l'arbre optimal (avec la procédure d'élagage classique).

```
printcp(tree)
```

```
##
## Regression tree:
## rpart(formula = Sales ~ ., data = train, cp = 1e-06, minsplit = 2)
##
## Variables actually used in tree construction:
##  [1] Advertising Age         CompPrice   Education
##  [5] Income      Population  Price       ShelveLoc
##  [9] Urban       US
##
## Root node error: 1930.1/250 = 7.7203
##
## n= 250
##
##             CP nsplit  rel error  xerror     xstd
## 1   2.1456e-01      0 1.0000e+00 1.00199 0.090218
## 2   9.9792e-02      1 7.8544e-01 0.86595 0.075513
## 3   5.5822e-02      2 6.8565e-01 0.82348 0.071817
## 4   5.5012e-02      3 6.2983e-01 0.76327 0.065209
## 5   4.7593e-02      4 5.7481e-01 0.75011 0.065969
## 6   3.2780e-02      5 5.2722e-01 0.69666 0.062659
## 7   3.2081e-02      6 4.9444e-01 0.71690 0.062718
## 8   2.8747e-02      7 4.6236e-01 0.71639 0.062790
## 9   2.7988e-02      8 4.3361e-01 0.69569 0.059348
## 10  1.8568e-02      9 4.0563e-01 0.70266 0.064934
## 11  1.8305e-02     10 3.8706e-01 0.75844 0.071881
## 12  1.7705e-02     11 3.6875e-01 0.75332 0.071355
## 13  1.6028e-02     12 3.5105e-01 0.77667 0.075496
## 14  1.4152e-02     13 3.3502e-01 0.76655 0.074752
## 15  1.4119e-02     14 3.2087e-01 0.80299 0.082942
## 16  1.1545e-02     15 3.0675e-01 0.82136 0.082988
## 17  1.1033e-02     16 2.9520e-01 0.80368 0.081778
## 18  1.0407e-02     17 2.8417e-01 0.80205 0.081219
## 19  9.6380e-03     18 2.7377e-01 0.80105 0.081149
## 20  9.4448e-03     19 2.6413e-01 0.79823 0.081147
## 21  9.2825e-03     21 2.4524e-01 0.79320 0.081143
## 22  8.7958e-03     22 2.3596e-01 0.76562 0.078130
## 23  8.7574e-03     23 2.2716e-01 0.76141 0.078054
## 24  7.9616e-03     24 2.1840e-01 0.76444 0.077936
## 25  7.0728e-03     25 2.1044e-01 0.77626 0.077783
## 26  7.0288e-03     27 1.9630e-01 0.77706 0.078603
## 27  6.7205e-03     28 1.8927e-01 0.77012 0.077833
## 28  6.5421e-03     29 1.8255e-01 0.76052 0.075687
## 29  6.4728e-03     30 1.7600e-01 0.77588 0.075711
```

```
## 30  5.7670e-03     31 1.6953e-01 0.77776 0.075870
## 31  5.0693e-03     32 1.6376e-01 0.79694 0.077306
## 32  4.9069e-03     34 1.5363e-01 0.78951 0.077248
## 33  4.7845e-03     35 1.4872e-01 0.78954 0.077227
## 34  4.7623e-03     36 1.4393e-01 0.79479 0.078655
## 35  4.7423e-03     38 1.3441e-01 0.79479 0.078655
## 36  4.3579e-03     39 1.2967e-01 0.78334 0.078557
## 37  4.3530e-03     40 1.2531e-01 0.78187 0.078607
## 38  4.1413e-03     41 1.2096e-01 0.78700 0.078606
## 39  4.0455e-03     42 1.1681e-01 0.78351 0.078553
## 40  3.9302e-03     43 1.1277e-01 0.76858 0.075026
## 41  3.8957e-03     45 1.0491e-01 0.76858 0.075026
## 42  3.8803e-03     46 1.0101e-01 0.77054 0.075020
## 43  3.8596e-03     47 9.7133e-02 0.77054 0.075020
## 44  3.5520e-03     48 9.3273e-02 0.76480 0.074222
## 45  3.5181e-03     49 8.9721e-02 0.75251 0.074226
## 46  3.4216e-03     50 8.6203e-02 0.75336 0.074228
## 47  3.1866e-03     51 8.2782e-02 0.75473 0.074308
## 48  3.1193e-03     52 7.9595e-02 0.75621 0.074297
## 49  3.0949e-03     53 7.6476e-02 0.75747 0.074346
## 50  2.8538e-03     54 7.3381e-02 0.76454 0.074387
## 51  2.7245e-03     55 7.0527e-02 0.75920 0.074369
## 52  2.6778e-03     56 6.7802e-02 0.75964 0.074366
## 53  2.2840e-03     57 6.5125e-02 0.75580 0.074519
## 54  2.1373e-03     58 6.2841e-02 0.74584 0.074550
## 55  2.1338e-03     59 6.0703e-02 0.73895 0.074268
## 56  1.9958e-03     60 5.8570e-02 0.73653 0.074241
## 57  1.9324e-03     61 5.6574e-02 0.73663 0.073524
## 58  1.8577e-03     62 5.4641e-02 0.73454 0.073556
## 59  1.7446e-03     63 5.2784e-02 0.73777 0.073803
## 60  1.7300e-03     64 5.1039e-02 0.73668 0.073751
## 61  1.7199e-03     65 4.9309e-02 0.73848 0.073725
## 62  1.6642e-03     67 4.5869e-02 0.73425 0.073646
## 63  1.5818e-03     68 4.4205e-02 0.72999 0.073374
## 64  1.4176e-03     69 4.2623e-02 0.74065 0.074144
## 65  1.2535e-03     70 4.1205e-02 0.73915 0.074086
## 66  1.2528e-03     71 3.9952e-02 0.73727 0.074038
## 67  1.2241e-03     72 3.8699e-02 0.73623 0.074052
## 68  1.1710e-03     73 3.7475e-02 0.74071 0.074539
## 69  1.0861e-03     74 3.6304e-02 0.73962 0.074496
## 70  1.0751e-03     75 3.5218e-02 0.73945 0.074716
## 71  1.0619e-03     76 3.4143e-02 0.73833 0.074740
## 72  1.0396e-03     77 3.3081e-02 0.73833 0.074740
```

```
## 73  1.0031e-03     78 3.2041e-02 0.73390 0.073412
## 74  9.8653e-04     79 3.1038e-02 0.73390 0.073412
## 75  9.7982e-04     80 3.0052e-02 0.73362 0.073421
## 76  9.6068e-04     81 2.9072e-02 0.73336 0.073431
## 77  9.0157e-04     82 2.8111e-02 0.73346 0.073239
## 78  8.5140e-04     83 2.7210e-02 0.74355 0.073608
## 79  8.2985e-04     84 2.6358e-02 0.74289 0.073577
## 80  7.6578e-04     85 2.5529e-02 0.75270 0.074401
## 81  7.5439e-04     87 2.3997e-02 0.75068 0.071516
## 82  7.1170e-04     88 2.3243e-02 0.74411 0.071166
## 83  6.8926e-04     89 2.2531e-02 0.74202 0.071059
## 84  6.7218e-04     90 2.1842e-02 0.73282 0.070730
## 85  6.7025e-04     91 2.1169e-02 0.73262 0.070738
## 86  6.6158e-04     92 2.0499e-02 0.73262 0.070738
## 87  6.3418e-04     93 1.9838e-02 0.73337 0.070711
## 88  5.8450e-04     94 1.9203e-02 0.73500 0.071237
## 89  5.6893e-04     95 1.8619e-02 0.73223 0.070717
## 90  5.5273e-04     96 1.8050e-02 0.73659 0.070702
## 91  5.4467e-04     97 1.7497e-02 0.73718 0.070776
## 92  5.4467e-04     98 1.6953e-02 0.73718 0.070776
## 93  5.3718e-04     99 1.6408e-02 0.73718 0.070776
## 94  5.2351e-04    100 1.5871e-02 0.73718 0.070776
## 95  5.0781e-04    101 1.5347e-02 0.73857 0.071077
## 96  4.9273e-04    102 1.4839e-02 0.73897 0.071303
## 97  4.7591e-04    103 1.4347e-02 0.73723 0.071291
## 98  4.7283e-04    104 1.3871e-02 0.73289 0.071245
## 99  4.7167e-04    105 1.3398e-02 0.73289 0.071245
## 100 4.6792e-04    106 1.2926e-02 0.73367 0.071229
## 101 4.4890e-04    107 1.2458e-02 0.73271 0.071251
## 102 4.4497e-04    108 1.2009e-02 0.73500 0.071336
## 103 4.3662e-04    109 1.1565e-02 0.73626 0.071314
## 104 4.0289e-04    110 1.1128e-02 0.73827 0.071318
## 105 3.9917e-04    111 1.0725e-02 0.73714 0.071225
## 106 3.5812e-04    112 1.0326e-02 0.73757 0.071280
## 107 3.4136e-04    113 9.9677e-03 0.73935 0.071322
## 108 3.4092e-04    114 9.6264e-03 0.73935 0.071322
## 109 3.1735e-04    115 9.2854e-03 0.73935 0.071322
## 110 2.9187e-04    116 8.9681e-03 0.74282 0.072752
## 111 2.8919e-04    117 8.6762e-03 0.74209 0.072720
## 112 2.6331e-04    118 8.3870e-03 0.74465 0.072682
## 113 2.5547e-04    119 8.1237e-03 0.74431 0.072695
## 114 2.5495e-04    120 7.8683e-03 0.74576 0.072656
## 115 2.3380e-04    121 7.6133e-03 0.74654 0.072644
```

```
## 116 2.2890e-04    122 7.3795e-03 0.74668 0.072724
## 117 2.2642e-04    123 7.1506e-03 0.74690 0.072727
## 118 2.0984e-04    124 6.9242e-03 0.74265 0.072544
## 119 2.0200e-04    125 6.7143e-03 0.74425 0.072512
## 120 1.9608e-04    126 6.5123e-03 0.74161 0.072178
## 121 1.8717e-04    127 6.3163e-03 0.74511 0.072464
## 122 1.8717e-04    128 6.1291e-03 0.74799 0.072449
## 123 1.8580e-04    129 5.9419e-03 0.74770 0.072459
## 124 1.8476e-04    130 5.7561e-03 0.74770 0.072459
## 125 1.7793e-04    131 5.5714e-03 0.74719 0.072478
## 126 1.7444e-04    132 5.3934e-03 0.75014 0.072719
## 127 1.7244e-04    133 5.2190e-03 0.75150 0.072759
## 128 1.5738e-04    134 5.0466e-03 0.75072 0.072755
## 129 1.5505e-04    135 4.8892e-03 0.75222 0.072736
## 130 1.5275e-04    136 4.7341e-03 0.75193 0.072741
## 131 1.4819e-04    137 4.5814e-03 0.75415 0.072836
## 132 1.4370e-04    138 4.4332e-03 0.75422 0.072833
## 133 1.4148e-04    139 4.2895e-03 0.75413 0.072836
## 134 1.3805e-04    140 4.1480e-03 0.75413 0.072836
## 135 1.3430e-04    141 4.0100e-03 0.74921 0.071582
## 136 1.2773e-04    142 3.8757e-03 0.74657 0.071549
## 137 1.2334e-04    143 3.7479e-03 0.74713 0.071529
## 138 1.2312e-04    144 3.6246e-03 0.74737 0.071512
## 139 1.2024e-04    145 3.5015e-03 0.74737 0.071512
## 140 1.1979e-04    146 3.3812e-03 0.74737 0.071512
## 141 1.1629e-04    147 3.2615e-03 0.74785 0.071532
## 142 1.1285e-04    148 3.1452e-03 0.74861 0.071529
## 143 1.1222e-04    149 3.0323e-03 0.74823 0.071534
## 144 1.1026e-04    150 2.9201e-03 0.74823 0.071534
## 145 1.0832e-04    151 2.8098e-03 0.74823 0.071534
## 146 1.0640e-04    152 2.7015e-03 0.74763 0.071529
## 147 1.0640e-04    153 2.5951e-03 0.74763 0.071529
## 148 1.0611e-04    154 2.4887e-03 0.74763 0.071529
## 149 1.0260e-04    155 2.3826e-03 0.74763 0.071529
## 150 9.6395e-05    156 2.2800e-03 0.74796 0.071519
## 151 9.1612e-05    157 2.1836e-03 0.74794 0.071510
## 152 9.1612e-05    158 2.0920e-03 0.74575 0.071262
## 153 9.0178e-05    159 2.0004e-03 0.74575 0.071262
## 154 8.8088e-05    160 1.9102e-03 0.74505 0.071262
## 155 8.2225e-05    161 1.8221e-03 0.74505 0.071262
## 156 8.1241e-05    162 1.7399e-03 0.74505 0.071262
## 157 7.8365e-05    163 1.6587e-03 0.74505 0.071262
## 158 7.7933e-05    164 1.5803e-03 0.74444 0.071272
```

```
## 159 7.6301e-05    165 1.5024e-03 0.74439 0.071302
## 160 7.2769e-05    166 1.4261e-03 0.74487 0.071275
## 161 6.7381e-05    167 1.3533e-03 0.74537 0.071259
## 162 6.4264e-05    168 1.2859e-03 0.74567 0.071240
## 163 6.2200e-05    169 1.2216e-03 0.74575 0.071237
## 164 6.2200e-05    170 1.1594e-03 0.74484 0.071204
## 165 5.9104e-05    172 1.0350e-03 0.74682 0.071255
## 166 5.7226e-05    173 9.7594e-04 0.74664 0.071254
## 167 5.2975e-05    174 9.1872e-04 0.74630 0.071256
## 168 5.0154e-05    175 8.6574e-04 0.74784 0.071591
## 169 4.5138e-05    176 8.1559e-04 0.74775 0.071593
## 170 4.3548e-05    177 7.7045e-04 0.74783 0.071590
## 171 3.7343e-05    178 7.2690e-04 0.74733 0.071588
## 172 3.3574e-05    179 6.8956e-04 0.74901 0.071885
## 173 3.2132e-05    181 6.2241e-04 0.74965 0.071873
## 174 3.1933e-05    182 5.9028e-04 0.74965 0.071873
## 175 3.1735e-05    183 5.5835e-04 0.74965 0.071873
## 176 2.8211e-05    184 5.2661e-04 0.74871 0.071893
## 177 2.6528e-05    186 4.7019e-04 0.74910 0.071893
## 178 2.4895e-05    187 4.4366e-04 0.74849 0.071891
## 179 2.3315e-05    189 3.9387e-04 0.74884 0.071879
## 180 2.2406e-05    190 3.7055e-04 0.74863 0.071879
## 181 2.1787e-05    191 3.4815e-04 0.74883 0.071893
## 182 2.0310e-05    192 3.2636e-04 0.74905 0.071891
## 183 1.8885e-05    193 3.0605e-04 0.74848 0.071856
## 184 1.7512e-05    194 2.8717e-04 0.74842 0.071854
## 185 1.7486e-05    195 2.6965e-04 0.74764 0.071829
## 186 1.6191e-05    196 2.5217e-04 0.74786 0.071823
## 187 1.5967e-05    198 2.1978e-04 0.74741 0.071800
## 188 1.4922e-05    199 2.0382e-04 0.74741 0.071800
## 189 1.3816e-05    200 1.8890e-04 0.74746 0.071784
## 190 1.3704e-05    201 1.7508e-04 0.74738 0.071787
## 191 1.3704e-05    202 1.6138e-04 0.74738 0.071787
## 192 1.3134e-05    203 1.4767e-04 0.74738 0.071787
## 193 1.2538e-05    204 1.3454e-04 0.74713 0.071769
## 194 1.2469e-05    205 1.2200e-04 0.74686 0.071769
## 195 9.3520e-06    206 1.0953e-04 0.74739 0.071770
## 196 9.3520e-06    207 1.0018e-04 0.74683 0.071766
## 197 8.3935e-06    208 9.0826e-05 0.74686 0.071762
## 198 7.4868e-06    210 7.4039e-05 0.74709 0.071770
## 199 6.2951e-06    211 6.6552e-05 0.74743 0.071763
## 200 5.0775e-06    212 6.0257e-05 0.74757 0.071758
## 201 4.9739e-06    213 5.5179e-05 0.74752 0.071756
```

```
## 202 4.9739e-06    214 5.0205e-05 0.74752 0.071756
## 203 4.7731e-06    215 4.5232e-05 0.74752 0.071756
## 204 4.1967e-06    217 3.5685e-05 0.74745 0.071757
## 205 4.1492e-06    218 3.1488e-05 0.74741 0.071759
## 206 3.7304e-06    219 2.7339e-05 0.74701 0.071761
## 207 3.1346e-06    220 2.3609e-05 0.74663 0.071759
## 208 2.4956e-06    221 2.0474e-05 0.74656 0.071748
## 209 2.2106e-06    222 1.7979e-05 0.74660 0.071747
## 210 2.2106e-06    223 1.5768e-05 0.74670 0.071746
## 211 1.6580e-06    224 1.3557e-05 0.74670 0.071746
## 212 1.4594e-06    226 1.0241e-05 0.74634 0.071706
## 213 1.2694e-06    227 8.7821e-06 0.74652 0.071710
## 214 1.2694e-06    229 6.2433e-06 0.74652 0.071710
## 215 1.0000e-06    230 4.9739e-06 0.74652 0.071710
```

```r
simple.tree <- prune(tree,cp=0.1)
large.tree <- prune(tree,cp=1e-6)
#cp_opt <- tree$cptable[which.min(tree$cptable[,"xerror"]),"CP"]
cp_opt <- tree$cptable |> as.data.frame() |>
  filter(xerror==min(xerror)) |>
  dplyr::select(CP) |> dplyr::slice(1) |> as.numeric()
opt.tree <- rpart::prune(tree,cp=cp_opt)
```

10. Calculer l'erreur quadratique de ces 3 arbres en utilisant l'échantillon test.

```r
data.prev <- data.frame(simple=predict(simple.tree,newdata = test),
                        large=predict(large.tree,newdata = test),
                        opt=predict(opt.tree,newdata = test),
                        obs=test$Sale)
```

```r
data.prev |> summarise_at(1:3,~mean((obs-.)^2))
##     simple   large      opt
## 1 5.800361 5.43738 4.469369
```

11. Refaire la comparaison avec une validation croisée 10 blocs.

```r
library(caret)
K <- 10
set.seed(1234)
kfolds <- createFolds(1:nrow(Carseats),k=K)
```

```r
prev <- matrix(0,nrow=nrow(Carseats),ncol=3) |> as.data.frame()
names(prev) <- c("simple","large","opt")
for (j in 1:K){
  train <- Carseats[-kfolds[[j]],]
  test <- Carseats[kfolds[[j]],]
  tree <- rpart(Sales~.,data=train,minsplit=2,cp=1e-9)
  simple <- prune(tree,cp=tree$cptable[2,1])
  large <- prune(tree,cp=1e-9)
  cp_opt <- tree$cptable |> as.data.frame() |>
    filter(xerror==min(xerror)) |>
    dplyr::select(CP) |> as.numeric()
  opt <- prune(tree,cp=cp_opt)
  prev[kfolds[[j]],1] <- predict(simple,newdata=test)
  prev[kfolds[[j]],2] <- predict(large,newdata=test)
  prev[kfolds[[j]],3] <- predict(opt,newdata=test)
}
prev |> mutate(obs=Carseats$Sales) |>
  summarize_at(1:3,~mean((obs-.)^2))
##     simple   large      opt
## 1 6.003064 4.79406 4.556404
```

4.2.2 Élagage en classification binaire et matrice de coût

On considère ici les mêmes données que précédemment mais on cherche à expliquer une version binaire de la variable **Sales**. Cette nouvelle variable, appelée `High` prend pour valeurs `No` si `Sales` est inférieur ou égal à 8, `Yes` sinon. On travaillera donc avec le jeu `data1` défini ci-dessous.

```r
High <- ifelse(Carseats$Sales<=8,"No","Yes")
data1 <- Carseats |> dplyr::select(-Sales) |> mutate(High)
```

1. Construire un arbre permettant d'expliquer `High` par les autres variables (sans `Sales` évidemment !) et expliquer les principales différences par rapport à la partie précédente précédente.

```r
set.seed(321)
tree <- rpart(High~.,data=data1)
rpart.plot(tree)
```

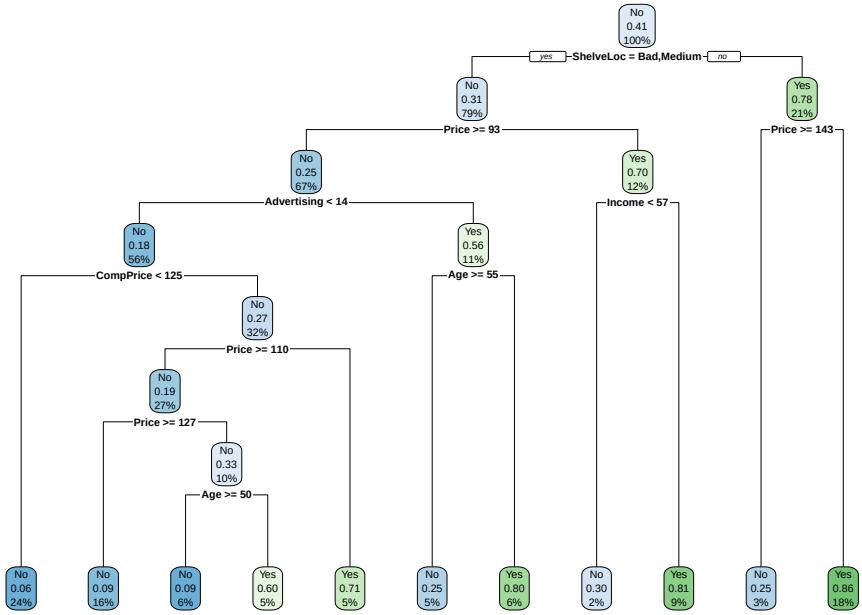

2. Expliquer l'option `parms` dans la commande :

```
tree1 <- rpart(High~.,data=data1,parms=list(split="information"))
tree1$parms
## $prior
##    1    2
## 0.59 0.41
##
## $loss
##      [,1] [,2]
## [1,]    0    1
## [2,]    1    0
##
## $split
## [1] 2
```

3. Expliquer les sorties de la fonction **printcp** sur le premier arbre construit et retrouver la valeur du dernier terme de la colonne **rel error**.

```
printcp(tree)
##
## Classification tree:
## rpart(formula = High ~ ., data = data1)
##
## Variables actually used in tree construction:
## [1] Advertising Age         CompPrice   Income
```

```
## [5] Price       ShelveLoc
##
## Root node error: 164/400 = 0.41
##
## n= 400
##
##         CP nsplit rel error  xerror     xstd
## 1 0.286585      0   1.00000 1.00000 0.059980
## 2 0.109756      1   0.71341 0.71341 0.055477
## 3 0.045732      2   0.60366 0.66463 0.054298
## 4 0.036585      4   0.51220 0.64634 0.053821
## 5 0.027439      5   0.47561 0.60976 0.052806
## 6 0.024390      7   0.42073 0.58537 0.052083
## 7 0.012195      8   0.39634 0.56707 0.051515
## 8 0.010000     10   0.37195 0.53659 0.050518
```

```
data1 |> mutate(fitted=predict(tree,type="class")) |>
  summarise(MC=mean(fitted!=High)/mean(High=="Yes"))
##          MC
## 1 0.3719512
#mean(predict(arbre,type="class")!=donnees$High)/mean(donnees$High=="Yes")
```

4. Sélectionner un arbre optimal dans la suite.

```
tree1 <- rpart(High~.,data=data1,cp=0.000001,minsplit=2)
plotcp(tree1)
```

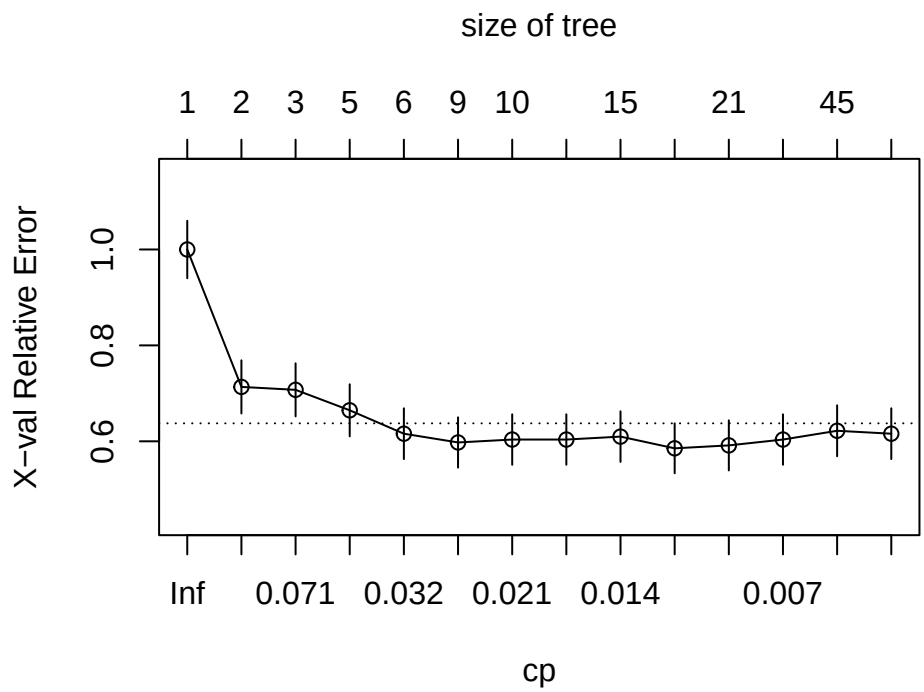


```
cp_opt <- tree1$cptable |> as.data.frame() |>
  slice(which.min(xerror)) |>
  dplyr::select(CP) |> as.numeric()
tree_sel <- prune(tree1,cp=cp_opt)
rpart.plot(tree_sel)
```

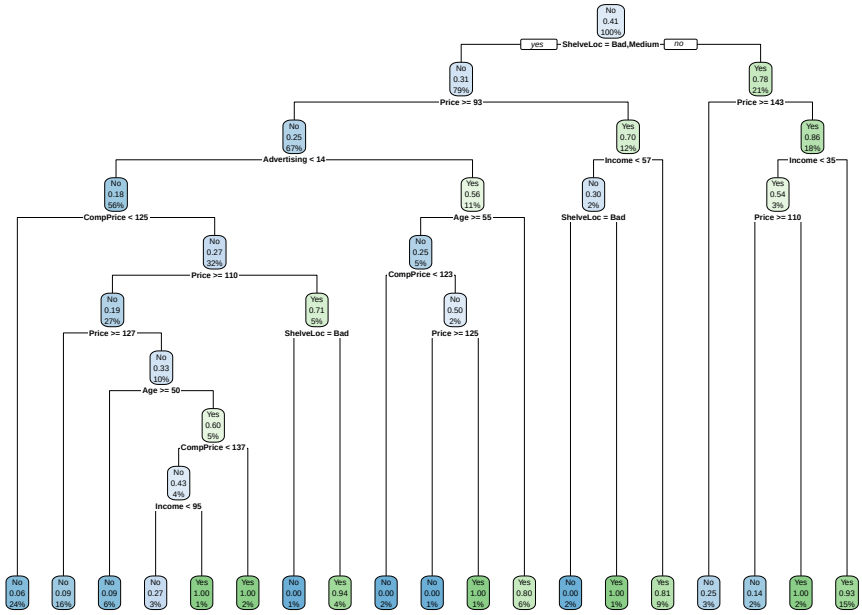

5. On considère la suite d'arbres

```
tree2 <- rpart(High~.,data=data1,
               parms=list(loss=matrix(c(0,5,1,0),ncol=2)),
               cp=0.01,minsplit=2)
```

Expliquer les sorties des commandes suivantes. On pourra notamment calculer le dernier terme de la colonne **rel error** de la table **cptable**.

```
tree2$parms
## $prior
##    1    2
## 0.59 0.41
##
## $loss
##      [,1] [,2]
## [1,]    0    1
## [2,]    5    0
##
## $split
## [1] 1
printcp(tree2)
##
## Classification tree:
## rpart(formula = High ~ ., data = data1, parms = list(loss = matrix(c(0,
##     5, 1, 0), ncol = 2)), cp = 0.01, minsplit = 2)
```

```
##
## Variables actually used in tree construction:
## [1] Advertising Age         CompPrice   Education
## [5] Income      Population  Price       ShelveLoc
##
## Root node error: 236/400 = 0.59
##
## n= 400
##
##          CP nsplit rel error xerror    xstd
## 1  0.101695      0   1.00000 5.0000 0.20840
## 2  0.050847      2   0.79661 3.7119 0.20834
## 3  0.036017      3   0.74576 3.1653 0.20197
## 4  0.035311      5   0.67373 2.9449 0.19818
## 5  0.025424      9   0.50847 2.4915 0.18872
## 6  0.016949     11   0.45763 2.3559 0.18485
## 7  0.015537     16   0.37288 2.0339 0.17491
## 8  0.014831     21   0.28814 2.0339 0.17491
## 9  0.010593     23   0.25847 1.8983 0.16982
## 10 0.010000     25   0.23729 1.8263 0.16664
```

```
prev <- predict(tree2,type="class")
conf <- table(data1$High,prev)
conf
##      prev
##        No Yes
##   No  185  51
##   Yes   1 163
loss <- tree2$parms$loss
(conf[1,2]*loss[1,2]+
    conf[2,1]*loss[2,1])/nrow(data1)/mean(data1$High=="No")
## [1] 0.2372881
```

6. Comparer les valeurs ajustées par les deux arbres considérés.

```
summary(predict(tree_sel,type="class"))
##  No Yes
## 240 160
summary(predict(tree2,type="class"))
##  No Yes
## 186 214
```

4.2.3 Calcul de la sous-suite d'arbres optimaux

Exercice 4.1 (Minimisation du critère coût/complexité)**.** On considère l'algorithme qui permet de calculer les suites $(\alpha_m)_m$ et $(T_{\alpha_m})_m$ du théorème présenté en cours. Pour simplifier on se place en classification binaire et on considère les notations suivantes (en plus de celles présentées dans le chapitre) :

- $R(t)$: erreur de classification dans le nœud t pondérée par la proportion d'individus dans le nœud (nombre d'individus dans t sue le nombre total d'individus).
- T^t : la branche de l'arbre T issue du nœud interne t.
- $R(T^t)$: l'erreur de la branche T^t pondérée par la proportion d'individus dans le nœud.

L'algorithme suivant présente le calcul explicite des suites $(\alpha_m)_m$ et $(T_{\alpha_m})_m$.

Initialisation : on pose $\alpha_0 = 0$ et on calcule l'arbre maximale T_0 qui minimise $C_0(T)$. On fixe $m = 0$. Répéter jusqu'à obtenir l'arbre racine

1. Calculer pour tous les nœuds t internes de T_{α_m}
$$g(t) = \frac{R(t) - R(T^t_{\alpha_m})}{|T^t_{\alpha_m}| - 1}$$
2. Choisir le nœud interne t_m qui minimise $g(t)$.
3. On pose
$$\alpha_{m+1} = g(t_m) \quad \text{et} \quad T_{\alpha_{m+1}} = T_{\alpha_m} - T^{t_m}_{\alpha_m}.$$
4. Mise à jour : $m := m + 1$.

Retourner : les suites finies $(\alpha_m)_m$ et $(T_{\alpha_m})_m$.

On propose d'utiliser cet algorithme sur l'arbre construit suivant

```
gen_class_bin2D <- function(n=100,graine=1234,bayes=0.1){
  set.seed(graine)
  grille <- 0.1
  X1 <- runif(n)
  X2 <- runif(n)
  Y <- rep(0,n)
  cond0 <- (X1>0.2 & X2>=0.8) | (X1>0.6 & X2<0.4) | (X1<0.25 & X2<0.5)
  cond1 <- !cond0
  Y[cond0] <- rbinom(sum(cond0),1,bayes)
  Y[cond1] <- rbinom(sum(cond1),1,1-bayes)
  donnees <- tibble(X1,X2,Y=as.factor(Y))
  px1 <- seq(0,1,by=grille)
  px2 <- seq(0,1,by=grille)
  px <- expand.grid(X1=px1,X2=px2)
  py <- rep(0,nrow(px))
  cond0 <- (px[,1]>0.2 & px[,2]>=0.8) |
```

```
    (px[,1]>0.6 & px[,2]<0.4) |
    (px[,1]<0.25 & px[,2]<0.5)
  cond1 <- !cond0
  py[cond0] <- 0
  py[cond1] <- 1
  df <- px |> as_tibble() |> mutate(Y=as.factor(py))
  p <- ggplot(df)+aes(x=X1,y=X2,fill=Y)+
    geom_raster(hjust=1,vjust=1)
  return(list(donnees=donnees,graphe=p))
}
don.2D.arbre <- gen_class_bin2D(n=150,graine=3210,bayes=0.05)$donnees
set.seed(123)
T0 <- rpart(Y~.,data=don.2D.arbre)
rpart.plot(T0,extra = 1)
```

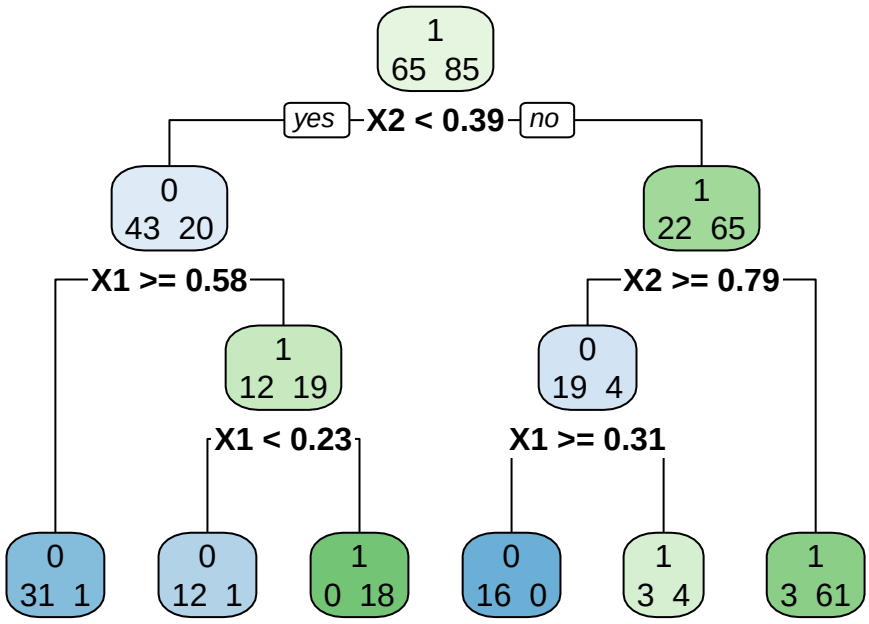

Figure 4.1: L'arbre T_0.

Cet arbre n'est pas l'arbre maximal mais la manière d'élaguer est identique.

1. Calculer pour les 5 nœuds internes de T_0 la fonction $g(t)$.
2. En déduire la valeur de α_1 ainsi que l'arbre T_{α_1}.
3. Retrouver cette valeur en utilisant la fonction `printcp` et représenter l'arbre T_1 en utilisant `prune`.

```r
printcp(T0)
##
## Classification tree:
## rpart(formula = Y ~ ., data = don.2D.arbre)
##
## Variables actually used in tree construction:
## [1] X1 X2
##
## Root node error: 65/150 = 0.43333
##
## n= 150
##
##         CP nsplit rel error  xerror     xstd
## 1 0.353846      0   1.00000 1.00000 0.093370
## 2 0.230769      1   0.64615 0.70769 0.086883
## 3 0.138462      2   0.41538 0.50769 0.078053
## 4 0.015385      4   0.13846 0.21538 0.054812
## 5 0.010000      5   0.12308 0.26154 0.059730
```

```r
T1 <- prune(T0,cp=0.015385)
rpart.plot(T1,extra = 1)
```

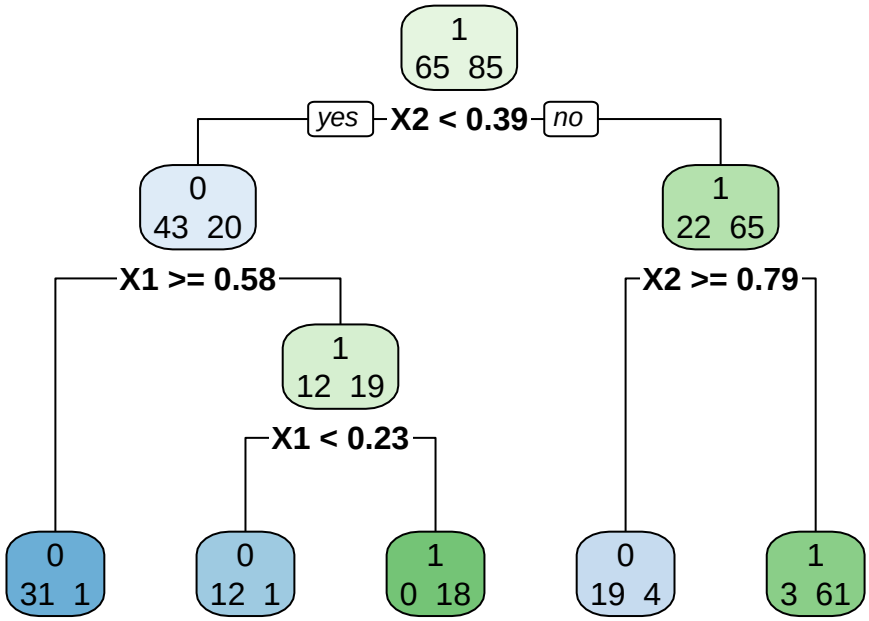

Figure 4.2: L'arbre T_{α_1}.

4. Faire le même travail pour calculer α_2 et T_{α_2}.

```r
T2 <- prune(T0,cp=0.138462)
rpart.plot(T2,extra = 1)
```

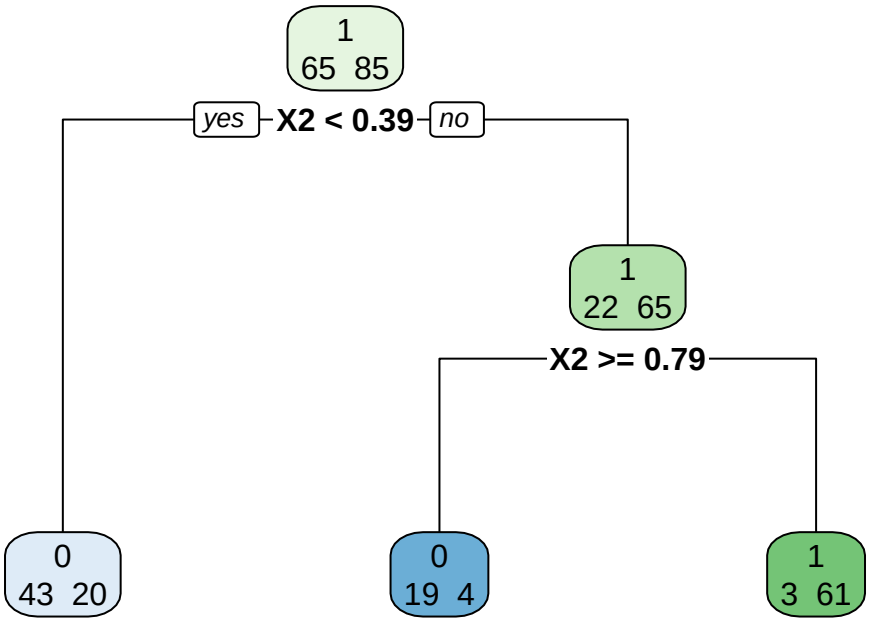

Figure 4.3: L'arbre T_{α_2}.

partie III

Agrégation

5 Forêts aléatoires

Les méthodes par arbres présentées précédemment sont des algorithmes qui possèdent tout un tas de qualités (facile à mettre en œuvre, interprétable...). Ce sont néanmoins rarement les algorithmes qui se révèlent les plus performants. Les méthodes d'agrégation d'arbres présentées dans cette partie sont souvent beaucoup plus pertinentes, notamment en terme de qualité de prédiction. Elles consistent à construire un très grand nombre d'arbres "simples" : $g_1, \ldots, g_B$ et à les agréger en faisant la moyenne :

$$\frac{1}{B}\sum_{k=1}^{B} g_k(x).$$

Les forêts aléatoires (Breiman 2001) et le gradient boosting (Friedman 2001) utilisent ce procédé d'agrégation. Dans ce chapitre on étudiera ces algorithmes sur le je de données `spam` :

```
library(kernlab)
data(spam)
set.seed(1234)
spam <- spam[sample(nrow(spam)),]
```

Le problème est d'expliquer la variable binaire **type** par les autres.

L'algorithme des forêts aléatoires consiste à construire des arbres sur des échantillons bootstrap et à les agréger. Il peut s'écrire de la façon suivante :

Entrées :

- $x \in \mathbb{R}^d$ l'observation à prévoir, $\mathcal{D}_n$ l'échantillon ;
- B nombre d'arbres ; n_{max} nombre max d'observations par nœud
- $m \in \{1, \ldots, d\}$ le nombre de variables candidates pour découper un nœud.

Algorithme : pour $k = 1, \ldots, B$:

1. Tirer un échantillon *bootstrap* dans $\mathcal{D}_n$
2. Construire un *arbre CART sur cet échantillon bootstrap*, chaque coupure est sélectionnée en minimisant la fonction de coût de CART sur un ensemble de m variables choisies au hasard parmi les d. On note $T(., \theta_k, \mathcal{D}_n)$ l'arbre construit.

Sortie : l'estimateur $T_B(x) = \frac{1}{B}\sum_{k=1}^{B} T(x, \theta_k, \mathcal{D}_n)$.

Cet algorithme peut être utilisé sur **R** avec la fonction **randomForest** du package **randomForest** ou la fonction **ranger** du package **ranger**.

Exercice 5.1 (Biais et variance des algorithmes bagging)**.** Comparer le biais et la variance de la forêt $T_B(x)$ au biais et à la variance d'un arbre de la forêt $T(x, \theta_k, \mathcal{D}_n)$. On pourra utiliser $\rho(x) = \text{corr}(T(x, \theta_1, \mathcal{D}_n), T(x, \theta_2, \mathcal{D}_n))$ pour comparer les variances.

Exercice 5.2 (RandomForest versus ranger)**.** On sépare le jeu de données `spam` en un échantillon d'apprentissage et un échantillon test :

```
set.seed(1234)
library(tidymodels)
data_split <- initial_split(spam, prop = 3/4)
spam.app <- training(data_split)
spam.test  <- testing(data_split)
```

1. Entraîner une forêt aléatoire sur les données d'apprentissage uniquement en utilisant les paramètres par défaut de la fonction **randomForest**. Commenter.

```
library(randomForest)
set.seed(123)
(foret1 <- randomForest(type~.,data=spam.app))
##
## Call:
##  randomForest(formula = type ~ ., data = spam.app)
##                Type of random forest: classification
##                      Number of trees: 500
## No. of variables tried at each split: 7
##
##         OOB estimate of  error rate: 4.72%
## Confusion matrix:
##         nonspam spam class.error
## nonspam    2023   58  0.02787122
## spam        105 1264  0.07669832
```

2. Calculer les groupes prédits pour les individus de l'échantillon test et en déduire une estimation de l'erreur de classification.

```
prev.class <- predict(foret1,newdata=spam.test)
head(prev.class)
##    4046    1685    3000    1403    1014     561
```

```
## nonspam    spam nonspam    spam    spam    spam
## Levels: nonspam spam
mean(prev.class!=spam.test$type)
## [1] 0.04952215
```

3. Calculer les estimations de la probabilité de spam pour les individus de l'échantillon test.

```
prev.prob <- predict(foret1,newdata=spam.test,type="prob")
head(prev.prob)
##      nonspam  spam
## 4046   0.780 0.220
## 1685   0.010 0.990
## 3000   0.908 0.092
## 1403   0.216 0.784
## 1014   0.028 0.972
## 561    0.054 0.946
```

4. Refaire les questions précédentes avec la fonction **ranger** du package **ranger** (voir https://arxiv.org/pdf/1508.04409.pdf).

```
library(ranger)
```

```
(foret2 <- ranger(type~.,data=spam.app))
## Ranger result
##
## Call:
##  ranger(type ~ ., data = spam.app)
##
## Type:                             Classification
## Number of trees:                  500
## Sample size:                      3450
## Number of independent variables:  57
## Mtry:                             7
## Target node size:                 1
## Variable importance mode:         none
## Splitrule:                        gini
## OOB prediction error:             4.99 %
class.ranger <- predict(foret2,data=spam.test)$predictions
head(class.ranger)
## [1] nonspam spam    nonspam spam    spam    spam
## Levels: nonspam spam
mean(class.ranger!=spam.test$type)
## [1] 0.04865334
```

```r
foret.prob <- ranger(type~.,data=spam.app,probability=TRUE)
prob.ranger <- predict(foret.prob,data=spam.test)$predictions
head(prob.ranger)
##         nonspam       spam
## [1,] 0.74964937 0.25035063
## [2,] 0.01032460 0.98967540
## [3,] 0.90508132 0.09491868
## [4,] 0.31905319 0.68094681
## [5,] 0.03715000 0.96285000
## [6,] 0.07066232 0.92933768
```

5. Comparer les temps de calcul de **randomForest** et **ranger**.

```r
system.time(randomForest(type~.,data=spam.app))
##    user  system elapsed
##   6.502   0.096   6.643
system.time(ranger(type~.,data=spam.app))
##    user  system elapsed
##   1.360   0.007   0.391
```

Exercice 5.3 (Sélection des paramètres)**.** Nous nous intéressons ici au choix des paramètres de la forêt aléatoire.

1. Expliquer la sortie suivante.

```r
set.seed(12345)
library(OOBCurve)
foret1 <- ranger(type~.,data=spam,keep.inbag=TRUE)
spam.task <- mlr::makeClassifTask(data=spam,target="type")
erreurs <- OOBCurve(foret1,measures = list(mmce, auc),
                task=spam.task,data=spam)
erreurs1 <- erreurs |> as_tibble() |> mutate(ntrees=1:500) |>
  filter(ntrees>=5) |>
  pivot_longer(-ntrees,names_to="Erreur",values_to="valeur")
ggplot(erreurs1)+aes(x=ntrees,y=valeur)+geom_line()+
  facet_wrap(~Erreur,scales="free")
```

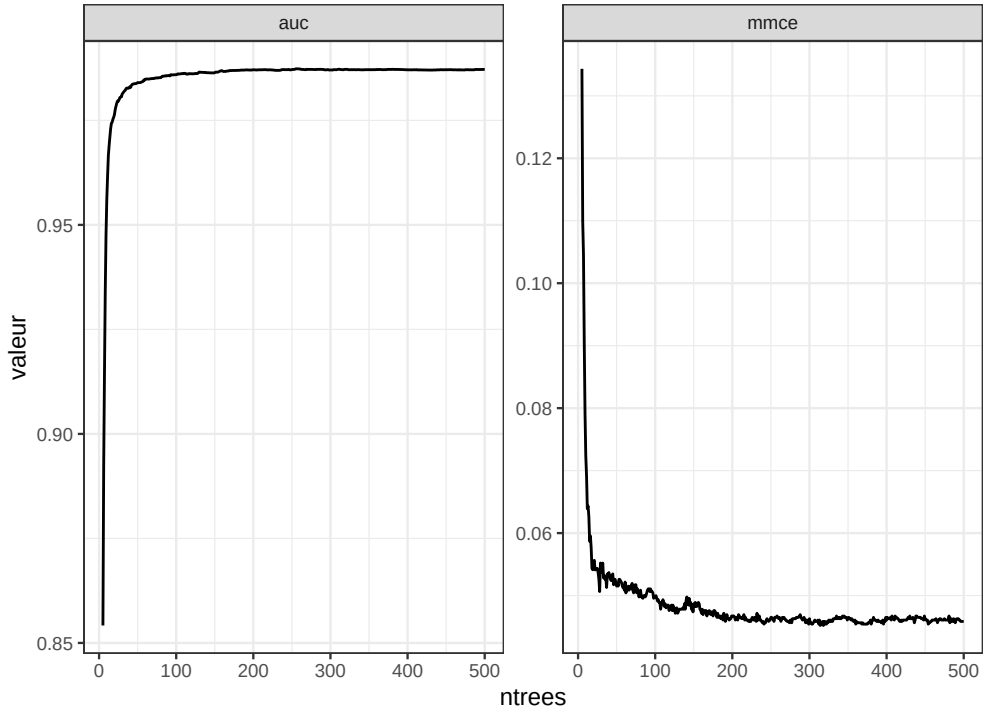

2. Construire la forêt avec `mtry=1` et comparer ses performances avec celle construite précédemment.

```
set.seed(321)
foret2 <- ranger(type~.,data=spam,mtry=1)
foret1
## Ranger result
##
## Call:
##  ranger(type ~ ., data = spam, keep.inbag = TRUE)
##
## Type:                             Classification
## Number of trees:                  500
## Sample size:                      4601
## Number of independent variables:  57
## Mtry:                             7
## Target node size:                 1
## Variable importance mode:         none
## Splitrule:                        gini
## OOB prediction error:             4.59 %
foret2
## Ranger result
##
```

```
## Call:
##  ranger(type ~ ., data = spam, mtry = 1)
##
## Type:                             Classification
## Number of trees:                  500
## Sample size:                      4601
## Number of independent variables:  57
## Mtry:                             1
## Target node size:                 1
## Variable importance mode:         none
## Splitrule:                        gini
## OOB prediction error:             8.09 %
```

3. A l'aide des outils `tidymodels` sélectionner les paramètres `mtry` et `min_n` dans les grilles `c(1,6,seq(10,50,by=10),57)` et `c(1,5,100,500)`. On pourra notamment visualiser les critères en fonction des valeurs de paramètres.

```
rf_grid <- expand.grid(mtry=c(1,6,seq(10,50,by=10),57),
                   min_n=c(1,5,100,500))
```

```
set.seed(1234)
blocs <- vfold_cv(spam, v = 10)
tune_spec <- rand_forest(mtry = tune(),min_n= tune()) |>
  set_engine("ranger") |>
  set_mode("classification")
rf_wf <- workflow() |> add_model(tune_spec) |> add_formula(type ~ .)
```

```
cl <- makePSOCKcluster(4)
registerDoParallel(cl)
rf_res <- rf_wf |> tune_grid(resamples = blocs,grid = rf_grid)
on.exit(stopCluster(cl))
```

```
rf_res |> show_best("roc_auc")
## # A tibble: 5 x 8
##    mtry min_n .metric .estimator  mean     n std_err .config
##   <dbl> <dbl> <chr>   <chr>      <dbl> <int>   <dbl> <chr>
## 1     6     1 roc_auc binary     0.988    10 0.00157 Prepro~
## 2     6     5 roc_auc binary     0.988    10 0.00168 Prepro~
## 3    10     1 roc_auc binary     0.987    10 0.00188 Prepro~
## 4    10     5 roc_auc binary     0.987    10 0.00178 Prepro~
## 5    20     1 roc_auc binary     0.985    10 0.00195 Prepro~
rf_res |> show_best("accuracy")
## # A tibble: 5 x 8
```

```
##    mtry min_n .metric  .estima~1  mean     n std_err .config
##   <dbl> <dbl> <chr>    <chr>     <dbl> <int>   <dbl> <chr>
## 1     6     1 accuracy binary    0.955    10 0.00296 Prepro~
## 2    10     1 accuracy binary    0.954    10 0.00320 Prepro~
## 3     6     5 accuracy binary    0.953    10 0.00330 Prepro~
## 4    10     5 accuracy binary    0.953    10 0.00337 Prepro~
## 5    20     1 accuracy binary    0.953    10 0.00364 Prepro~
## # ... with abbreviated variable name 1: .estimator
```

```
rf_res |> collect_metrics() |> filter(.metric=="accuracy") |>
  mutate(min_n=as.factor(min_n),err_classif=1-mean) |>
  ggplot()+aes(x=mtry,y=err_classif,color=min_n)+geom_line()+
  geom_pointrange((aes(ymin=err_classif-std_err,
                       ymax=err_classif+std_err)))
```

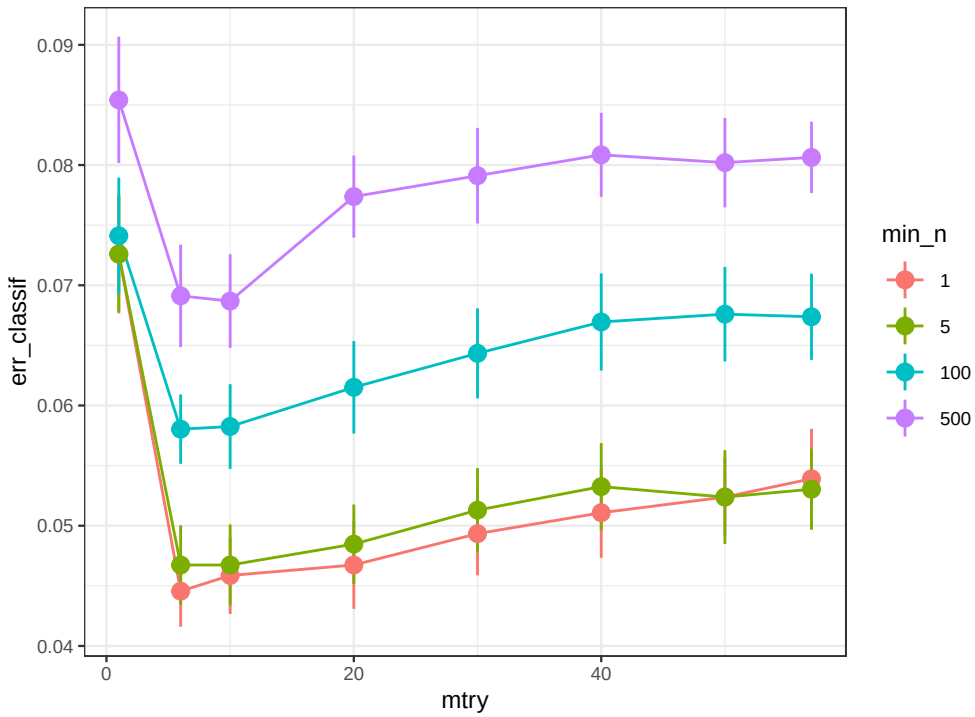


```
rf_res |> collect_metrics() |> filter(.metric=="roc_auc") |>
  mutate(min_n=as.factor(min_n),auc=mean) |>
  ggplot()+aes(x=mtry,y=auc,color=min_n)+geom_line()+
  geom_pointrange((aes(ymin=mean-std_err,ymax=mean+std_err)))
```

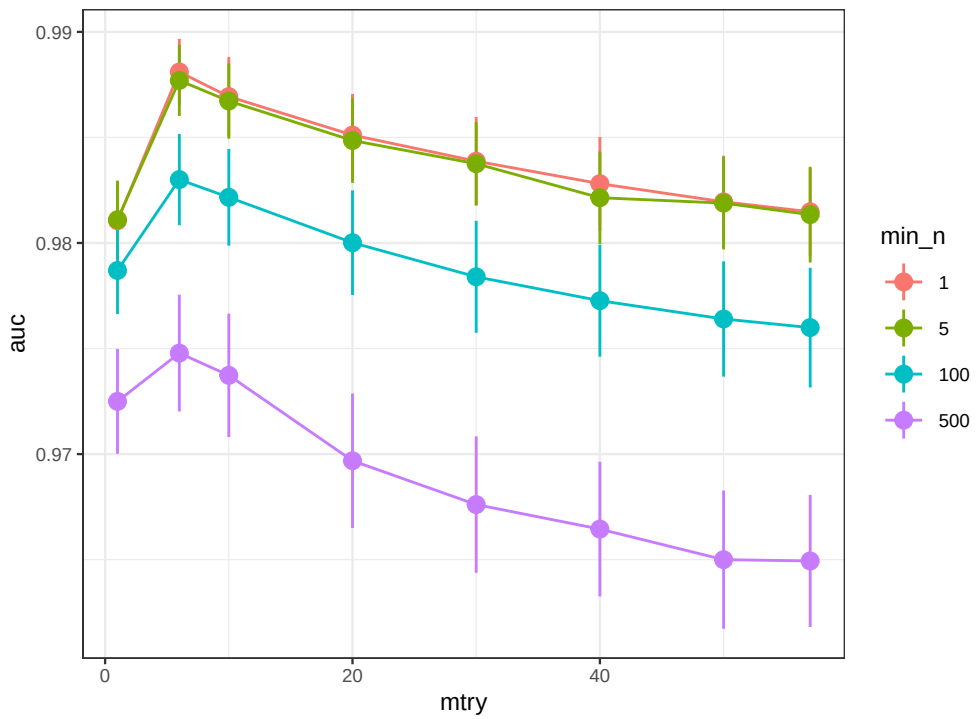


```
foret_finale <- rf_wf |>
  finalize_workflow(list(mtry=7,min_n=1)) |>
  fit(data=spam)
```

4. Visualiser l'importance des variables pour les scores d'impureté et de permutations.

```
set.seed(1234)
foret.imp <- ranger(type~.,data=spam,importance="impurity")
foret.perm <- ranger(type~.,data=spam,importance="permutation")
vip::vip(foret.imp)
```

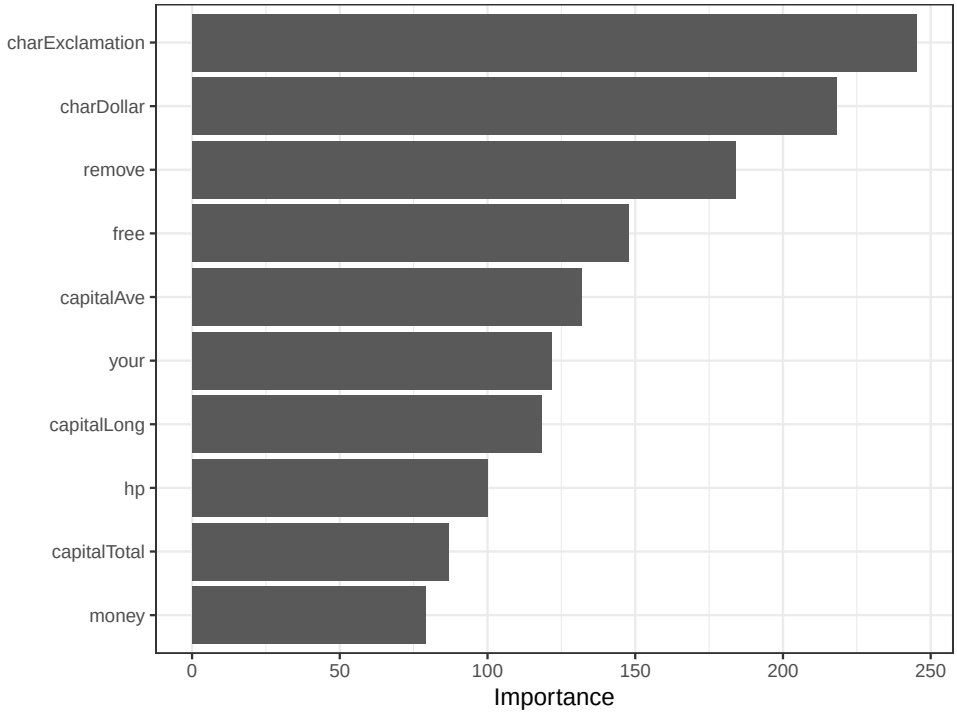


```
vip::vip(foret.perm)
```

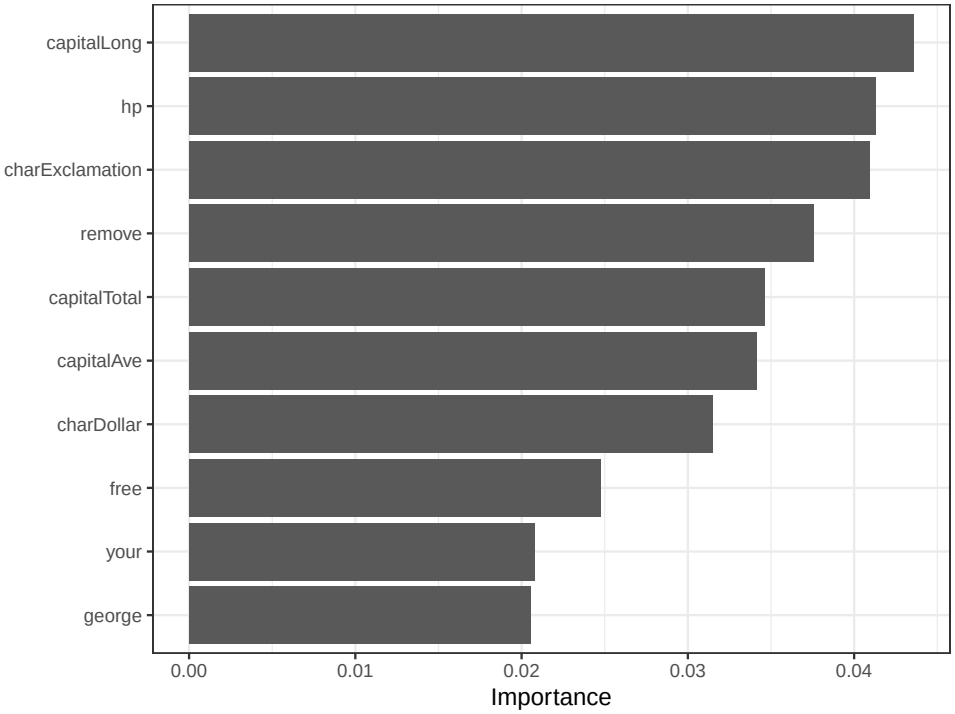

Exercice 5.4 (Arbre vs forêt aléatoire)**.** Proposer et mettre en œuvre une procédure permettant de comparer les performances (courbes ROC, AUC et accuracy) d'un arbre CART utilisant la procédure d'élagage proposée dans la Section 4.2 avec une forêt aléatoire.

```
set.seed(123)
blocs <- vfold_cv(spam, v = 10)
```

```
prev.arbre <- function(df,newX){
  arbre <- rpart(type~.,data=df,cp=1e-8,minsplit=15)
  cp_opt <- arbre$cptable |> as.data.frame() |>
    filter(xerror==min(xerror)) |>
    dplyr::select(CP) |> slice(1) |> as.numeric()
  arbre.opt <- prune(arbre,cp=cp_opt)
  predict(arbre,newdata=newX,type="prob")[,2]
}
```

```
prev.foret <- function(df,grille.mtry=c(seq(1,55,by=5),57),newX){
  err <- rep(0,length(grille.mtry))
  for (m in 1:length(grille.mtry)){
```

```
    err[m] <- ranger(type~.,data=df)$prediction.error
  }
  foret <- ranger(type~.,data=df,probability=TRUE,
                  mtry=grille.mtry[which.min(err)])
  predict(foret,data=newX,type="response")$predictions[,2]
}
```

```
set.seed(321)
score <- as_tibble(matrix(0,nrow=nrow(spam),ncol=2))
names(score) <- c("arbre","foret")
for (k in 1:10){
  k
  ind.app <- blocs$splits[[k]]$in_id
  dapp <- spam[ind.app,]
  dtest <- spam[-ind.app,]
  score[-ind.app,1] <- prev.arbre(df=dapp,newX = dtest)
  score[-ind.app,2] <- prev.foret(df=dapp,newX = dtest)
}
score1 <- score |> mutate(obs=spam$type) |>
  pivot_longer(-obs,names_to = "Methode",values_to = "Prob") |>
  mutate(class=recode_factor(as.numeric(Prob>0.5),
                             `0`="nonspam",`1`="spam"))
```

```
score1 |> group_by(Methode) |>
  roc_curve(obs,Prob,event_level="second") |> autoplot()
```

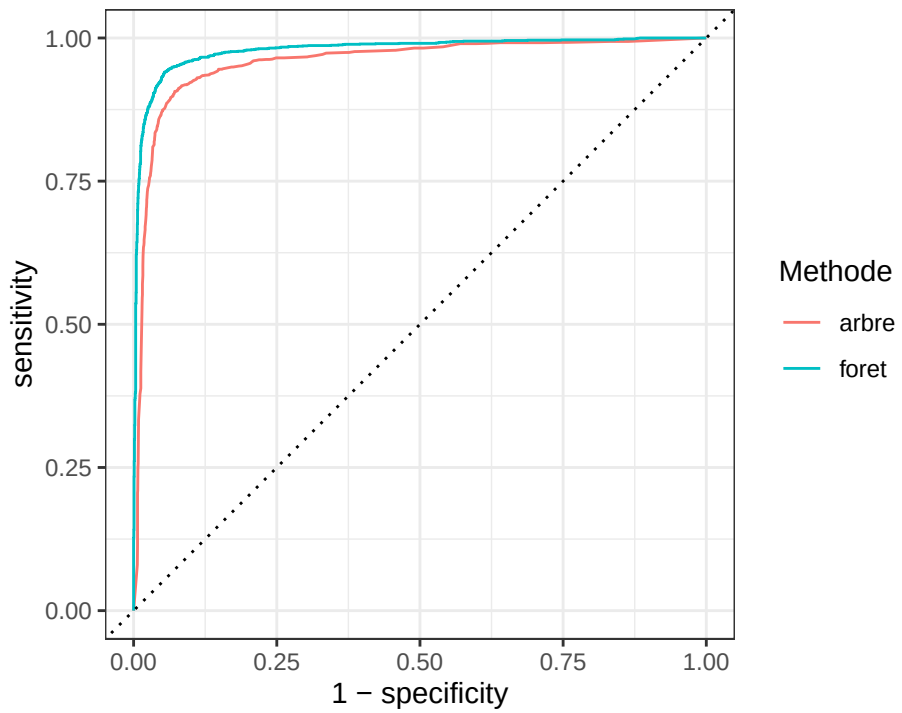


```
score1 |> group_by(Methode) |> roc_auc(obs,Prob,event_level="second")
## # A tibble: 2 x 4
##   Methode .metric .estimator .estimate
##   <chr>   <chr>   <chr>          <dbl>
## 1 arbre   roc_auc binary         0.958
## 2 foret   roc_auc binary         0.979
```

```
score1 |> group_by(Methode) |> accuracy(obs,class)
## # A tibble: 2 x 4
##   Methode .metric  .estimator .estimate
##   <chr>   <chr>    <chr>          <dbl>
## 1 arbre   accuracy binary         0.919
## 2 foret   accuracy binary         0.939
```

6 Gradient boosting

Les algorithmes de gradient boosting permettent de minimiser des pertes empiriques de la forme

$$\frac{1}{n}\sum_{i=1}^{n}\ell(y_i, f(x_i)).$$

où $\ell : \mathbb{R}\times\mathbb{R}\to\mathbb{R}$ est une fonction de coût convexe en son second argument. Il existe plusieurs type d'algorithmes boosting. Un des plus connus et utilisés a été proposé par Friedman (2001), c'est la version que nous étudions dans cette partie.

Cette approche propose de chercher la meilleure combinaison linéaire d'arbres binaires, c'est-à-dire que l'on recherche $g(x) = \sum_{m=1}^{M}\alpha_m h_m(x)$ qui minimise

$$\mathcal{R}_n(g) = \frac{1}{n}\sum_{i=1}^{n}\ell(y_i, g(x_i)).$$

Optimiser sur toutes les combinaisons d'arbres binaires se révélant souvent trop compliqué, Friedman (2001) utilise une descente de gradient pour construire la combinaison d'arbres de façon récursive. L'algorithme est le suivant :

Entrées :

- $d_n = (x_1, y_1), \dots, (x_n, y_n)$ l'échantillon, λ un paramètre de régularisation tel que $0 < \lambda \leq 1$.
- $M \in \mathbb{N}$ le nombre d'itérations.
- paramètres de l'arbre (nombre de coupures...)

Itérations :

1. Initialisation : $g_0(.) = \text{argmin}_c \frac{1}{n}\sum_{i=1}^{n}\ell(y_i, c)$
2. Pour $m = 1$ à M :
   a. Calculer l'opposé du gradient $-\frac{\partial}{\partial g(x_i)}\ell(y_i, g(x_i))$ et l'évaluer aux points $g_{m-1}(x_i)$:
   $$U_i = -\frac{\partial}{\partial g(x_i)}\ell(y_i, g(x_i))\Big|_{g(x_i)=g_{m-1}(x_i)}, \quad i = 1, \dots, n.$$
   b. Ajuster un arbre sur l'échantillon $(x_1, U_1), \dots, (x_n, U_n)$, on le note h_m.
   c. Mise à jour : $g_m(x) = g_{m-1}(x) + \lambda h_m(x)$.

Sortie : la suite $(g_m(x))_m$.

Sur **R** On peut utiliser différents packages pour faire du gradient boosting. Nous utilisons ici le package **gbm** (Ridgeway 2006).

6.1 Un exemple simple en régression

On considère un jeu de données $(x_i, y_i), i = 1, \ldots, 200$ issu d'un modèle de régression

$$y_i = m(x_i) + \varepsilon_i$$

où la vraie fonction de régression est la fonction **sinus** (mais on va faire comme si on ne le savait pas).

```
x <- seq(-2*pi,2*pi,by=0.01)
y <- sin(x)
set.seed(1234)
X <- runif(200,-2*pi,2*pi)
Y <- sin(X)+rnorm(200,sd=0.2)
df1 <- data.frame(X,Y)
df2 <- data.frame(X=x,Y=y)
p1 <- ggplot(df1)+aes(x=X,y=Y)+geom_point()+
  geom_line(data=df2,linewidth=1)+xlab("")+ylab("")
p1
```

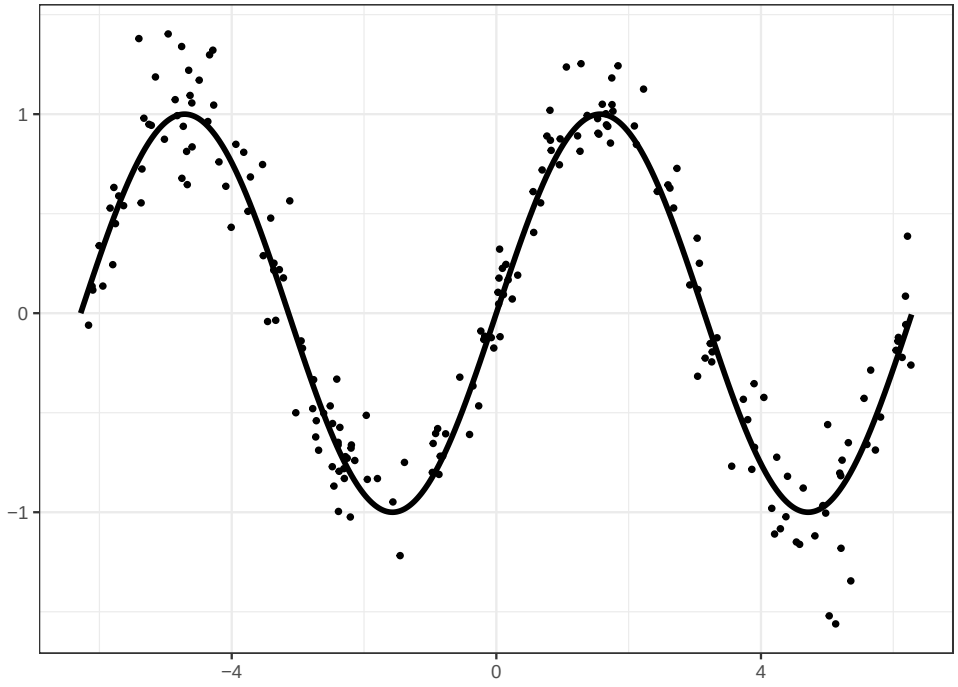

1. Rappeler ce que siginifie le L_2-boosting.
2. A l'aide de la fonction **gbm** du package **gbm** construire un algorithme de L_2-boosting. On utilisera 500000 itérations et gardera les autres valeurs par défaut de paramètres, à l'exception de `bag.fraction` qu'on prendra égal à 1.

```
library(gbm)
L2boost <- gbm(Y~.,data=df1,n.trees = 500000,
               distribution="gaussian",bag.fraction = 1)
```

3. Visualiser l'estimateur à la première itération. On pourra faire un **predict** avec l'option `n.trees` ou utiliser directement la fonction **plot.gbm** avec l'option `n.trees`.

```
prev1 <- predict(L2boost,newdata=df2,n.trees=1)
df3 <- df2 |> rename(vraie=Y) |> mutate(`M=1`=prev1)
df4 <- df3 |> pivot_longer(-X,names_to="courbes",values_to="prev")
ggplot(df4)+aes(x=X,y=prev,color=courbes)+geom_line(size=1)
```

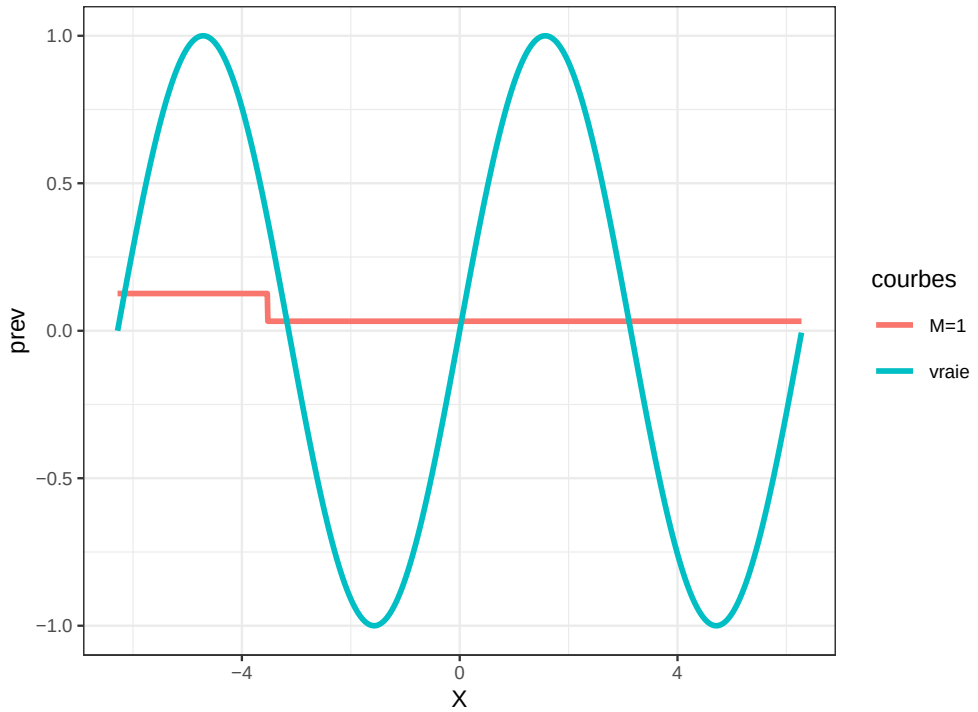


```
plot(L2boost,n.trees=1)
```

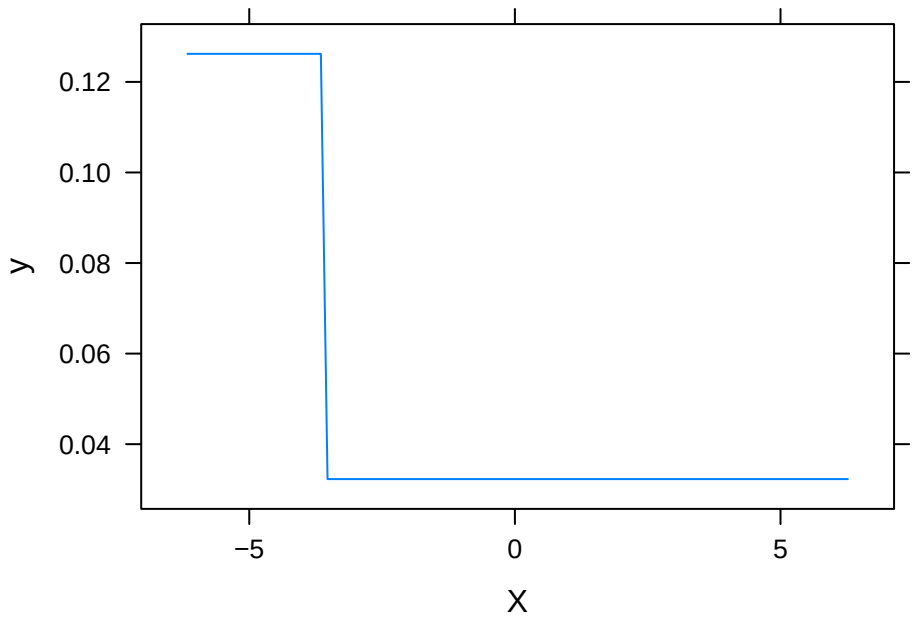

4. Faire de même pour les itérations 1000 et 500000.

```
prev1000 <- predict(L2boost,newdata=df2,n.trees=1000)
prev500000 <- predict(L2boost,newdata=df2,n.trees=500000)
df31 <- df3 |> mutate(`M=1000`=prev1000,`M=500000`=prev500000)
df41 <- df31 |> pivot_longer(-X,names_to="courbes",values_to="prev")
ggplot(df41)+aes(x=X,y=prev,color=courbes)+geom_line(size=1)
```

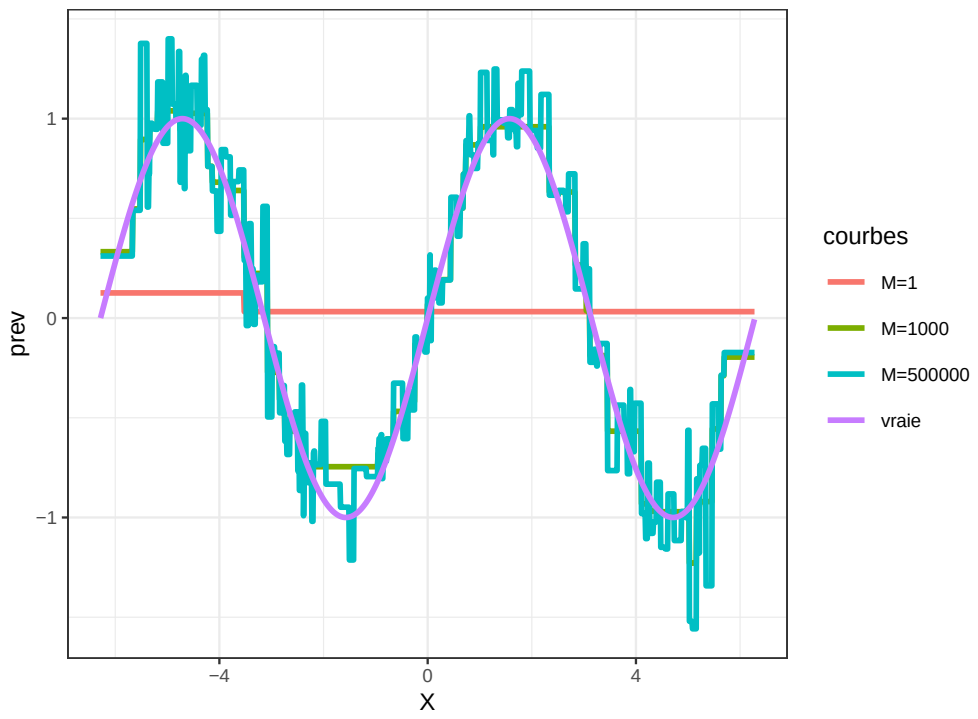

5. Sélectionner le nombre d'itérations par la procédure de votre choix.

```
#parallel:::setDefaultClusterOptions(setup_strategy = "sequential")
L2boost.sel <- gbm(Y~.,data=df1,n.trees = 10000,distribution="gaussian",
                   bag.fraction = 1,train.fraction=0.75)
iter_opt <- gbm.perf(L2boost.sel)
```

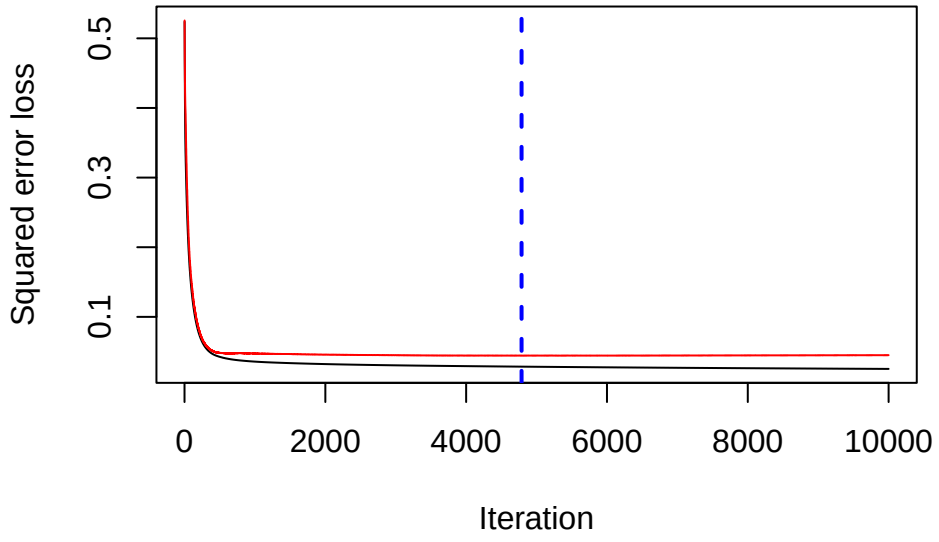

6. Représenter l'estimateur sélectionné.

```
prev_opt <- predict(L2boost.sel,newdata=df2,n.trees=iter_opt)
df5 <- df2 |> rename(vraie=Y) |> mutate(Mopt=prev_opt)
df51 <- df5 |> pivot_longer(-X,names_to="courbes",values_to="prev")
ggplot(df51)+aes(x=X,y=prev,color=courbes)+geom_line(size=1)
```

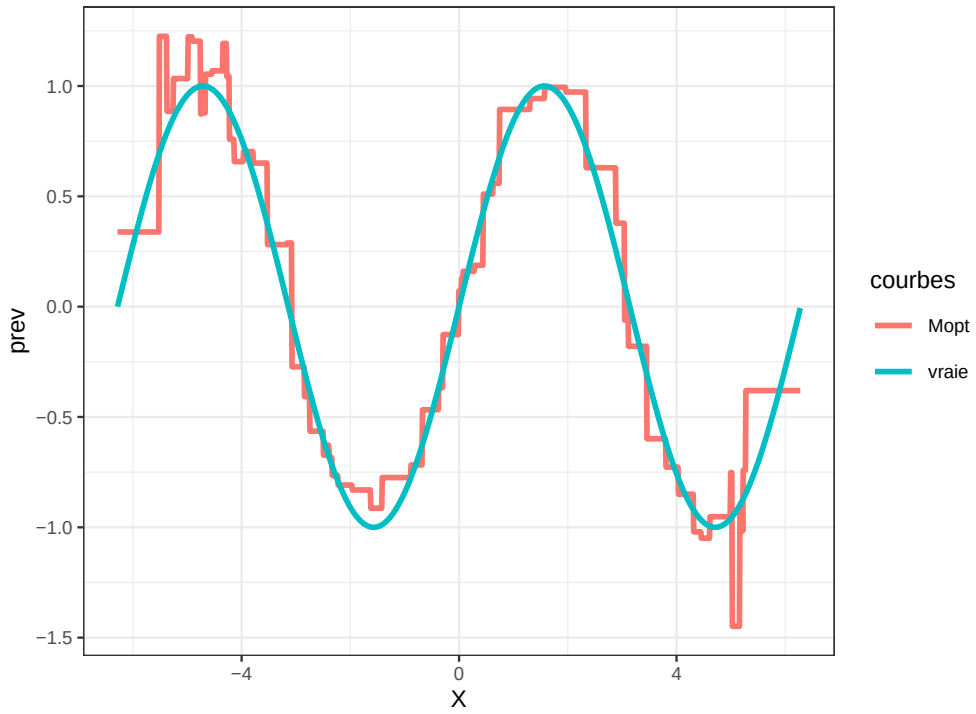

6.2 Adaboost et logitboost pour la classification binaire.

On considère le jeu de données **spam** du package **kernlab**.

```
library(kernlab)
data(spam)
set.seed(1234)
spam <- spam[sample(nrow(spam)),]
```

1. Exécuter la commande et commenter la sortie.

```
model_ada1 <- gbm(type~.,data=spam,distribution="adaboost",
                  interaction.depth=2,
```

```
                    shrinkage=0.05,n.trees=500)
```

```
model_ada1 <- gbm(type~.,data=spam,distribution="adaboost",
                    interaction.depth=2,
                    shrinkage=0.05,n.trees=500)
## Error in gbm.fit(x = x, y = y, offset = offset, distribution = distribution, : This versio
```

2. Proposer une correction permettant de faire fonctionner l'algorithme.

```
spam1 <- spam
spam1$type <- as.numeric(spam1$type)-1
set.seed(1234)
model_ada1 <- gbm(type~.,data=spam1,distribution="adaboost",
                    interaction.depth=2,
                    shrinkage=0.05,n.trees=500)
```

3. Expliciter le modèle ajusté par la commande précédente.
4. Effectuer un **summary** du modèle ajusté. Expliquer la sortie.

```
summary(model_ada1)
```

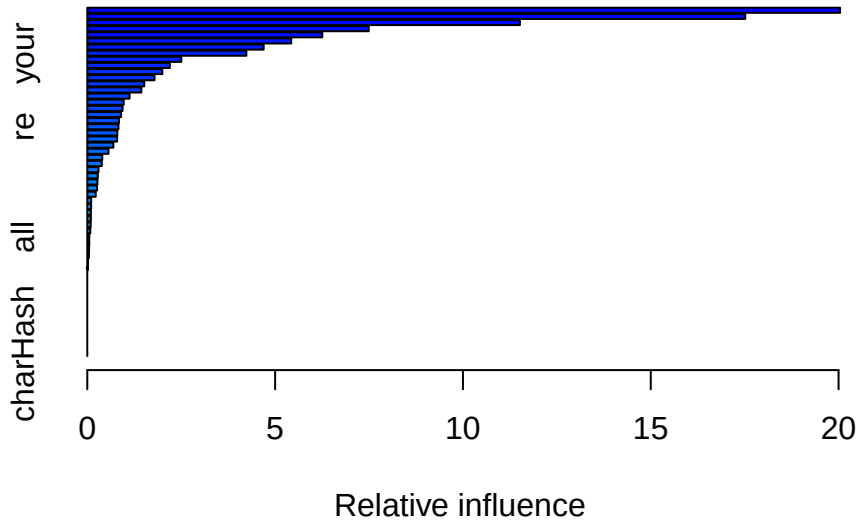


```
##                                var     rel.inf
## charExclamation     charExclamation 20.04035224
## charDollar               charDollar 17.51535261
## remove                       remove 11.51692621
## free                           free  7.49397637
```

```
## hp                              hp  6.25654932
## capitalLong             capitalLong  5.42905223
## capitalAve               capitalAve  4.69521299
## your                           your  4.23371585
## george                       george  2.50300727
## edu                             edu  2.19692796
## our                             our  1.99655393
## money                         money  1.79063219
## email                         email  1.51773292
## capitalTotal           capitalTotal  1.43872496
## internet                   internet  1.12579132
## receive                     receive  0.97001932
## will                           will  0.94015881
## you                             you  0.89915372
## business                   business  0.84418397
## re                               re  0.82959153
## num1999                     num1999  0.80016393
## num650                       num650  0.79468746
## meeting                     meeting  0.69494729
## num000                       num000  0.56448978
## charRoundbracket   charRoundbracket  0.39921437
## report                       report  0.38621968
## charSemicolon         charSemicolon  0.29835251
## credit                       credit  0.27841575
## over                           over  0.27064075
## order                         order  0.26017226
## mail                           mail  0.22398163
## technology               technology  0.10340435
## hpl                             hpl  0.10151723
## original                   original  0.09615196
## font                           font  0.09539134
## make                           make  0.08995855
## project                     project  0.07970985
## all                             all  0.05392468
## people                       people  0.05359692
## address                     address  0.04690996
## parts                         parts  0.04260362
## conference               conference  0.02037549
## num85                         num85  0.01155488
## num3d                         num3d  0.00000000
## addresses                 addresses  0.00000000
## lab                             lab  0.00000000
## labs                           labs  0.00000000
```

```
## telnet                          telnet  0.00000000
## num857                          num857  0.00000000
## data                              data  0.00000000
## num415                          num415  0.00000000
## pm                                  pm  0.00000000
## direct                          direct  0.00000000
## cs                                  cs  0.00000000
## table                            table  0.00000000
## charSquarebracket charSquarebracket  0.00000000
## charHash                      charHash  0.00000000
```

5. Utiliser la fonction **vip** du package **vip** pour retrouver ce sorties.

```
library(vip)
vip(model_ada1,num_features = 20L)
```

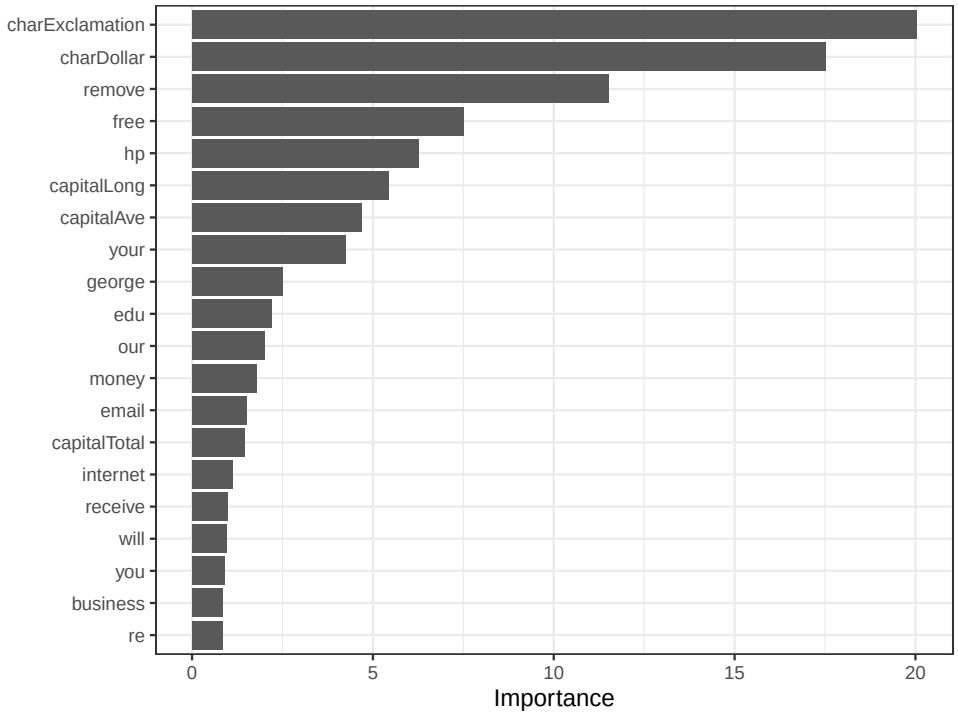

6. Sélectionner le nombre d'itérations pour l'algorithme adaboost en faisant une validation croisée 5 blocs.

```
model_ada2 <- gbm(type~.,data=spam1,distribution="adaboost",
                  interaction.depth=2,bag.fraction=1,
```

```
                    cv.folds = 5,n.trees=500)
gbm.perf(model_ada2)
```

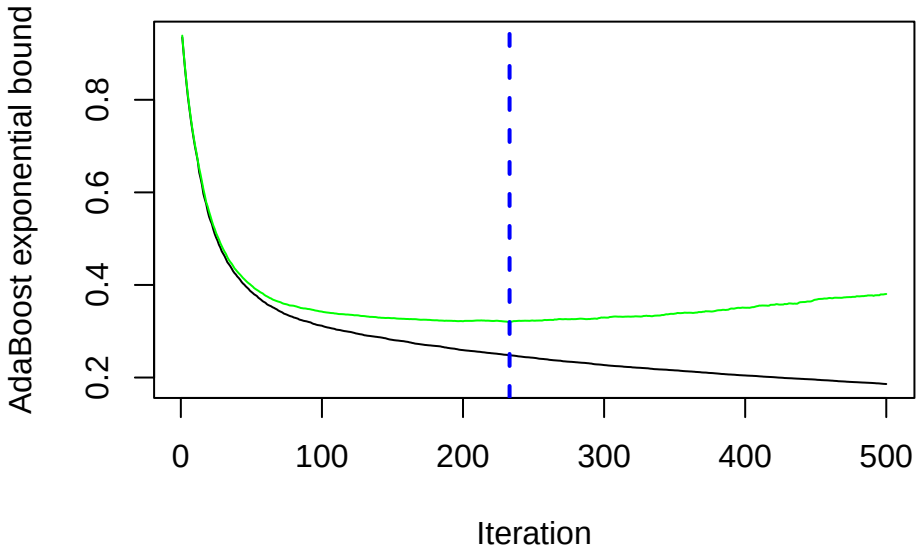


```
## [1] 233
```

7. Pour l'estimateur sélectionné, calculer la prévision (label et probabilité d'être un spam) de l'individu suivant :

```
xnew <- spam[1000,-58]
```

```
predict(model_ada2,newdata=xnew,type="response")
## [1] 0.0007065154
```

8. Faire la même procédure en changeant la valeur du paramètre **shrinkage** (par exemple 0.05 et 0.5). Interpréter.

```
model_ada3 <- gbm(type~.,data=spam1,distribution="adaboost",
                    interaction.depth=2,bag.fraction=1,
                    cv.folds = 5,n.trees=500,shrinkage=0.05)
gbm.perf(model_ada3)
```

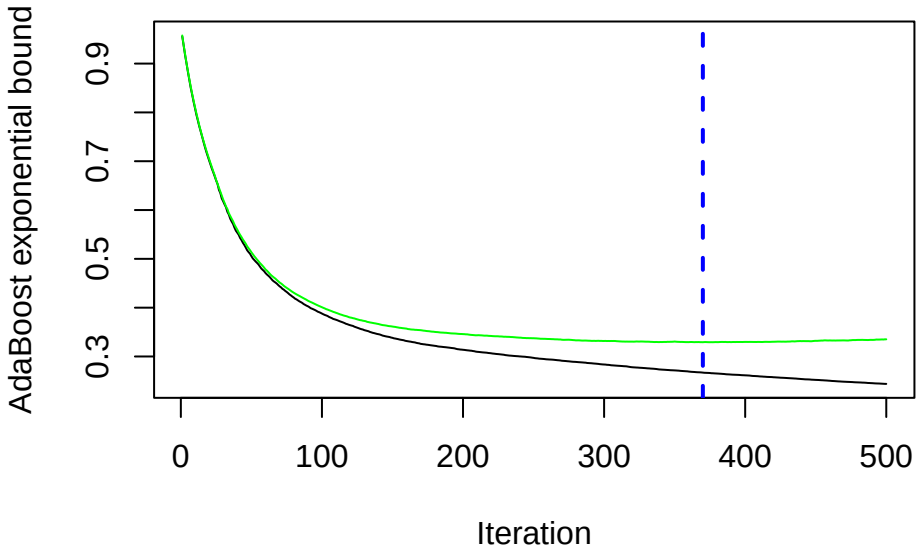


```
## [1] 370
```

```
model_ada4 <- gbm(type~.,data=spam1,distribution="adaboost",
                  interaction.depth=2,bag.fraction=1,
                  cv.folds = 5,n.trees=500,shrinkage=0.5)
gbm.perf(model_ada4)
```

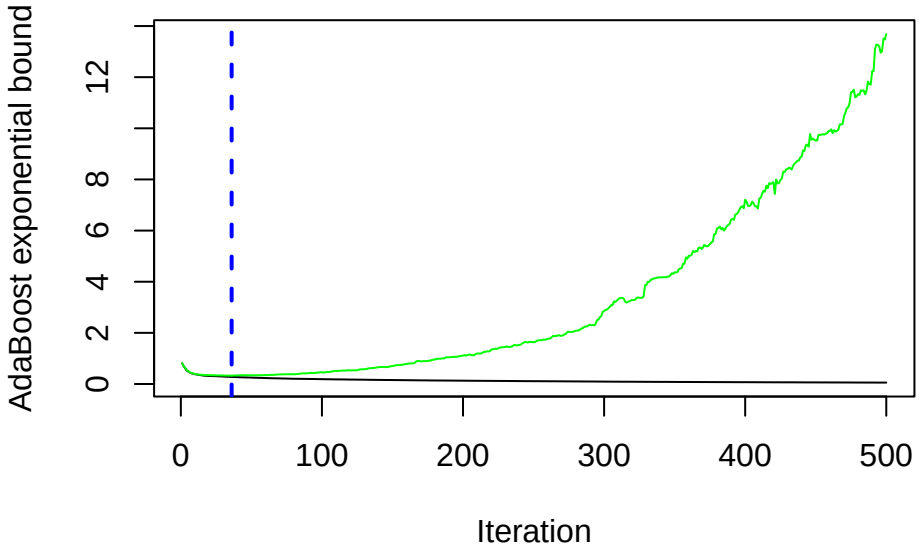


```
## [1] 36
```

9. Expliquer la différence entre **adaboost** et **logitboost** et précisez comment on peut mettre en œuvre ce dernier algorithme.

```
set.seed(4321)
logitboost <- gbm(type~.,data=spam1,distribution="bernoulli",
                  interaction.depth=2,
                  bag.fraction=1,cv.folds = 5,
                  n.trees=500,shrinkage=0.4)
gbm.perf(logitboost)
```

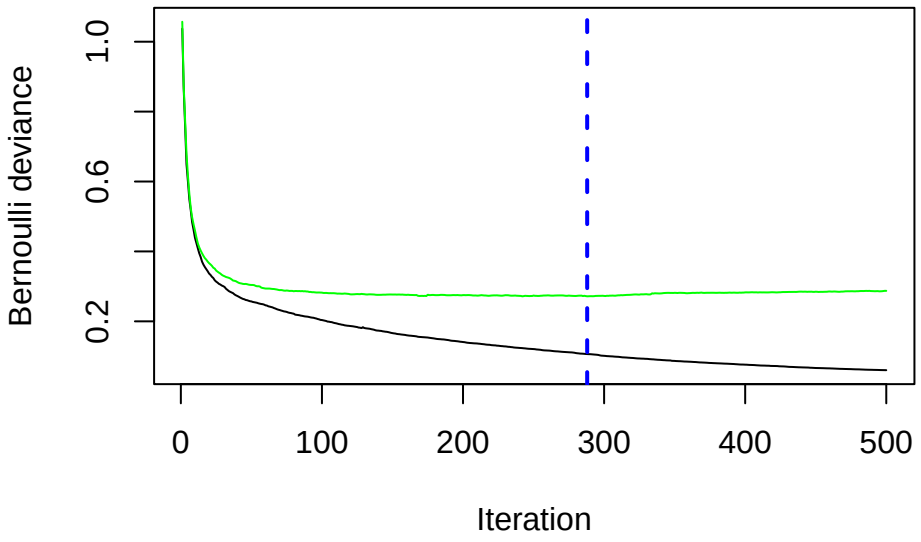


```
## [1] 288
```

6.3 Comparaison de méthodes

On reprend les données `spam` de l'exercice précédent et on les coupe en un échantillon d'apprentissage pour entraîner les algorithmes et un échantillon test pour les comparer :

```
set.seed(1234)
perm <- sample(1:nrow(spam))
app <- spam[perm[1:3000],]
test <- spam[-perm[1:3000],]
```

1. Sur les données d'apprentissage uniquement, entraîner
   - l'algorithme **adaboost** en sélectionnant le nombre d'itérations par validation croisée
   - l'algorithme **logitboost** en sélectionnant le nombre d'itérations par validation croisée
   - une **forêt aléatoire** avec les paramètres par défaut

- un **arbre CART**

```
set.seed(4321)
app1 <- app |> mutate(type=as.numeric(type)-1)
model_ada <- gbm(type~.,data=app1,distribution="adaboost",
                 interaction.depth=3,bag.fraction=1,
                 shrinkage = 0.05,
                 cv.folds = 5,n.trees=500)
nb_ada <- gbm.perf(model_ada)
```

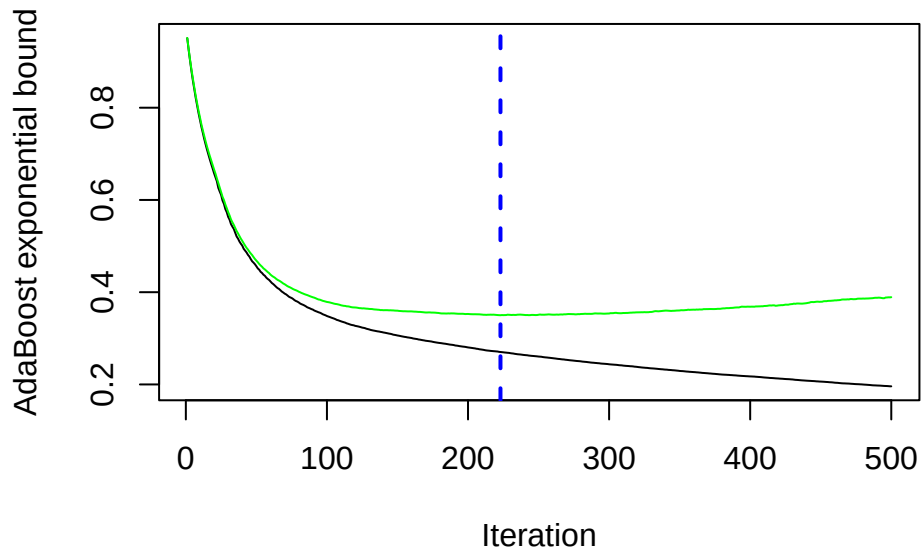


```
set.seed(5432)
model_logit <- gbm(type~.,data=app1,distribution="bernoulli",
                   interaction.depth=3,bag.fraction=1,
                   cv.folds = 5,n.trees=800)
nb_logit <- gbm.perf(model_logit)
```

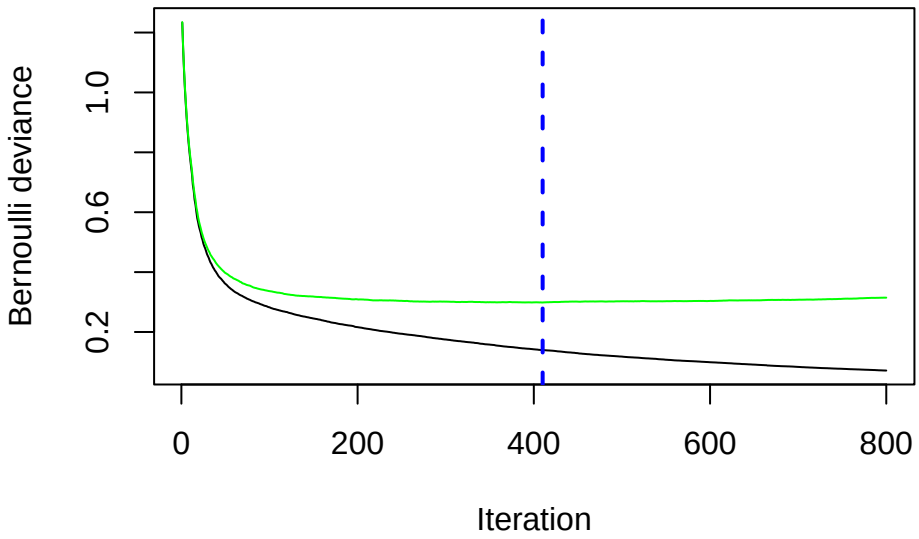


```
library(ranger)
foret <- ranger(type~.,data=app,probability=TRUE)
library(rpart)
arbre <- rpart(type~.,data=app,cp=1e-8,minsplit=2)
cp_opt <- arbre$cptable |> as.data.frame() |>
    filter(xerror==min(xerror)) |> dplyr::select(CP) |>
    dplyr::slice(1) |> as.numeric()
arbre.opt <- prune(arbre,cp=cp_opt)
```

2. Pour les 4 algorithmes, calculer, pour tous les individus de l'échantillon `test`, la probabilité que ce soit un spam. On pourra stocker toutes ces probabilités dans un même `tibble`.

```
prob <- tibble(ada=predict(model_ada,newdata=test,n.trees=nb_ada,
                           type="response"),
               logit=predict(model_logit,newdata=test,n.trees=nb_logit,
                             type="response"),
               foret=predict(foret,data=test)$prediction[,2],
               arbre=predict(arbre.opt,newdata=test)[,2],
               obs=test$type)
```

3. Comparer les 3 algorithmes avec la courbe ROC, l'AUC et l'erreur de classification.

```
library(tidymodels)
prob1 <- prob |> pivot_longer(-obs,names_to="Methode",
                              values_to="score")
prob1 |> group_by(Methode) |>
  roc_curve(truth=obs,estimate=score,event_level="second") |>
```

```
  autoplot()
```

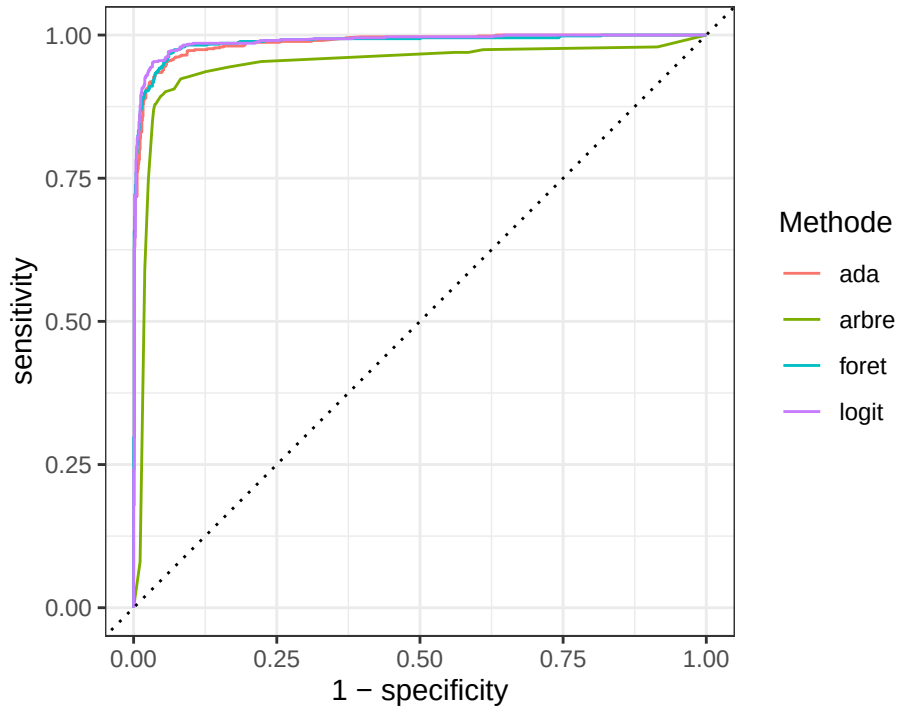


```
prob1 |> group_by(Methode) |>
  roc_auc(truth=obs,estimate=score,event_level="second") |>
  arrange(desc(.estimate))
## # A tibble: 4 x 4
##   Methode .metric .estimator .estimate
##   <chr>   <chr>   <chr>          <dbl>
## 1 logit   roc_auc binary         0.989
## 2 foret   roc_auc binary         0.987
## 3 ada     roc_auc binary         0.986
## 4 arbre   roc_auc binary         0.944
```

```
prob1 |> mutate(class=recode(round(score),
                             `0`="nonspam",`1`="spam")) |>
  group_by(Methode) |> summarize(err=mean(class!=obs)) |>
  arrange(err)
## # A tibble: 4 x 2
##   Methode    err
##   <chr>    <dbl>
## 1 logit   0.0412
## 2 ada     0.0525
```

```
## 3 foret   0.0525
## 4 arbre   0.0750
```

4. Comment aurait-on pu faire pour obtenir des résultats plus précis ?

```
set.seed(1234)
bloc <- sample(1:10,nrow(spam),replace=TRUE)
table(bloc)
## bloc
##   1   2   3   4   5   6   7   8   9  10
## 438 455 449 439 496 471 442 472 470 469
```

```
library(rpart)
set.seed(5678)
spam1 <- spam |> mutate(type=as.numeric(type)-1)
score <- matrix(0,nrow=nrow(spam),ncol=4) |> as_tibble()
names(score) <- c("arbre","ada","logit","foret")
for (k in 1:10){
  #print(k)
  ind.test <- bloc==k
  dapp <- spam1[!ind.test,]
  dtest <- spam1[ind.test,]
  dapp2 <- spam[!ind.test,]
  dtest2 <- spam[ind.test,]
  arbre <- rpart(type~.,data=dapp2,cp=1e-8,minsplit=2)
  cp_opt <- arbre$cptable |> as.data.frame() |>
    filter(xerror==min(xerror)) |> dplyr::select(CP) |>
    slice(1) |> as.numeric()
  arbre.opt <- prune(arbre,cp=cp_opt)
  ada <- gbm(type~.,data=dapp,distribution="adaboost",
             interaction.depth=3,bag.fraction=1,
             shrinkage = 0.05,
             cv.folds = 5,n.trees=500)
  nb_ada <- gbm.perf(ada,plot.it=FALSE)
  logit <- gbm(type~.,data=dapp,distribution="bernoulli",
               interaction.depth=3,bag.fraction=1,
               cv.folds = 5,n.trees=800)
  nb_logit <- gbm.perf(logit,plot.it=FALSE)
  foret <- ranger(type~.,data=dapp2,probability=TRUE)

  score[ind.test,] <- tibble(arbre=predict(arbre,newdata=dtest,
                                           type="prob")[,2],
                             ada=predict(ada,newdata=dtest,
                                         n.trees=nb_ada,
                                         type="response"),
                             logit=predict(logit,newdata=dtest,
```

```
                                                n.trees=nb_logit,
                                                type="response"),
                                foret=predict(foret,
                                                data=dtest)$prediction[,2])
}
```

```
score1 <- score |> mutate(obs=spam$type) |>
  pivot_longer(-obs,names_to="Methode",values_to="score")
score1 |> group_by(Methode) |>
  roc_curve(truth=obs,estimate=score,event_level="second") |>
  autoplot()
```

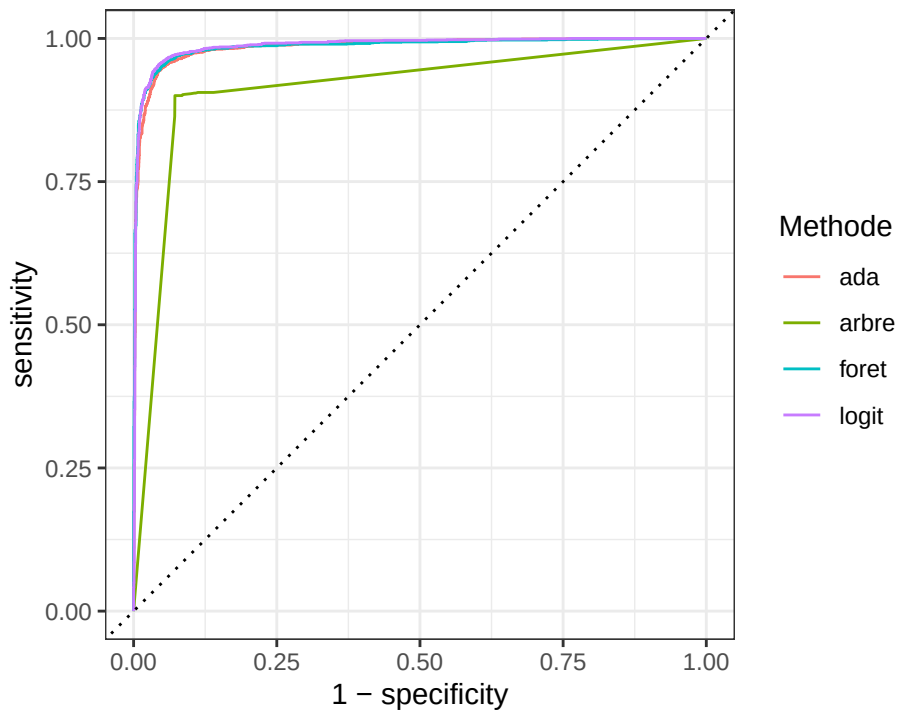


```
score1 |> group_by(Methode) |>
  roc_auc(truth=obs,estimate=score,event_level="second") |>
  arrange(desc(.estimate))
## # A tibble: 4 x 4
##   Methode .metric .estimator .estimate
##   <chr>   <chr>   <chr>          <dbl>
## 1 logit   roc_auc binary         0.988
## 2 foret   roc_auc binary         0.986
## 3 ada     roc_auc binary         0.985
## 4 arbre   roc_auc binary         0.912
```

6.4 Xgboost

L'algorithme **xgboost** Chen et Guestrin (2016) va plusloin que le **gradient boosting** en minimisant une approximation à l'odre 2 de la fonction de perte et en ajoutant un terme de régularisation dans la fonction objectif. On cherche toujours des combinaisons d'arbres

$$f_b(x) = f_{b-1}(x) + h_b(x) \quad \text{où} \quad h_b(x) = w_{q(x)}$$

est un arbre à T feuilles : $w \in \mathbb{R}^T$ et $q : \mathbb{R}^d \to \{1, 2, \ldots, T\}$. À l'étape b, on cherche l'arbre qui minimise la **fonction objectif** de la forme

$$\begin{aligned}\text{obj}^{(b)} &= \sum_{i=1}^{n} \ell(y_i, f_b(x_i)) + \sum_{j=1}^{b} \Omega(h_j) \\ &= \sum_{i=1}^{n} \ell(y_i, f_{b-1}(x_i) + h_b(x_i)) + \sum_{j=1}^{b} \Omega(h_j)\end{aligned}$$

où $\Omega(h_j)$ est un terme de **régularisation** qui va pénaliser h_j en fonction de son nombre de feuilles T et des valeurs prédites w. Un développement limité à l'ordre 2 permet d'approcher cette fonction par

$$\text{obj}^{(b)} = \sum_{i=1}^{n} [\ell_i^{(1)} h_b(x_i) + \frac{1}{2} \ell_i^{(2)} h_b^2(x_i)] + \Omega(h_b) + \text{constantes},$$

avec

$$\ell_i^{(1)} = \frac{\partial \ell(y_i, f(x))}{\partial f(x)}(f_{b-1}(x_i)) \quad \text{et} \quad \ell_i^{(2)} = \frac{\partial^2 \ell(y_i, f(x))}{\partial f(x)^2}(f_{b-1}(x_i)).$$

Pour les arbres, la fonction de régularisation a la forme suivante :

$$\Omega(h) = \Omega(T, w) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^{T} w_j^2,$$

où γ et λ contrôlent le **poids** que l'on donne aux paramètres de l'arbre. On obtient au final l'algorithme suivant

1. Initialisation $f_0 = h_0$.
2. Pour $b = 1, \ldots, B$

a) Ajuster un arbre h_b à T feuilles qui minimise

$$\sum_{i=1}^{n}[\ell_i^{(1)}h_b(x_i) + \frac{1}{2}\ell_i^{(2)}h_b^2(x_i)] + \gamma T + \frac{1}{2}\lambda\sum_{j=1}^{T} w_j.$$

b) Mettre à jour

$$f_b(x) = f_{b-1}(x) + h_b(x).$$

3. Sortie : la suite d'algorithmes $(f_b)_b$.

On pourra trouver plus de précisions ici : https://xgboost.readthedocs.io/en/stable/tutorials/index.html

Exercice 6.1 (Prise en main des principales fonction de xgboost)**.** On commence par charger le package

```
library(xgboost)
```

et on reprend les données sur le **sinus** de la Section 6.1 :

```
x <- seq(-2*pi,2*pi,by=0.01)
y <- sin(x)
set.seed(1234)
X <- runif(200,-2*pi,2*pi)
Y <- sin(X)+rnorm(200,sd=0.2)
df1 <- data.frame(X,Y)
df2 <- data.frame(X=x,Y=y)
```

La fonction `xgboost` requiert que les données possèdent la classe `xgb.DMatrix`, on peut l'obtenir avec

```
X_mat <- xgb.DMatrix(as.matrix(df1[,1]),label=df1$Y)
```

1. Expliquer la sortie

```
boost1 <- xgboost(data=X_mat,nrounds = 5,
                  params=list(objective="reg:squarederror"))
## [1]  train-rmse:0.633250
## [2]  train-rmse:0.468674
## [3]  train-rmse:0.354599
```

```
## [4]  train-rmse:0.275842
## [5]  train-rmse:0.224803
boost1
## ##### xgb.Booster
## raw: 16.4 Kb
## call:
##   xgb.train(params = params, data = dtrain, nrounds = nrounds,
##     watchlist = watchlist, verbose = verbose, print_every_n = print_every_n,
##     early_stopping_rounds = early_stopping_rounds, maximize = maximize,
##     save_period = save_period, save_name = save_name, xgb_model = xgb_model,
##     callbacks = callbacks)
## params (as set within xgb.train):
##   objective = "reg:squarederror", validate_parameters = "TRUE"
## xgb.attributes:
##   niter
## callbacks:
##   cb.print.evaluation(period = print_every_n)
##   cb.evaluation.log()
## niter: 5
## nfeatures : 1
## evaluation_log:
##  iter train_rmse
##     1  0.6332497
##     2  0.4686737
##     3  0.3545990
##     4  0.2758424
##     5  0.2248031
```

2. Faire la même chose avec 100 itération et un `learning rate` de 0.1.

```
boost2 <- xgboost(data=X_mat,nrounds = 100,
                  params=list(objective="reg:squarederror",eta=0.1),
                  verbose = FALSE)
```

3. On peut obtenir les valeurs prédites entre -2π et 2π pour 100 itérations avec

```
Xtest <- as.matrix(df2$X)
prev100 <- predict(boost2,newdata=Xtest,iterationrange = c(1,101))
```

Tracer les estimateurs **xgboost** pour 1 itération, 20 itérations et 100 itérations. Commenter.

```
prev1 <- predict(boost2,newdata=Xtest,iterationrange=c(1,2))
prev20 <- predict(boost2,newdata=Xtest,iterationrange=c(1,21))
```

```r
tbl <- tibble(x=df2$X,vraie=df2$Y,b1=prev1,b20=prev20,b100=prev100) |>
  pivot_longer(-x,names_to = "fonc",values_to = "valeurs")
ggplot(tbl)+aes(x=x,y=valeurs,color=fonc)+geom_line()
```

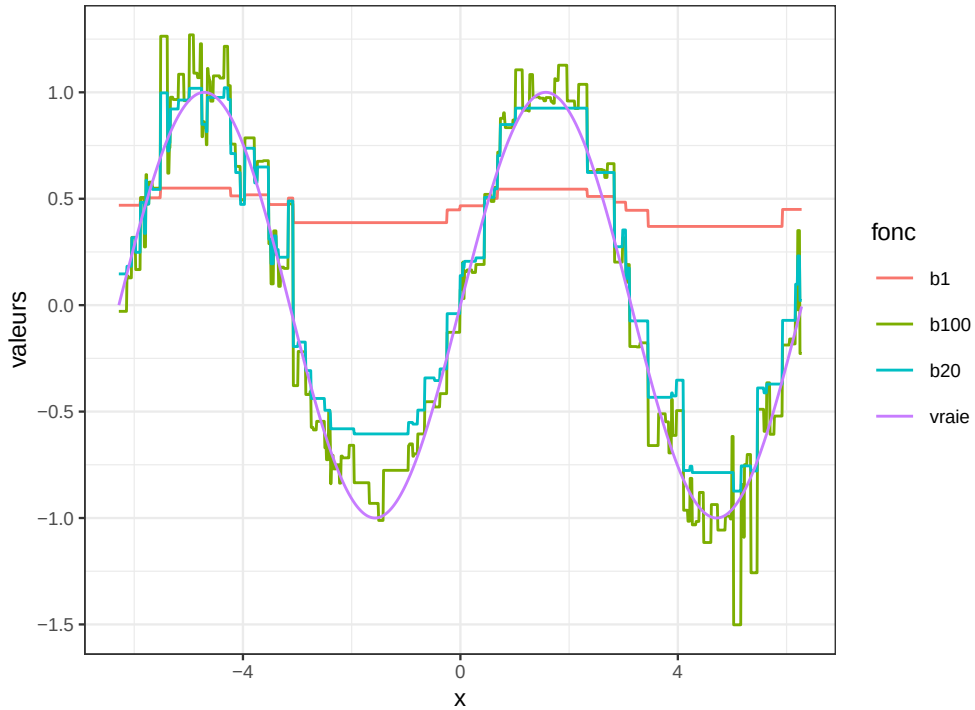

4. Commenter la sortie

```r
set.seed(123)
sel.xgb <- xgb.cv(data = X_mat,
                  nrounds = 100, objective = "reg:squarederror",
                  eval_metric = "rmse",
                  nfold=5,eta=0.1,
                  early_stopping_rounds=10,
                  verbose=FALSE)
sel.xgb$evaluation_log |> head()
##    iter train_rmse_mean train_rmse_std test_rmse_mean
## 1:    1       0.7894653    0.012973111      0.7906004
## 2:    2       0.7189852    0.011889426      0.7228767
## 3:    3       0.6556685    0.010877136      0.6607388
## 4:    4       0.5985454    0.010104324      0.6055111
## 5:    5       0.5471973    0.009379501      0.5567722
## 6:    6       0.5007942    0.008971210      0.5129458
##    test_rmse_std
## 1:    0.05513590
```

```
## 2:    0.05364182
## 3:    0.05284791
## 4:    0.05240736
## 5:    0.05117564
## 6:    0.04971156
(ite.opt.xgb <- sel.xgb$best_iteration)
## [1] 27
sel.xgb$niter
## [1] 37
```

5. Tracer les prévisions pour l'algorithme sélectionné.

```
prev_opt <- predict(boost2,newdata=Xtest,
                    iterationrange=c(1,ite.opt.xgb))
tbl <- tibble(x=df2$X,vraie=df2$Y,bopt=prev_opt) |>
  pivot_longer(-x,names_to = "fonc",values_to = "valeurs")
ggplot(tbl)+aes(x=x,y=valeurs,color=fonc)+geom_line()
```

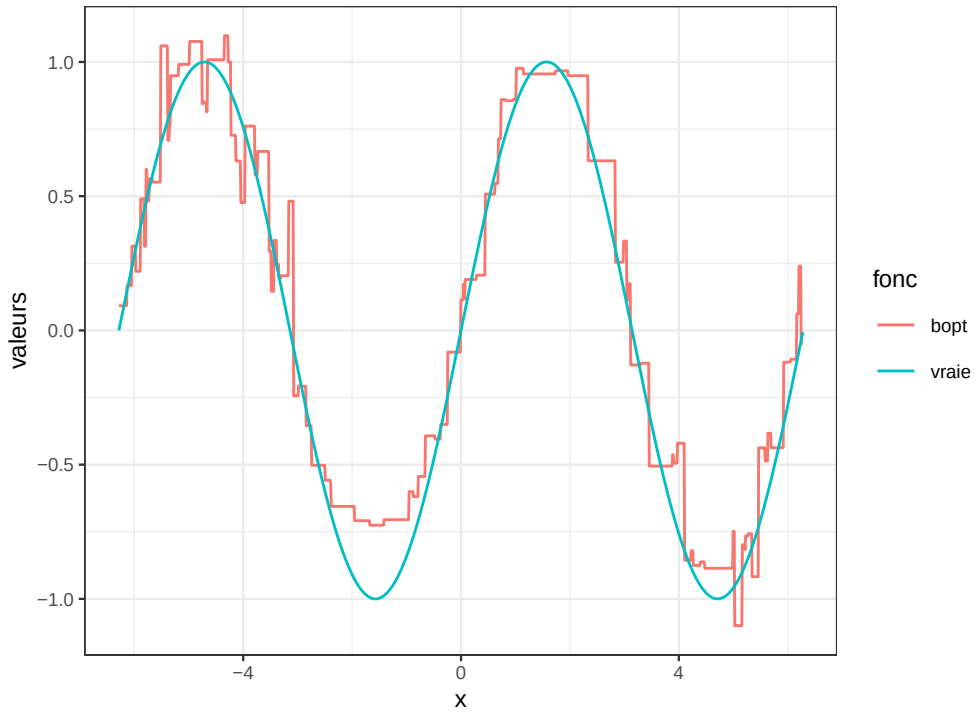

Exercice 6.2 (Xgboost sur les données spam)**.** On reprend les données spam de la Section 6.2. Entraîner un algorithme **xgboost** avec la fonction de perte `binary:logistic` et en sélectionnant

la nombre d'itérations par validation croisée en optimisant l'AUC. **Attention** cette fonction de perte requiert que la variable à expliquer prenne pour valeurs 0 ou 1 en classe `numeric`.

```
spam1 <- as_tibble(spam) |>
  mutate(type=as.numeric(fct_recode(type,`1`="spam",`0`="nonspam"))-1)
X_mat <- xgb.DMatrix(as.matrix(spam1[,1:56]),label=spam1$type)
```

```
boost1 <- xgboost(data=X_mat,nrounds = 5,
                  params=list(objective="binary:logistic"))
## [1]  train-logloss:0.499990
## [2]  train-logloss:0.387195
## [3]  train-logloss:0.318618
## [4]  train-logloss:0.262772
## [5]  train-logloss:0.224457
```

```
set.seed(123)
sel.xgb <- xgb.cv(data = X_mat,
                  nrounds = 500, objective = "binary:logistic",
                  eval_metric = "auc",
                  nfold=5,eta=0.1,
                  early_stopping_rounds=10,
                  prediction=TRUE,
                  verbose=FALSE)
(ite.opt.xgb <- sel.xgb$best_iteration)
## [1] 198
sel.xgb$niter
## [1] 208
sel.xgb$evaluation_log
##      iter train_auc_mean train_auc_std test_auc_mean
##   1:    1      0.9500731  2.121192e-03     0.9306506
##   2:    2      0.9564121  4.808012e-03     0.9425352
##   3:    3      0.9621426  1.063738e-03     0.9493209
##   4:    4      0.9641394  2.185222e-03     0.9528820
##   5:    5      0.9677919  3.347806e-03     0.9577987
##  ---
## 204:  204      0.9995687  4.404906e-05     0.9884326
## 205:  205      0.9995765  4.599862e-05     0.9884267
## 206:  206      0.9995785  4.314789e-05     0.9884106
## 207:  207      0.9995888  3.724468e-05     0.9884006
## 208:  208      0.9995943  3.701767e-05     0.9883994
##      test_auc_std
##   1: 0.0034779143
##   2: 0.0035386497
##   3: 0.0035729044
##   4: 0.0039124835
```

```
##   5: 0.0064362485
##  ---
## 204: 0.0009331813
## 205: 0.0009201703
## 206: 0.0009008832
## 207: 0.0009117750
## 208: 0.0009253329
```

```
score <- tibble(prev=sel.xgb$pred,obs=spam$type)
```

```
score |> roc_curve(truth=obs,estimate=prev,event_level="second") |>
  autoplot()
```

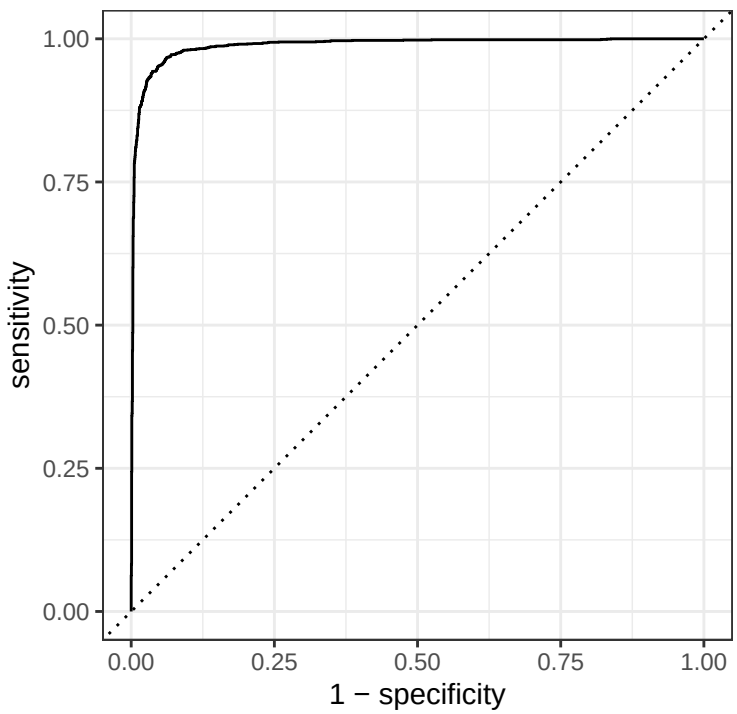


```
score |> roc_auc(truth=obs,estimate=prev,event_level="second")
## # A tibble: 1 x 3
##   .metric .estimator .estimate
##   <chr>   <chr>          <dbl>
## 1 roc_auc binary         0.988
```

Exercice 6.3 (Sélection avec tidymodels)**.** Refaire l'exercice précédent avec la syntaxe `tidymodels`. On choisira notamment :

- la profondeur des arbres dans le vecteur

```
c(1,3,8,10)
```

- le nombre d'itérations entre 1 et 500 avec un `early_stopping` toujours égal à 10 et un learning rate à 0.05.

On pourra consulter la page https://www.tidymodels.org/find/parsnip/ pour trouver les noms de paramètre du `worfklow` et sur le tutoriel https://juliasilge.com/blog/shelter-animals/ pour la stratégie. Elle est ici de fixer le nombre d'itérations à 500 puisqu'on utilise le **early stopping** en séparant les données en 2. On initialisera donc le workflow avec

```
library(tidymodels)
tune_spec <-
  boost_tree(tree_depth=tune(),trees=500,learn_rate=0.05,
             stop_iter=10) |>
  set_mode("classification") |>
  set_engine("xgboost",validation=0.2)

xgb_wf <- workflow() |>
  add_model(tune_spec) |>
  add_formula(type ~ .)
```

```
set.seed(321)
grille <- expand.grid(tree_depth=c(1,3,8,10))
re_ech <- vfold_cv(spam,v=5)
```

```
xgb_tidy <- xgb_wf |>
  tune_grid(
    resamples = re_ech,
    grid = grille,
    metrics=metric_set(roc_auc))
```

```
xgb_tidy |> collect_metrics()
## # A tibble: 4 x 7
##   tree_depth .metric .estimator  mean     n  std_err .config
##        <dbl> <chr>   <chr>      <dbl> <int>    <dbl> <chr>
## 1          1 roc_auc binary     0.981     5 0.00144  Prepro~
## 2          3 roc_auc binary     0.988     5 0.000946 Prepro~
## 3          8 roc_auc binary     0.987     5 0.000569 Prepro~
## 4         10 roc_auc binary     0.988     5 0.000862 Prepro~
```

```r
(best_par <- xgb_tidy |> select_best())
## # A tibble: 1 x 2
##   tree_depth .config
##        <dbl> <chr>
## 1         10 Preprocessor1_Model4
```

```r
final_xgb <-
  xgb_wf |>
  finalize_workflow(best_par) |>
  fit(data=spam)
```

```r
mod_final <- final_xgb$fit$fit$fit
mod_final$best_iteration
## [1] 136
```

```r
final_xgb |> extract_fit_parsnip() |>
  vip(num_features = 15, geom = "point")
```

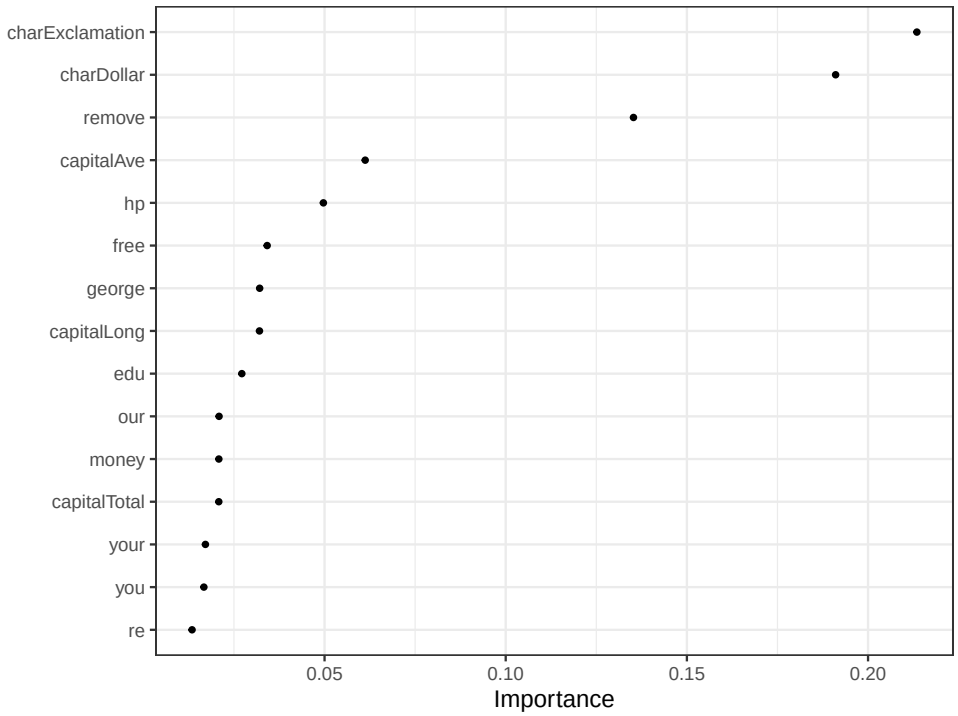

Références

Boehmke, B., et B. Greenwell. 2019. *Hands-On Machine Learning with R*. CRC Press. https://bradleyboehmke.github.io/HOML/.

Breiman, L. 2001. « Random forests ». *Machine learning* 45: 5-32.

Breiman, L., J. Friedman, R. Olshen, et C. Stone. 1984. *Classification and regression trees*. Wadsworth & Brooks.

Chen, T., et C. Guestrin. 2016. « XGBoost: A Scalable Tree Boosting System ». In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-94. KDD '16. New York, NY, USA: ACM. https://doi.org/10.1145/2939672.2939785.

Friedman, J. H. 2001. « Greedy Function Approximation: A Gradient Boosting Machine ». *Annals of Statistics* 29: 1189-1232.

Hastie, T., R. Tibshirani, et J. Friedman. 2009. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Second. Springer. https://web.stanford.edu/~hastie/ElemStatLearn/.

Ridgeway, G. 2006. « Generalized boosted models: A guide to the gbm package ».